# Estimación y Predicción en Series Temporales

Práctico 3: Estimadores MLE y MAP

#### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

## Agenda<sup>l</sup>

Hallar el MLE del parámetro desconocido [7.3]
Consistencia del MLE [7.5]
Propiedades asintóticas del MLE [7.20]

2

Minimum Mean Square Error (BMSE)
Comparación MMSE vs MAP [11.3]
MMSE de una transformación lineal [11.8, 11.9]
Máximo a posteriori (MAP)
Hallar el estimador MAP [11.4]

- Se tienen N muestras IID de las siguientes PDFs
  - a) Gaussiana

$$p(x;\mu) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}(x-\mu)^2\right]$$

b) Exponencial

$$p(x;\lambda) = \begin{cases} \lambda \exp(-\lambda x) & x > 0\\ 0 & x < 0 \end{cases}$$

 Hallar el MLE y verificar que maximiza la función de verosimilitud.

a) Gaussiana

$$p(x;\mu) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}(x-\mu)^2\right]$$

 Como son variables IID, la verosimilitud de las N muestras es:

$$p(\mathbf{x}; \mu) = \prod_{i=0}^{N-1} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}(x-\mu)^2\right]$$

• Como el logaritmo es una función monótona, maximizar  $p(\mathbf{x};\mu)$ , es lo mismo que maximizar  $\log p(\mathbf{x};\mu)$ 

$$\log p(\mathbf{x}; \mu) = N \log \left( \frac{1}{\sqrt{2\pi}} \right) + \sum_{i=0}^{N-1} -\frac{1}{2} (x_i - \mu)^2$$

$$\log p(\mathbf{x}; \mu) = -\frac{N}{2} \log(2\pi) - \frac{1}{2} \sum_{i=0}^{N-1} (x_i - \mu)^2$$

• Queremos maximizar según  $\mu$ . La  $\log p(\mathbf{x};\mu)$  es un polinomio de grado 2 con concavidad negativa, tiene un único máximo global.

$$\frac{\partial \log p(\mathbf{x}; \mu)}{\partial \mu} = 0$$

$$\frac{\partial \log p(\mathbf{x}; \mu)}{\partial \mu} = \sum_{i=0}^{N-1} x_i - \mu = 0 \iff \mu = \frac{\sum_i x_i}{N}$$

• El MLE  $\hat{\mu}$  es la media muestral.

b) Exponencial

$$p(x; \lambda) = \begin{cases} \lambda \exp(-\lambda x) & x > 0 \\ 0 & x < 0 \end{cases}$$

Planteamos la verosimilitud

$$p(\mathbf{x}; \lambda) = \prod_{i=0}^{N-1} \exp(-\lambda x_i)$$

Tomando logaritmo

$$\log p(\mathbf{x}; \lambda) = N \log(\lambda) - \sum_{i=0}^{N-1} \lambda x_i$$

Hallamos el máximo anulando la primera derivada

$$\frac{\partial \log p(\mathbf{x}; \lambda)}{\partial \lambda} = \frac{N}{\lambda} - \sum_{i=0}^{N-1} x_i$$

$$\frac{N}{\lambda} - \sum_{i=0}^{N-1} x_i = 0 \iff \lambda = \frac{N}{\sum_i x_i}$$

• El MLE  $\hat{\lambda}$  es el inverso de la media muestral.

 Solo falta comprobar que el valor hallado corresponde al máximo. Calculemos la derivada segunda y verifiquemos su valor negativo.

$$\frac{\partial^2 \log p(\mathbf{x}; \lambda)}{\partial \lambda^2} = -\frac{N}{\lambda^2}$$

La segunda derivada es negativa  $\forall \lambda$ .

## Consistencia del MLE [7.5]

• Un estimador  $\hat{\theta}$  es consistente si, para cualquier  $\epsilon > 0$ ,

$$\lim_{N\to\infty} \Pr\{|\hat{\theta}-\theta|>\epsilon\}=0$$

 Demostrar que la media muestral es un estimador consistente para la estimación del nivel A de DC en AWGN. Sugerencia: Usar la desigualdad de Chebychev.

#### Teorema

Sea X una V.A con esperanza finita  $\mu$  y varianza finita  $\sigma^2 \neq 0$ . Entonces para cualquier real k > 0

$$\Pr\{|X - \mu| \ge k\sigma\} \le \frac{1}{k^2}$$

## Consistencia del MLE [7.5]

Se tiene

$$x[n] = A + w[n], \ w[n] \sim \mathcal{N}(0, \sigma^2)$$

- ullet La esperanza del estimador  $\hat{A} = rac{\sum_i x_i}{N}$ , es  $\mathbb{E}[\hat{A}] = A$
- La varianza es

$$\operatorname{var}(\hat{A}) = \operatorname{var}\left(\frac{\sum_{i} x_{i}}{N}\right) = \frac{\sum_{i} \operatorname{var}(x_{i})}{N^{2}} = \frac{\sigma^{2}}{N}$$

• Usando  $k = \frac{\epsilon}{\sigma}$  en la desigualdad

$$\Pr\{|\hat{A} - A| \ge \epsilon\} \stackrel{Chebychev}{\le} \frac{\sigma^2}{N\epsilon^2} \xrightarrow[N \to \infty]{} 0$$

Se consideran N muestras de la señal

$$x[n] = s[n] + w[n]$$

donde s[n] es desconocido y w[n] es WGN de varianza  $\sigma^2$ . Hallar el MLE de s[n] y analizar las propiedades asintóticas: sesgo, eficiencia, distribución normal y consistencia.

Las muestras son IID

$$p(\mathbf{x}; \mathbf{s}) = p_w(\mathbf{x} - \mathbf{s})$$

$$p(\mathbf{x}; \mathbf{s}) = \prod_{i=0}^{N-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2} \left(\frac{x_i - s_i}{\sigma}\right)^2\right]$$

Aplicamos logaritmo

$$\log p(\mathbf{x}; \mathbf{s}) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=0}^{N-1} (x_i - s_i)^2$$

Tomamos derivadas parciales respecto a cada  $s_i$ 

$$\frac{\partial \log p(\mathbf{x}; \mathbf{s})}{\partial s_i} = \frac{x_i - s_i}{\sigma^2} = 0 \iff s_i = x_i$$

• El estimador MLE de cada  $\hat{s}[n]$  es simplemente el valor de la muestra x[n]

- Sesgo: El estimador es insesgado ( $\mathbb{E}[\hat{s}[n]] = \mathbb{E}[x[n]] = \mathbb{E}[s[n])$
- Distribución normal (PDF):

$$(x[n] - s[n]) \sim \mathcal{N}(0, \sigma^2)$$
  
 $x[n] \sim \mathcal{N}(s[n], \sigma^2)$ 

El estimador tiene distribución normal.

#### • Eficiencia:

Calculemos la CRLB para ver si la varianza del estimador la alcanza, de ser así, tenemos un estimador eficiente.

$$\operatorname{var}(\hat{s}[n]) \ge \frac{1}{-\mathbb{E}_x \left[\frac{\partial^2 \log p(x[n]; s[n])}{\partial s[n]^2}\right]}$$

$$\frac{\partial^2 \log p(x[n]; s[n])}{\partial s[n]^2} = -\frac{1}{\sigma^2}$$

La varianza del estimador alcanza la CRLB, por lo tanto, es eficiente.

• Consistencia: El estimador no es consistente pues cuando  $N \to \infty$  la varianza del estimador se mantiene constante. (No hay ningún efecto de promediado, ya que se quieren estimar

tantos parámetros como muestras se tienen)

• Para que la distribución asintótica del MLE sea gaussiana, se deben tener N muestras para estimar cada parámetro, de forma que cuando  $N \to \infty$  se pueda aplicar el Teorema Central del Límite. (Ver Apéndice 2 [?])

## Comparación MMSE vs MAP [11.3]

Para la siguiente PDF a posteriori:

$$p(\theta|x) = \begin{cases} \exp\big[-(\theta-x)\big] & \theta > x \\ 0 & \theta < x \end{cases}$$

Hallar los estimadores MMSE y MAP.

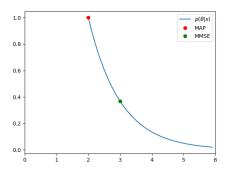
## Comparación MMSE vs MAP [11.3]

- Estimador MAP Es el  $\theta$  que maximiza la posteriori  $\rightarrow \hat{\theta}_{MAP} = x$
- Estimador MMSE

$$\begin{split} \mathbf{E}[\theta|x] &= \int_x^\infty \theta \exp\big[-(\theta-x)\big] d\theta \\ \int_x^\infty \theta \exp\big[-(\theta-x)\big] d\theta &= -e^x \big(\theta e^{-\theta} + e^{-\theta}\big)\bigg|_x^\infty \\ &= e^x (xe^{-x} + e^{-x}) = x + 1 \end{split}$$

## Comparación MMSE vs MAP [11.3]

- $\hat{\theta}_{MAP} = x$   $\hat{\theta}_{MMSE} = x + 1$



• Considerar un parámetro  $\theta$  que evoluciona en el tiempo con la siguiente ley determinística:

$$\boldsymbol{\theta}[n] = A\boldsymbol{\theta}[n-a]$$

Siendo A una matriz  $p \times p$  conocida e invertible y  $\theta[0]$  un vector aleatorio (realización del parámetro desconocido).

• Demostrar que el MMSE de  $\theta[n]$  es:

$$\hat{\boldsymbol{\theta}}[n] = A^n \hat{\boldsymbol{\theta}}[0]$$

Siendo  $\hat{\boldsymbol{\theta}}[0]$  el MMSE de  $\boldsymbol{\theta}[0]$ 

## Ejercicios [?]

## MMSE de una transformación lineal [11.8, 11.9]

$$\hat{\boldsymbol{\theta}}[n] = \mathbf{E}[\boldsymbol{\theta}[n]|\mathbf{x}] = \mathbf{E}[A\boldsymbol{\theta}[n-1]|\mathbf{x}]$$

$$= A\mathbf{E}[\boldsymbol{\theta}[n-1]|\mathbf{x}] = A\hat{\boldsymbol{\theta}}[n-1]$$

. . .

$$\hat{\boldsymbol{\theta}}[n] = A^n \hat{\boldsymbol{\theta}}[0]$$

 Como el modelo es lineal y la esperanza también lo es, basta con estimar el parámetro en un tiempo para tener un estimado para todos los demás instantes

 Un vehículo que arranca en una posición desconocida y se mueve con velocidad desconocida pero constante, puede modelarse de la siguiente forma:

$$x[n] = x[0] + v_x n$$
$$y[n] = y[0] + v_y n$$

Se quieren estimar todos los parámetros para todo tiempo y se modela la posición inicial y la velocidad como un vector aleatorio  $\boldsymbol{\theta}[n] = \begin{bmatrix} x[n], y[n], v_x, v_y \end{bmatrix}^T$ 

 Apliquemos lo hallado anteriormente. Primero escribamos la evolución de los parámetros en forma lineal:

$$\theta[n] = A\theta[n-1] = A^n\theta[0]$$

Por ejemplo

$$x[n] - x[n-1] = vx$$

$$\rightarrow x[n] = x[n-1] + vx$$

Lo mismo sucede para y[n] y las velocidades permanecen constantes.

Podemos escribirlo en forma matricial

$$A = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

 Aplicando el resultado anterior, podemos estimar la posición para cualquier tiempo con la matriz A y el estimador MMSE en tiempo 0

$$\hat{\boldsymbol{\theta}}_{MMSE}[n] = A^n \hat{\boldsymbol{\theta}}_{MMSE}[0]$$

## Hallar el estimador MAP [11.4]

Se observan N muestras de la siguiente señal:

$$x[n] = A + w[n]$$

A es desconocido,  $\lambda > 0$  y w[n] WGN de varianza  $\sigma^2$  independiente de A. Hallar el estimador MAP de A, asumiendo que su distribución a priori es:

$$p(A) = \begin{cases} \lambda e^{-\lambda A} & A > 0\\ 0 & A < 0 \end{cases}$$

#### Hallar el estimador MAP [11.4]

El estimador MAP se halla de la siguiente forma:

$$\hat{A} = \underset{A}{\operatorname{arg max}} p(A|x) = \underset{A}{\operatorname{arg max}} \frac{p(x|A)p(A)}{p(x)}$$
$$= \underset{A}{\operatorname{arg max}} log p(\mathbf{x}|A) + log p(A)$$

Utilizando las PDFs del problema:

$$log p(\mathbf{x}|A) = -\frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=0}^{N-1}(x_i - A)^2$$

$$log p(A) = log(\lambda) - \lambda A$$

con A > 0

#### Hallar el estimador MAP [11.4]

Tomamos derivada e igualamos a 0 para hallar el máximo

$$\frac{\partial logp(\mathbf{x}|A) + logp(A)}{\partial a} = \frac{\sum_{i=0}^{N-1} (x_i - A)^2}{\sigma} - \lambda A = 0$$

$$\iff \hat{A} = \frac{\sum_i x_i}{N} - \frac{\sigma^2 \lambda}{N}$$

- Si  $N \to \infty$ ,  $\hat{A}_{MAP}$  tiende a la media muestral (ignoramos el prior). El prior también se debilita si las muestras tienen poco ruido.
- Si λ es grande (prior fuerte), el estimador se aleja de la media muestral. Lo mismo sucede si las muestras son ruidosas.
- Es un estimador sesgado por el prior.

## Referencias I