# Estimación y Predicción en Series Temporales

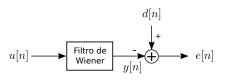
Práctico 6: filtros adativos

#### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

## Filtros lineales óptimos: filtro de Wiener



- d[n] señal deseada
- u[n] señal observable conjuntamente estacionaria con d[n]
- : Diseñar un filtro discreto cuya salida y[n] provea un estimador de una señal deseada d[n] a partir de una señal de entrada correlacionada u[n].
- El criterio de optimización es la minimización del error cuadrático medio de la estimación, definido como

$$J(\mathbf{w}) = E(|e[n]|^2),$$
 con  $e[n] = d[n] - y[n].$ 

ullet En el caso en que el filtro Wiener es FIR con M coeficientes, la dependencia del error cuadrático medio con los coeficientes del filtro es

$$J(\mathbf{w}) = \sigma_d^2 - \mathbf{p}^H \mathbf{w} - \mathbf{w}^H \mathbf{p} + \mathbf{w}^H \mathbf{R} \mathbf{w}$$
 (1)

#### Filtro de Wiener

 Los coeficientes del filtro óptimo que minimizan el error cuadrático medio cumplen que

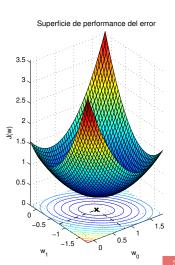
$$\nabla_{\mathbf{w}} J(\mathbf{w}) = 0,$$

• lo que conduce al sistema  $M \times M$  denominado

$$\mathbf{R}\mathbf{w}_o = \mathbf{p} \qquad \Leftrightarrow \qquad \mathbf{w}_o = \mathbf{R}^{-1}\mathbf{p}$$

 Con el filtro funcionando en condiciones óptimas, el error mínimo es

$$J(\mathbf{w}) = J_{min}$$
$$= \sigma_d^2 - \mathbf{w}_o^H \mathbf{R} \mathbf{w}_o$$

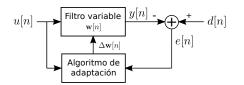


#### Filtro de Wiener

#### Observaciones

- Se necesita conocer la función de autocorrelación de la entrada R y la correlación cruzada entre la entrada y la señal deseada p.
- Se necesita invertir R, que es Topelitz y simétrica.
  - Puede ser costoso computacionalmente si M es grande.
  - Mala estimación si la matriz está mal condicionada.
- Hipótesis: El filtro de Wiener solo puede aplicarse en condiciones de estacionaridad:
  - u[n] estacionario en sentido amplio (*WSS*).
  - u[n] y d[n] tienen que ser conjuntamente estacionarios.

# Filtros adaptivos



- d[n] señal deseada
- u[n] señal observable conjuntamente estacionaria con d[n]
- Los coeficientes del filtro se actualizan con el requerimiento de cuadrático medio J[n] en cada iteración,

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \Delta \mathbf{w}[n].$$

- El define como se realiza la corrección de los coeficientes en cada paso, es decir, define  $\Delta \mathbf{w}[n]$ .
  - Para eso, usa la señal de error e[n], ya que permite al filtro medir su desempeño y determinar como deben ser actualizados los coeficientes.
- Teniendo en cuenta que los coeficientes son variables, la salida del filtro es

M-1

## Filtros adaptivos

#### Curva de aprendizaje

- La curva de aprendizaje de un filtro adaptivo es la evolución del error cuadrático medio J[n] con el número de iteración.
- Indica cuan rápido el filtro adaptivo aprende la solución de las ecuaciones de Wiener-Hopf.

#### Propiedades deseables de un filtro adaptivo

• En condiciones estacionarias, el filtro debe producir una sucesión de correcciones  $\Delta \mathbf{w}[n]$  de forma de que  $\mathbf{w}[n]$  converja al filtro de Wiener,

$$\lim_{n \to \infty} \mathbf{w}[n] = \mathbf{R}^{-1} \mathbf{p}.$$

• No debería ser necesario conocer  $r_u[k]$  y p[k] para calcular  $\Delta \mathbf{w}[n]$ . La estimación de la estadística de las señales

 En el método de descenso por gradiente, la regla de adaptación es

$$\mathbf{w}[n\!+\!1] = \mathbf{w}[n] \!+\! \frac{1}{2} \mu \left( -\nabla J[n] \right)$$

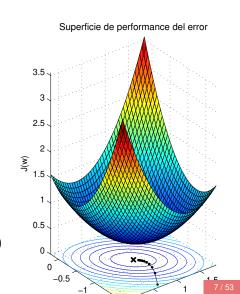
- $\mu > 0$ : tamaño del paso de adaptación
- Aplicando el gradiente a J[n] (ecuación 1) se tiene que

$$\nabla J[n] = -2\mathbf{p} + 2\mathbf{R}\mathbf{w}[n]$$

La regla de adaptación queda

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu \left(\mathbf{p} - \mathbf{R}\mathbf{w}[n]\right)$$

El algoritmo comienza con
alguna estimación inicial de



#### Estabilidad del algoritmo de descenso por gradiente

La evolución del i-ésimo coeficiente del filtro está dada por

$$w_i[n] = w_{io} + \sum_{k=0}^{M-1} a_{ik} (1 - \mu \lambda_k)^n$$
  $i = 0, 1, \dots, M-1$ 

- $w_{io}$  es el valor óptimo del i-ésimo coeficiente del filtro.
- $\lambda_k$  son los valoes propios de  $\mathbf{R}$ .
- a<sub>ik</sub> son constantes que dependen de las condiciones iniciales y los valores y vectores propios de R.
- Cada exponencial en la sumatoria se llama modo natural del filtro.

### Convergencia

En el caso estacionario, el algoritmo de descenso por gradiente converge a la solución de las ecuaciones de Wiener-Hopí si el tamaño de paso cumple que [los modos naturales se

#### Velocidad de convergencia

• Se define la constante de tiempo  $\tau_k$  como la cantidad de iteraciones para que el k-ésimo modo caiga 1/e de su valor inicial,

$$(1 - \mu \lambda_k)^{\tau_k} = \frac{1}{e}$$
  $\Rightarrow$   $\tau_k = -\frac{1}{\ln(1 - \mu \lambda_k)}$ 

- En el caso en que  $\mu$  es pequeño ( $\mu\lambda_k\ll 1$ ),  $au_kpprox rac{1}{\mu\lambda_k}$
- Definiendo la constante de tiempo global  $\tau$  como la cantidad de iteraciones para que el modo de decaimiento mas lento caiga 1/e de su valor inicial,

$$au = \max au_k pprox rac{1}{\mu \lambda_{\mathsf{min}}}$$

• Definiendo  $\alpha$  como el paso de adaptación normalizado,

### Algoritmo (descenso por gradiente, máxima pendiente)

$$\left\{ \begin{array}{ll} \mathbf{w}[0] &= \mathbf{0} \\ \mathbf{w}[n+1] &= \mathbf{w}[n] + \mu \left( \mathbf{p} - \mathbf{R} \mathbf{w}[n] \right) \end{array} \right.$$

#### Observacio<u>nes</u>

- Hay que conocer R y p, igual que en cálculo del filtro de Wiener.
- Hipótesis:
  - u[n] estacionario en sentido amplio
  - u[n] y d[n] conjuntamente estacionarios
- No se necesita invertir R.
- Si el algoritmo converge, lo hace al filtro óptimo (filtro de Wiener).
- Condición de convergencia: El paso de adaptación tiene que cumplir

## Algoritmo LMS

 En el método de descenso por gradiente, la regla de adaptación es

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \frac{1}{2}\mu \left(-\nabla J[n]\right) \qquad \text{con} \qquad \nabla J[n] = -2\mathbf{p} + 2\mathbf{R}\mathbf{w}[n]$$

En el algoritmo LMS,

$$\hat{\mathbf{w}}[n{+}1] = \hat{\mathbf{w}}[n] {+} \frac{1}{2} \mu \left( -\hat{\nabla} J[n] \right)$$

Valores verdaderos

$$\mathbf{R}[n] = E\left(\mathbf{u}[n]\mathbf{u}^{H}[n]\right)$$
$$\mathbf{p}[n] = E\left(\mathbf{u}[n]d^{*}[n]\right)$$

Usando los estimadores instantáneos, la estimación del gradiente es

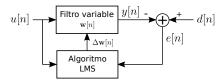
Estimadores instantáneos

 $con \qquad \hat{\nabla}J[n] = -2\hat{\mathbf{p}} + 2\hat{\mathbf{R}}\hat{\mathbf{w}}[n]$ 

$$\hat{\mathbf{R}}[n] = \mathbf{u}[n]\mathbf{u}^H[n]$$
$$\hat{\mathbf{p}}[n] = \mathbf{u}[n]d^*[n]$$

## Algoritmo LMS

La ecuación en recurrencia del algoritmo LMS queda



- : Se establecen condiciones iniciales:  $\hat{\mathbf{w}}[0] = \mathbf{0}$ .
- : Se tiene la estimación de  $\hat{\mathbf{w}}[n]$ 
  - Se calcula la salida del filtro,

$$y[n] = \hat{\mathbf{w}}^H[n]\mathbf{u}[n]$$

Se calcula el error de estimación,

$$e[n] = d[n] - y[n]$$

3 Se adaptan los coeficientes del filtro,

$$\hat{\mathbf{w}}[n+1] = \hat{\mathbf{w}}[n] + \mu \mathbf{u}[n]e^*[n]$$

## Propiedades del algoritmo LMS

#### Hipótesis de independencia

Los datos  $\mathbf{u}[n]$  y los coeficientes del filtro  $\hat{\mathbf{w}}[n]$  son estadísticamente independientes.

- Como  $\hat{\mathbf{w}}[n]$  depende de  $\mathbf{u}[n-1], \, \mathbf{u}[n-2], \ldots,$  la hipótesis no es cierta.
- El uso de la hipótesis conduce a propiedades de convergencia que coinciden con los resultados experimentales.

#### Convergencia

Si los procesos son conjuntamente estacionarios y se cumple la hipótesis de independencia, el algoritmo LMS converge en media si se cumple que

$$0 < \mu < rac{2}{\lambda_{\max}}, \qquad ext{con } \lambda_{\max} ext{ el valor propio máximo de } \mathbf{R}.$$

13 / 53

## Propiedades del algoritmo LMS

#### Error por exceso

- Con el filtro de Wiener, el error cuadrático medio de estimación al usar los coeficientes óptimos es  $J(\mathbf{w}_o) = J_{min}$ .
- Las estimaciones sucesivas de los coeficientes  $\hat{\mathbf{w}}[n]$  en el algoritmo LMS sufren de ruido de gradiente debido al uso de estimadores instantáneos.
- Como resultado, en funcionamiento en régimen los coeficientes permanecen fluctuando en torno a los coeficientes óptimos w<sub>o</sub>.
- El error en régimen con el algoritmo LMS será mayor que el error producido por el filtro óptimo. La diferencia es el error por exceso,

$$J_{ex}[n] = J[n] - J_{min}$$
 con  $J[n] = E(|e[n]|^2)$ .

En condiciones de convergencia, el exter quadrática madia

# Propiedades del algoritmo LMS

#### Curva de aprendizaje

• En el algoritmo de descenso por gradiente, dado  $\mathbf{w}[0]$ , la curva de aprendizaje queda completamente determinada,

$$J[n] = \sigma_d^2 - \mathbf{p}^H \mathbf{w}[n] - \mathbf{w}^H[n]\mathbf{p} + \mathbf{w}^H[n]\mathbf{R}\mathbf{w}[n].$$

 En el algoritmo LMS, la curva de aprendizaje no es determinística porque la estimación del gradiente se realiza empleando valores muestrales de la entrada y la señal deseada,

$$J[n] = |e^2[n]|.$$

 La curva de aprendizaje es ruidosa. Una estimación adecuada se logra promediando las curvas de aprendizaje en muchos experimentos usando los mismos parámetros.

### Algoritmo NLMS

En el algoritmo LMS, la adaptación de los coeficientes está dada por

$$\hat{\mathbf{w}}[n+1] = \hat{\mathbf{w}}[n] + \mu \mathbf{u}[n]e^*[n] \qquad \text{con } 0 < \mu < 2/\lambda_{max}$$

- Aparecen dos dificultades:
  - Si  $\mathbf{u}[n]$  es grande, se produce
  - No se conoce **R** y por lo tanto tampoco  $\lambda_{max}$ .
- La condición de convergencia puede sustituirse por la condición mas restrictiva (convergencia en media cuadrática)

$$0 < \mu < \frac{2}{ME(|u[n]|^2)}$$

•  $E(|u[n]|^2)$  puede estimarse a partir de  $\mathbf{u}[n]$ ,

$$\begin{split} \widehat{E(|u[n]|^2)} &= \frac{1}{M} \sum_{k=0}^{M-1} |u[n-k]|^2 = \frac{1}{M} \mathbf{u}^H[n] \mathbf{u}[n] = \frac{1}{M} \|\mathbf{u}[n]\|^2. \\ \text{lo que conduce a la restricción} \qquad 0 < \mu < \frac{2}{\|\mathbf{u}[n]\|^2}. \end{split}$$

## Algoritmo NLMS

 Teniendo en cuenta esta restricción, el paso de adaptación del algoritmo LMS puede ser sustituido por el paso variable

$$\mu[n] = \frac{\beta}{\|\mathbf{u}[n]\|^2} \qquad \text{con} \qquad 0 < \beta < 2.$$

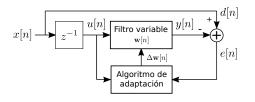
Esto conduce al algoritmo NLMS,

$$\hat{\mathbf{w}}[n+1] = \hat{\mathbf{w}}[n] + \beta \frac{\mathbf{u}[n]}{\|\mathbf{u}[n]\|^2} e^*[n]$$

• Ocurre un problema similar al de amplificación del ruido de gradiente si  $\|\mathbf{u}[n]\|$  es pequeño. Para evitarlo se aplica la siguiente modificación,

$$\hat{\mathbf{w}}[n+1] = \hat{\mathbf{w}}[n] + \beta \frac{\mathbf{u}[n]}{\epsilon + ||\mathbf{u}[n]||^2} e^*[n],$$

con  $\epsilon$  algún número real positivo pequeño.



- La señal deseada d[n] es cierta señal x[n] que se quiere predecir.
- La entrada al filtro adaptivo es la señal retardada 1 muestra, u[n] = x[n-1].

## Ejemplo

• La señal a predecir es un proceso AR(2):

$$x[n] = -a_1x[n-1] - a_2x[n-2] + v[n]$$
 con  $v[n]$  de potencia  $\sigma_v^2$ 

• El filtro adaptivo a diseñar es de primer orden (M=2).

#### Filtro de Wiener

• Para encontrar el filtro óptimo, hay que resolver las ecuaciones de Wiener-Hopf de tamaño  $2 \times 2$ .

• Como d[n] = x[n] y u[n] = x[n-1], la correlación cruzada es

$$p[-k] = E\{u[n-k]d[n]\}\}$$

$$= E\{x[n-1-k]x[n]\}$$

$$= r_x[k+1] = r_u[k+1]$$

Las ecuaciones de Wiener-Hopf quedan en este caso

$$\begin{bmatrix} r_u[0] & r_u[1] \\ r_u[1] & r_u[0] \end{bmatrix} \begin{bmatrix} w[0] \\ w[1] \end{bmatrix} = \begin{bmatrix} r_u[1] \\ r_u[2] \end{bmatrix}$$

• Teniendo en cuenta que x[n] (y por lo tanto u[n]) es un proceso AR(2), usando las ecuaciones de Yule-Walker se tiene que

$$r_u[0] = \frac{1 + a_2}{(1 - a_2) \left[ (1 + a_2)^2 - a_1^2 \right]} \sigma_v^2 = \sigma_u^2$$

$$r_u[1] = \frac{-a_1}{1 + a_2} \sigma_u^2$$

Las ecuaciones de Wiener-Hopf quedan

$$\sigma_u^2 \left[ \begin{array}{cc} 1 & \frac{-a_1}{1+a_2} \\ \frac{-a_1}{1+a_2} & 1 \end{array} \right] \left[ \begin{array}{c} w_0 \\ w_1 \end{array} \right] = \sigma_u^2 \left[ \begin{array}{c} \frac{-a_1}{1+a_2} \\ \frac{a_1^2}{1+a_2} - a_2 \end{array} \right]$$

 Resolviendo el sistema se llega a que los coeficientes del predictor son,

$$\mathbf{w}_o = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} = \begin{bmatrix} -a_1 \\ -a_2 \end{bmatrix} \qquad y[n] = -a_1 x[n-1] - a_2 x[n-2]$$

• El error de estimación e[n] del filtro óptimo es

$$e[n] = d[n] - y[n] = x[n] - y[n] = v[n],$$

por lo que el error cuadrático medio mínimo es

$$J_{min} = E(|e^2[n]|) = \sigma_v^2$$

#### Predictor lineal adaptivo con descenso por gradiente

 La regla de adaptación en el algoritmo de descenso por gradiente es

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \mu \left(\mathbf{p} - \mathbf{R}\mathbf{w}[n]\right)$$

 La matriz de autocorrelación de la entrada y la correlación cruzada entre la entrada y la señal deseada son,

$$\mathbf{R} = \sigma_u^2 \begin{bmatrix} 1 & \frac{-a_1}{1+a_2} \\ \frac{-a_1}{1+a_2} & 1 \end{bmatrix} \qquad \mathbf{p} = \sigma_u^2 \begin{bmatrix} \frac{-a_1}{1+a_2} \\ \frac{a_1^2}{1+a_2} - a_2 \end{bmatrix}$$

• Hay que decidir el valor del paso de adaptación  $\mu$  que cumpla las condiciones de convergencia,

$$0 < \mu < \frac{2}{1}$$
.

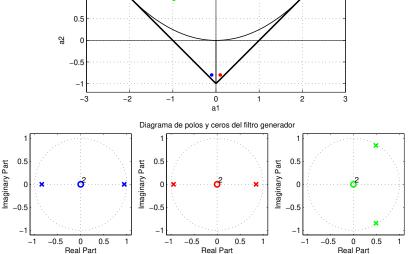
 En este ejemplo, el cálculo de los valores propios puede hacerse analíticamente,

$$\lambda_{1,2} = \frac{\pm a_1 + a_2 + 1}{(1 - a_2) \left[ (1 + a_2)^2 - a_1^2 \right]}.$$

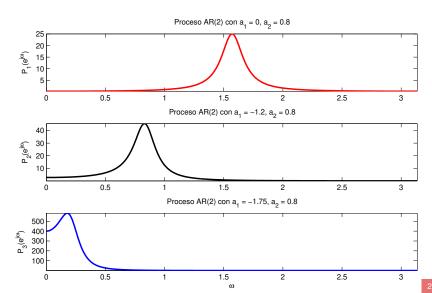
 Se consideran tres casos con distintos parámetros del proceso AR(2) a predecir,

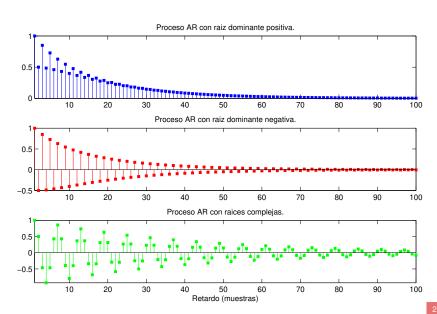
$a_1$	$a_2$	$\lambda_{max}$	$\lambda_{min}$	$\chi(\mathbf{R})$	$\mu_{max} = 2/\lambda_{max}$
0	0.8	2.7778	2.7778	1	0.72
-1.2	0.8	8.3333	1.6667	5	0.24
-1.75	0.8	100	1.4085	71	0.02

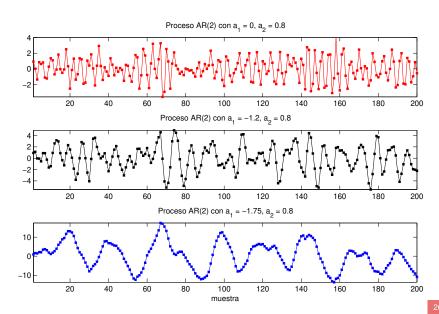
- Se corre el algoritmo de descenso por gradiente para los tres casos usando los mismos parámetros.
  - $\mathbf{w}[0] = \mathbf{0}$
  - $\mu = 0.05 \mu_{3 max} = 0.001$
  - 1500 iteraciones [los puntos están graficados cada 20

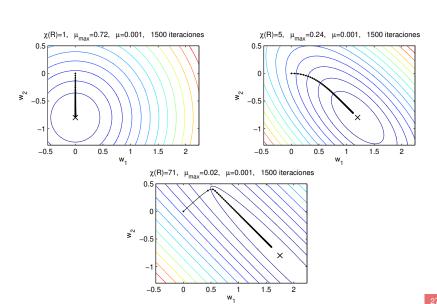


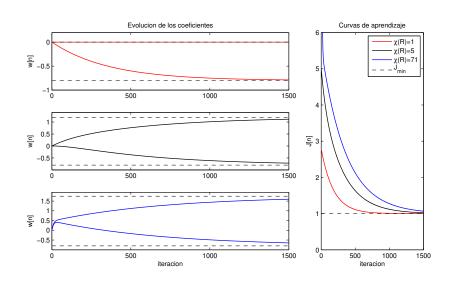
Lugar del plano a1-a2 para condicion de estacionaridad asintotica











Se considera ahora solo el segundo proceso AR(2),

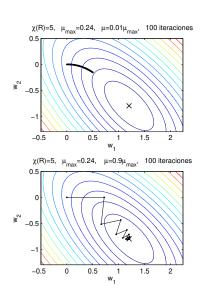
$a_1$	$a_2$	$\lambda_{max}$	$\lambda_{min}$	$\chi(\mathbf{R})$	$\mu_{max} = 2/\lambda_{max}$
-1.2	0.8	8.3333	1.6667	5	0.24

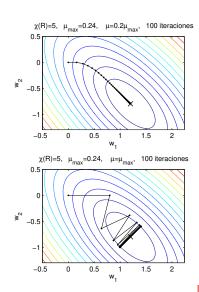
 Se corre el algoritmo de descenso por gradiente para distintos pasos de adaptación,

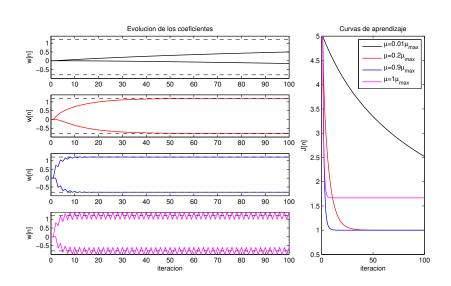
$\mu_1$	$\mu_2$	$\mu_3$	$\mu_4$
$0.01\mu_{max}$	$0.2\mu_{max}$	$0.9\mu_{max}$	$\mu_{max}$

con los parámetros,

- $\mathbf{w}[0] = \mathbf{0}$
- 100 iteraciones

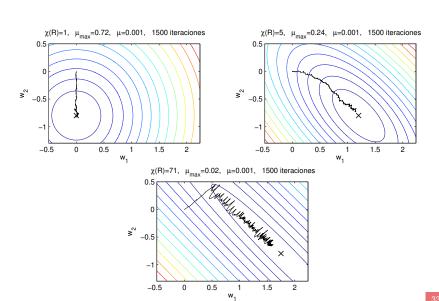


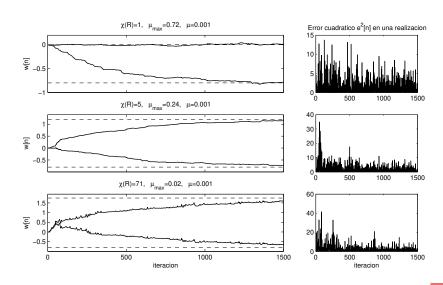


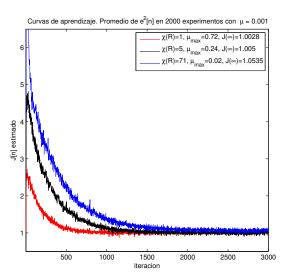


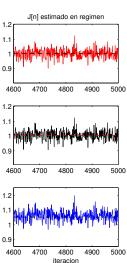
### Predictor lineal adaptivo con el algoritmo LMS

- Se emplea ahora como predictor un filtro adaptivo entrenado con el algoritmo LMS.
- Para entrenar el filtro no es necesario conocer R ni p.
- El procedimiento para realizar las simulaciones es el siguiente:
  - Se generan muestras del proceso AR(2) x[n] a predecir.
  - La señal deseada es d[n] = x[n].
  - La entrada al filtro adaptivo es u[n] = x[n-1]
- 1. Estudio de la convergencia con el número de condición de  ${f R}$ 
  - Se consideran los tres mismos casos de antes, donde se varía el numero de condición de la matriz de autocorrelación del proceso de entrada.
  - Se corre el algoritmo LMS usando los mismos parámetros,









Se considera ahora solo el segundo proceso AR(2),

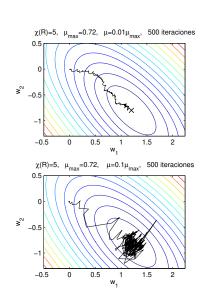
$a_1$	$a_2$	$\lambda_{max}$	$\lambda_{min}$	$\chi(\mathbf{R})$	$\mu_{max} = 2/\lambda_{max}$
-1.2	0.8	8.3333	1.6667	5	0.24

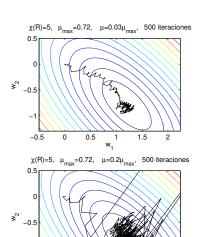
 Se corre el algoritmo de descenso por gradiente para distintos pasos de adaptación,

$\mu_1$	$\mu_2$	$\mu_3$	$\mu_4$
$0.01\mu_{max}$	$0.3\mu_{max}$	$0.1\mu_{max}$	$0.2\mu_{max}$

con los parámetros,

- $\mathbf{w}[0] = \mathbf{0}$
- 500 iteraciones



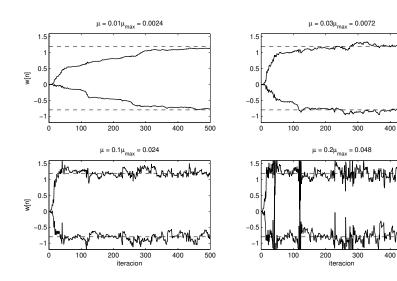


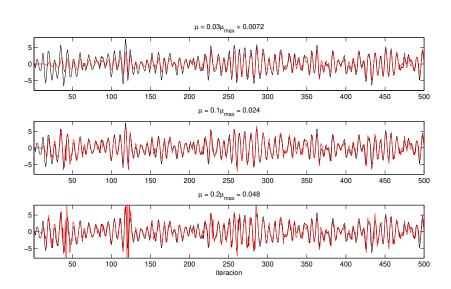
1.5

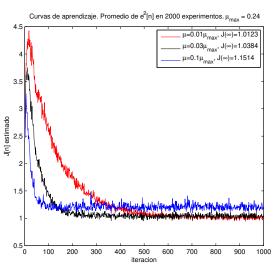
-1

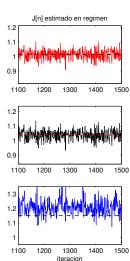
-0.5

0 0.5









- Considerando el caso de procesos con  ${\bf R}$  de distinto número de condición, para que la comparación de  $J_{min}$  tenga sentido, la potencia  $\sigma_u^2$  de los procesos debe ser igual.
- La potencia del proceso AR(2) es,

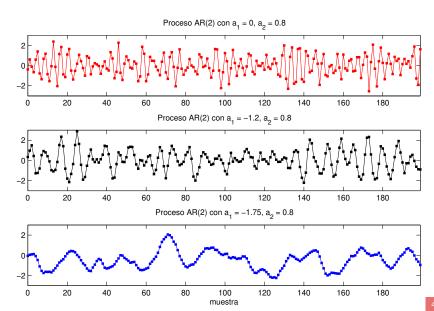
$$r_u[0] = \frac{1+a_2}{(1-a_2)\left[(1+a_2)^2 - a_1^2\right]}\sigma_v^2 = \sigma_u^2.$$

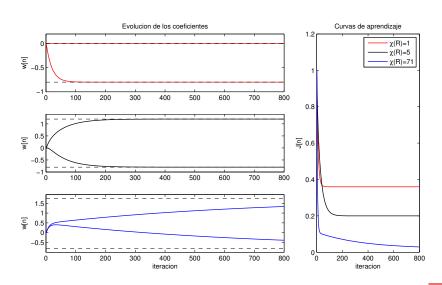
• Fijando  $\sigma_u^2$ , hay que elegir  $\sigma_v^2$  como

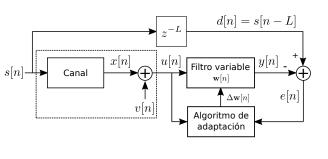
$$\sigma_v^2 = \frac{(1 - a_2) \left[ (1 + a_2)^2 - a_1^2 \right]}{1 + a_2} \sigma_u^2.$$

• En el ejemplo considerado, si  $\sigma_u^2 = 1$ , se tiene entonces

$a_1$	$a_2$	$\chi(\mathbf{R})$	$\mu_{max} = 2/\lambda_{max}$	$\sigma_v^2$
0	8.0	1	0.72	0.36
-1.2	0.8	5	0.24	0.2
-1.75	0.8	71	0.02	0.0197







- s[n] ruido blanco de media nula y potencia  $\sigma_s^2$ .
- v[n] ruido blanco introducido por el canal de media nula y potencia  $\sigma_v^2$  independiente de s[n].

### Ejemplo

 El canal se modela como el siguiente filtro FIR de tres coeficientes

$$h[n] = \left\{ \begin{array}{l} \frac{1}{2} \left[ 1 + \cos \left( \frac{2\pi}{W} (n-2) \right) \right], & \text{si } n = 1, \, 2, \, 3 \\ 0, & \text{en otro caso} \end{array} \right.$$

W controla la cantidad de distorsión del canal.

#### Filtro de Wiener

- Matriz de autocorrelación de la entrada
  - La entrada al filtro es u[n]=x[n]+v[n], con x[n] y v[n] procesos independientes. Por lo tanto,

$$r_u[k] = r_x[k] + r_v[k].$$

- v[n] es ruido blanco de potencia  $\sigma_v^2$ , así que  $r_v[k] = \sigma_v^2 \delta[k]$ .
- Teniendo en cuenta que x[n] es un proceso filtrado, se cumple que,

$$r_x[k] = r_s[k] * h[k] * h[-k],$$

• s[n] es un proceso blanco de potencia  $\sigma_s^2$ , así que  $r_s[k] = \sigma_s^2 \delta[k]$ . Además  $\sigma_s^2 = E(s^2[n]) = 1$ . Entonces,

$$r_u[k] = h[k] * h[-k] + \sigma_v^2 \delta[k].$$

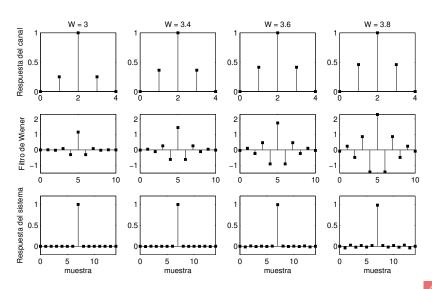
 Como h[n] tiene solo tres coeficientes no nulos, se tiene que,

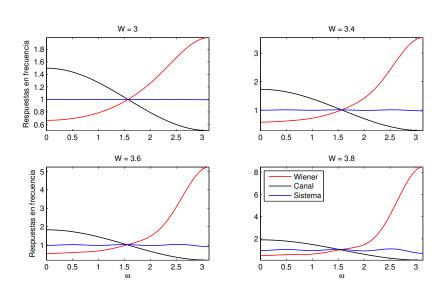
$$r_u[k] = \left\{ \begin{array}{ll} h^2[1] + h^2[2] + h^2[3] + \sigma_v^2, & k = 0 \\ h[1]h[2] + h[2]h[3], & k = 1 \\ h[1]h[3], & k = 2 \\ 0, & k \ge 3 \end{array} \right.$$

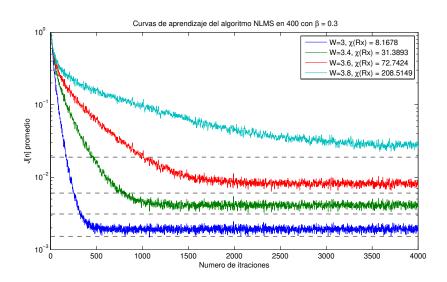
$$\begin{split} p[-k] &= E \left\{ u[n-k]d[n] \right\} \\ &= E \left\{ (x[n-k] + v[n-k])s[n-L] \right\} \\ &= E \left\{ x[n-k]s[n-L] \right\} \\ &= E \left\{ x[n]s[n+k-L] \right\} \\ &= E \left\{ \left( \sum_{l=-\infty}^{\infty} h[l]s[n-l] \right) s[n+k-L] \right\} \\ &= \sum_{l=-\infty}^{\infty} h[l]E \left\{ s[n-l]s[n+k-L] \right\} \\ &= \sum_{l=-\infty}^{\infty} h[l]r_s[-l-k+L] \\ &= \sum_{l=-\infty}^{\infty} h[l]\delta[-l-k+L] \end{split}$$

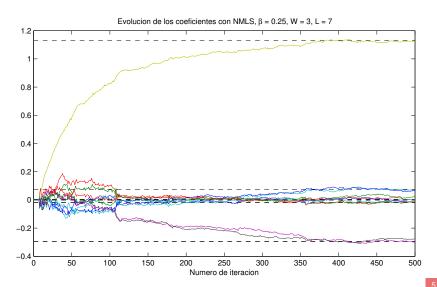
Por ejemplo, si L=7.

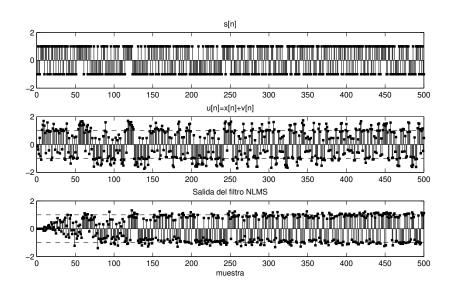
or ejempio, si 
$$=7$$
, 
$$\begin{bmatrix} h[7] \\ h[6] \\ h[5] \end{bmatrix}$$











### Observación

- La respuesta del canal en este ejemplo es un filtro FIR simétrico.
- Puede demostrarse que el filtro FIR óptimo para contrarrestar la distorsión del canal debe es simétrico.
- El sistema global (cascada del canal y el filtro adaptivo) tiene un retardo de grupo igual a la suma de los retardos de grupo de ambos filtros
- En este ejemplo se tiene que,

```
	au_{g, {
m canal}} = 2 \; {
m muestras} 	au_{g, {
m wiener}} = 5 \; {
m muestras} 	au_{g, {
m global}} = 7 \; {
m muestras}
```

