# Estimación y Predicción en Series Temporales

Estimadores MVU, caso lineal

### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

## Agenda

- Repaso Cota inferior de Cramér-Rao (CRLB)
- Estimadores MVU en modelos lineales
- Stimadores MVU caso General

### Cota Inferior de Cramér-Rao

#### Teorema: Cota Inferior de Cramér-Rao, parámetro escalar.

Se asume que la PDF  $p(\mathbf{x}; \theta)$  satisface la condición de regularidad,

$$\mathbb{E}_{\mathbf{x}}\left[\frac{\partial \log p(\mathbf{x};\theta)}{\partial \theta}\right] = 0 \quad \text{ para todo } \theta.$$

#### Entonces,

 $oldsymbol{0}$  la varianza de todo estimador insesgado  $\hat{\theta}$  cumple que

$$\operatorname{var}(\hat{\theta}) \ge \frac{1}{-\mathbb{E}_{\mathbf{x}} \left[ \frac{\partial^2 \log p(\mathbf{x}; \theta)}{\partial \theta^2} \right]},$$

donde la derivada se evalúa en el valor verdadero de  $\theta$ .

 $oldsymbol{2}$  existe un estimador que alcanza la cota para todo heta si y solo si

$$\frac{\partial \log p(\mathbf{x}; \theta)}{\partial \theta} = I(\theta) (g(\mathbf{x}) - \theta),$$

para alguna función I y g.

Este estimador, que es el MVU, es  $\hat{\theta}=g(\mathbf{x})$  y su varianza es  $\frac{1}{I(\theta)}.$ 

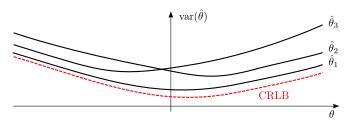
### Cota Inferior de Cramér-Rao: Consideraciones

• La esperanza se toma respecto a los datos  $\mathbf{x} \sim p(\mathbf{x}; \theta)$ ,

$$\mathbb{E}_{\mathbf{x}} \left[ \frac{\partial^2 \log p(\mathbf{x}; \theta)}{\partial \theta^2} \right] = \int \frac{\partial^2 \log p(\mathbf{x}; \theta)}{\partial \theta^2} p(\mathbf{x}; \theta) d\mathbf{x}.$$

La esperanza reconoce el hecho de que la función de verosimilitud y sus derivadas son variables aleatorias por depender de los datos observados  ${\bf x}$ .

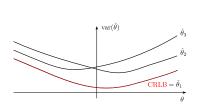
• La cota depende en general del parámetro desconocido  $\theta$ .



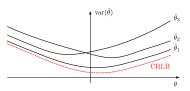
### Estimador eficiente

**Definición (Estimador eficiente).** Un estimador que es insesgado y alcanza la cota de Cramér-Rao para todos los valores del parámetro desconocido se dice que es eficiente.

### Observación. Un estimador MVU puede ser o no ser eficiente



- $\hat{\theta}_1$  alcanza la CRLB y por lo tanto es el MVU.
- $\theta_1$  es eficiente y MVU.



- Ningún estimador alcanza CRI B.
- Varianza de  $\hat{\theta}_1$  es menor que la de los otros estimad. insesgados.
- $\theta_1$  es MVU pero no es

# CRLB general para señales con AWGN

• Sea una señal determinística con un parámetro desconocido  $\theta$  observada en AWGN (ruido aditivo blanco Gaussiano),

$$x[n] = s[n; \theta] + w[n], \text{ con } n = 0, 1, ..., N-1 \text{ y } w[n] \sim \mathcal{N}(0, \sigma^2).$$

La función de verosimilitud es

$$p(\mathbf{x}; \theta) = \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - s[n; \theta])^2\right].$$

$$\mathbb{E}_{\mathbf{x}}\left(\frac{\partial^{2} \log p(\mathbf{x};\theta)}{\partial \theta^{2}}\right) = \frac{1}{\sigma^{2}} \sum_{n=0}^{N-1} \left[ \left(\mathbb{E}(x[n]) - s[n;\theta]\right) \frac{\partial^{2} s[n;\theta]}{\partial \theta^{2}} - \left(\frac{\partial s[n;\theta]}{\partial \theta}\right)^{2} \right]$$
$$= -\frac{1}{\sigma^{2}} \sum_{n=0}^{N-1} \left(\frac{\partial s[n;\theta]}{\partial \theta}\right)^{2}.$$

La CRLB es por lo tanto:

$$\operatorname{var}(\hat{\theta}) \ge \frac{\sigma^2}{\sum_{n=0}^{N-1} \left(\frac{\partial s[n;\theta]}{\partial \theta}\right)^2}$$

• Mejor estimación si la señal  $s[n;\theta]$  cambia rápidamente con parámetro  $\theta.$ 

## Transformación de parámetros: caso asintótico

La eficiencia es *aproximadamente* mantenida bajo transformaciones no afínes si la cantidad de observaciones es suficientemente grande.

• Un estimador  $\hat{\theta}$  del parámetro  $\theta$  es asintóticamente insesgado si

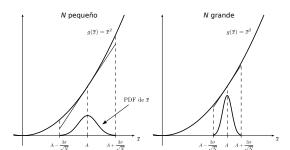
$$\lim_{N\to\infty} \mathbb{E}(\hat{\theta}) = \theta.$$

• Un estimador  $\hat{\theta}$  del parámetro  $\theta$  es asintóticamente eficiente si

$$\lim_{N \to \infty} \operatorname{var}(\hat{\theta}) = CRLB(\theta).$$

# Transformación de parámetros: Resumen

- Una transformación afín de un estimador eficiente mantiene la eficiencia.
- Es decir el estimador transformado es un estimador eficiente del parámetro transformado.
- Una transformación no afín de un estimador eficiente destruye la eficiencia, e incluso puede hacerlo sesgado.
- Sin embargo, estimador transformado es asint. insesgado y asint. eficiente.
- Es decir, cuando la cantidad de observaciones  $N \to \infty$  , el estimador limite es insesgado y eficiente.



# CRLB: Extensión a vector de parámetros

- Supongamos que queremos estimar vector de parámetros  $\boldsymbol{\theta} = [\theta_1, \theta_2, ..., \theta_p]^T$ .
- Si asumimos que tenemos un estimador  $\hat{\theta}$  que es insesgado, la CRLB para un vector de parámetros establece una cota en la varianza de cada elemento.

$$\operatorname{var}(\hat{\theta}_i) \geq [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii},$$

donde  $I(\theta)$  es la matriz de información de Fisher de tamaño  $p \times p$ .

La matriz de información de Fisher se define como

$$[\mathbf{I}(\boldsymbol{\theta})]_{ij} = -\mathbb{E}\left[\frac{\partial^2 \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \theta_i \partial \theta_j}\right], \quad \text{con } (i, j) \in \left\{1, 2, \dots, p\right\}^2,$$

en donde al evaluar la ecuación se debe emplear el valor verdadero de heta.

• En el caso escalar p=1, se tiene  $\mathbf{I}(\boldsymbol{\theta})=I(\boldsymbol{\theta})$  tal como se definió previamente (CRLB escalar).

# Cota Inferior de Cramér-Rao (vectorial)

### Teorema: Cota Inferior de Cramér-Rao, parámetro vectorial.

Se asume que la PDF  $p(\mathbf{x}; \boldsymbol{\theta})$  satisface la condición de regularidad,

$$\mathbb{E}_{\mathbf{x}}\left[\frac{\partial \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}}\right] = 0 \quad \text{ para todo } \boldsymbol{\theta}.$$

#### Entonces,

 $oldsymbol{0}$  la matriz de covarianza de todo estimador insesgado  $\hat{ heta}$  cumple que

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} - \mathbf{I}^{-1}(\boldsymbol{\theta}) \geq \mathbf{0}, \quad \text{donde } [\mathbf{I}(\boldsymbol{\theta})]_{ij} = -\mathbb{E}_{\mathbf{x}} \left[ \frac{\partial^2 \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \theta_i \partial \theta_j} \right],$$

- $I(\theta)$  es la matriz de información de Fisher,
- ">" se interpreta en el sentido de matriz semidefinida positiva,
- derivada se evalúa en el valor verdadero de  $\theta$ .
- $\bigcirc$  existe un estimador que alcanza la cota para todo  $\theta$  si y solo si

$$\frac{\partial \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta}) (\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta}),$$

para alguna función  $\mathbf{g}:\mathbb{R}^N \to \mathbb{R}^p$  y matriz I de tamaño  $p \times p$ . Ese

# Cota Inferior de Cramér-Rao (vectorial)

#### Consecuencias.

 Como en una matriz semidefinida positiva todos los elementos de la diagonal son no negativos, la cota matricial implica,

$$[\mathbf{C}_{\hat{\boldsymbol{\theta}}} - \mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii} \ge 0.$$

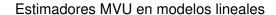
 Por lo tanto, la varianza de cada elemento del vector estimado cumple que,

$$\operatorname{var}(\hat{\theta}_i) = [\mathbf{C}_{\hat{\boldsymbol{\theta}}}]_{ii} \ge [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii}$$

 Si se cumple la condición de factorización, entonces la cota se alcanza y por lo tanto

$$\operatorname{var}(\hat{\theta}_i) = [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{ii}$$

En este caso, el estimado  $\hat{\theta} = \mathbf{g}(\mathbf{x})$  es eficiente y por lo tanto MVU.



### Estimadores MVU

En muchas situaciones no es posible encontrar el estimador
 MVU con la técnica de Cramér-Rao

$$\frac{\partial \log p(\mathbf{x}; \theta)}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta).$$

 Puede suceder que exista el MVU, pero ninguna técnica (regla) sirva para encontrarlo.

#### Modelos lineales

 En el caso en que los datos pueden representarse por un modelo lineal,

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w},$$

el estimador MVU siempre existe y se puede calcular.

# Modelo lineal: Ejemplo

### Ejemplo: Ajuste de recta

 Se considera el problema de ajustar una recta a partir de datos contaminados con AWGN,

$$x[n] = A + Bn + w[n],$$
 con  $n = 0, 1, ..., N - 1,$ 

donde  $w[n] \sim \mathcal{N}(0, \sigma^2)$  para todo n y se quiere estimar la pendiente B y el coeficiente de intersección A.

El modelo, se puede expresar en notación matricial

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w}$$

donde,

$$\mathbf{x} = [x[0], x[1], \dots, x[N-1]]^T$$

$$\mathbf{w} = [w[0], w[1], \dots, w[N-1]]^T$$

$$\boldsymbol{\theta} = [A, B]^T$$

$$\mathbf{h} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & N-1 \end{bmatrix}$$

 El problema de estimación de la recta es efectivamente un problema lineal

### Modelos lineal en ruido AWGN

- $\mathbf{x} \in \mathbb{R}^N$ : datos observados.
- $\theta \in \mathbb{R}^p$ : p parámetros desconocidos.

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w}$$

- $\mathbf{h} \in \mathbb{R}^{N \times p}$ : matriz de observación, con N > p y rango p.
- $\mathbf{w} \in \mathbb{R}^N$ : ruido en observación. Se asume  $\mathbf{w} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ .

Nota: El espacio  $\mathbb{R}$  puede ser remplazado por  $\mathbb{C}$ .

### Propiedades:

- En el caso de modelos lineales, siempre es posible encontrar el estimador MVU que además es eficiente.
- Según teorema de CRLB, debemos probar que:

$$\frac{\partial \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{I}(\boldsymbol{\theta})(\mathbf{g}(\mathbf{x}) - \boldsymbol{\theta}),$$

para alguna función  $\mathbf{g}: \mathbb{R}^N \to \mathbb{R}^p$  y alguna matriz  $\mathbf{I} \in \mathbb{R}^{p \times p}$ 

La función de verosimilitud es:

$$p(\mathbf{x}; \boldsymbol{\theta}) = \prod_{n=0}^{N-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2} (x[n] - (\mathbf{h}\boldsymbol{\theta})[n])^2\right]$$
$$= \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - (\mathbf{h}\boldsymbol{\theta})[n])^2\right]$$
$$= \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})\right]$$

Tomando el logaritmo se obtiene,

$$\log p(\mathbf{x}; \boldsymbol{\theta}) = -\log(2\pi\sigma^2)^{\frac{N}{2}} - \frac{1}{2\sigma^2}(\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T(\mathbf{x} - \mathbf{h}\boldsymbol{\theta})$$

Derivando respecto al parámetro desconocido,

$$\begin{split} \frac{\partial \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} &= \frac{\partial}{\partial \boldsymbol{\theta}} \left[ -\log(2\pi\sigma^2)^{\frac{N}{2}} - \frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{h}\boldsymbol{\theta}) \right] \\ &= -\frac{1}{2\sigma^2} \frac{\partial}{\partial \boldsymbol{\theta}} \left[ \mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{h}\boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{h}^T \mathbf{h}\boldsymbol{\theta} \right] \\ &\stackrel{(a)}{=} -\frac{1}{2\sigma^2} \left[ -2\mathbf{h}^T \mathbf{x} + 2\mathbf{h}^T \mathbf{h}\boldsymbol{\theta} \right] \\ &= \frac{1}{\sigma^2} \left[ \mathbf{h}^T \mathbf{x} - \mathbf{h}^T \mathbf{h}\boldsymbol{\theta} \right] \\ &\stackrel{(b)}{=} \frac{\mathbf{h}^T \mathbf{h}}{\sigma^2} \left[ (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x} - \boldsymbol{\theta} \right]. \end{split}$$

Donde se utilizó,

(a) 
$$\frac{\partial \mathbf{B}^T \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = \mathbf{B}$$
, y  $\frac{\partial \boldsymbol{\theta}^T \mathbf{A} \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = 2\mathbf{A} \boldsymbol{\theta}$  si  $\mathbf{A}$  es simétrica (Ver apéndice)

(b)  $\mathbf{h}^T \mathbf{h}$  invertible.

#### **CRLB en Modelos Lineales:**

El modelo cumple la condición del teorema de CRLB dada por,

$$\frac{\log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \underbrace{\frac{\mathbf{h}^T \mathbf{h}}{\sigma^2}}_{\mathbf{I}(\boldsymbol{\theta})} \left[ \underbrace{(\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}}_{\mathbf{g}(\mathbf{x})} - \boldsymbol{\theta} \right].$$

Por lo que tenemos

Estimador MVU

$$\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{x}) = (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}$$

Matriz de Covarianza

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \mathbf{I}^{-1}(\boldsymbol{\theta}) = \sigma^2 (\mathbf{h}^T \mathbf{h})^{-1}$$

- Además, el estimador  $\hat{\theta}$  es eficiente.
- Observación: Problema equivalente al problema de mínimos cuadrados.

### Estimador MVU en modelos lineales

#### Teorema: Estimador MVU en modelos lineales.

- $\mathbf{x} \in \mathbb{R}^N$ : datos observados.
- $\theta \in \mathbb{R}^p$ : p parámetros desconocidos.

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w}$$

- $\mathbf{h} \in \mathbb{R}^{N \times p}$ : matriz de observación con N > p y rango p
- $\mathbf{w} \in \mathbb{R}^N$ : ruido en observación. Se asume  $\mathbf{w} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ .

Nota: El espacio  $\mathbb{R}$  puede ser remplazado por  $\mathbb{C}$ . Entonces,

Estimador MVU

Matriz de Covarianza

$$\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{x}) = (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}$$

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \mathbf{I}^{-1}(\boldsymbol{\theta}) = \sigma^2 (\mathbf{h}^T \mathbf{h})^{-1}$$

• Además, el estimador  $\hat{\theta}$  es eficiente ya que alcanza la CRLB para todo  $\theta$ .

### Estimador MVU en modelos lineales

#### Teorema: Estimador MVU en modelos lineales.

El estimador es insesgado:

$$\mathbb{E}\left[\hat{\boldsymbol{\theta}}\right] = \mathbb{E}\left[\left(\mathbf{h}^T \mathbf{h}\right)^{-1} \mathbf{h}^T \mathbf{x}\right]$$

$$= \mathbb{E}\left[\left(\mathbf{h}^T \mathbf{h}\right)^{-1} \mathbf{h}^T (\mathbf{h} \boldsymbol{\theta} + \mathbf{w})\right]$$

$$= \mathbb{E}\left[\boldsymbol{\theta} + (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{w}\right]$$

$$= \boldsymbol{\theta} + (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbb{E}[\mathbf{w}]$$

$$= \boldsymbol{\theta}$$

• Además, como  $\hat{\theta}$  es una transformación lineal del vector Gaussiano  $\mathbf{x}$ , su PDF es Gaussiana y está completamente especificada,

$$\hat{\boldsymbol{\theta}} \sim \mathcal{N}(\boldsymbol{\theta}, \sigma^2(\mathbf{h}^T \mathbf{h})^{-1}).$$

- Muchas señales tienen un comportamiento periódico
- Presencia de componentes sinusoidales puede ser detectada mediante análisis de Fourier
- Grandes coeficientes indican presencia de fuertes componentes sinusoidales
- Supongamos como modelo la superposición de sinusoides en AWGN,

$$x[n] = \sum_{k=1}^{M} a_k \cos\left(\frac{2\pi kn}{N}\right) + b_k \sin\left(\frac{2\pi kn}{N}\right) + w[n], \quad n = 0, 1, \dots, N-1,$$

donde  $w[n] \sim \mathcal{N}(0, \sigma^2 I)$ . Las amplitudes  $a_k$  y  $b_k$  son desconocidas. El modelo asume que las frecuencias se encuentran en relación armónica con frecuencia fundamental  $f_1 = 1/N$  (frecuencia normalizada)

• ¿Es un modelo lineal en los parámetros?

Superposición de sinusoides en AWGN:

$$x[n] = \sum_{k=1}^{M} a_k \cos\left(\frac{2\pi kn}{N}\right) + b_k \sin\left(\frac{2\pi kn}{N}\right) + w[n], \quad n = 0, 1, \dots N - 1,$$

donde las amplitudes  $a_k$  y  $b_k$  son desconocidas.

• El modelo es lineal,  $x = h\theta + w$ , con

$$\boldsymbol{\theta} = \begin{bmatrix} a_1, a_2, \dots, a_M, b_1, b_2, \dots, b_M \end{bmatrix}^T$$

$$\mathbf{h} = \begin{bmatrix} 1 & \dots & 1 & 0 & \dots & 0 \\ \cos\left(\frac{2\pi}{N}\right) & \dots & \cos\left(\frac{2\pi M}{N}\right) & \sin\left(\frac{2\pi}{N}\right) & \dots & \sin\left(\frac{2\pi M}{N}\right) \\ \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ \cos\left(\frac{2\pi(N-1)}{N}\right) & \dots & \cos\left(\frac{2\pi M(N-1)}{N}\right) & \sin\left(\frac{2\pi(N-1)}{N}\right) & \dots & \sin\left(\frac{2\pi M(N-1)}{N}\right) \end{bmatrix}$$

θ es de dimensión 2M × 1 y h es de dimensión N × 2M.

#### Determinación del MVU

- El estimador MVU es  $\hat{\theta} = (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}$ .
- Si se representa h en columnas,

$$\mathbf{h} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_{2M}],$$

entonces se tiene que

$$\mathbf{h}^T \mathbf{h} = \begin{bmatrix} \mathbf{h}_1^T \\ \mathbf{h}_2^T \\ \vdots \\ \mathbf{h}_{2M}^T \end{bmatrix} [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_{2M}] = \begin{bmatrix} \mathbf{h}_1^T \mathbf{h}_1 & \mathbf{h}_1^T \mathbf{h}_2 & \dots & \mathbf{h}_1^T \mathbf{h}_{2M} \\ \mathbf{h}_2^T \mathbf{h}_1 & \mathbf{h}_2^T \mathbf{h}_2 & \dots & \mathbf{h}_2^T \mathbf{h}_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{h}_{2M}^T \mathbf{h}_1 & \mathbf{h}_{2M}^T \mathbf{h}_2 & \dots & \mathbf{h}_{2M}^T \mathbf{h}_{2M} \end{bmatrix}.$$

• Los cálculos se simplifican notando que las columnas de  ${\bf h}$  son ortogonales. Es decir si  ${\bf h}_i$  es la columna i-ésima de  ${\bf h}$ , se cumple que

$$\mathbf{h}_i^T \mathbf{h}_j = 0$$
 para  $i \neq j$ 

• Esto implica que  $\mathbf{h}^T \mathbf{h}$  es diagonal, haciéndola fácil de invertir.

La ortogonalidad de las columnas viene de la DFT (ejercicio),

$$\sum_{n=0}^{N-1} \cos\left(\frac{2\pi in}{N}\right) \cos\left(\frac{2\pi jn}{N}\right) = \frac{N}{2} \delta_{ij}$$

$$\sum_{n=0}^{N-1} \sin\left(\frac{2\pi in}{N}\right) \sin\left(\frac{2\pi jn}{N}\right) = \frac{N}{2} \delta_{ij}$$

$$\sum_{n=0}^{N-1} \cos\left(\frac{2\pi in}{N}\right) \sin\left(\frac{2\pi jn}{N}\right) = 0 \quad \forall i, j$$

Con lo cual

$$\mathbf{h}^T \mathbf{h} = \begin{bmatrix} \frac{\frac{N}{2}}{2} & 0 & \dots & 0 \\ 0 & \frac{N}{2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{N}{2} \end{bmatrix} = \frac{N}{2} \mathbf{I}$$

El estimador MVU queda entonces

$$\hat{\boldsymbol{\theta}} = (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x} = \frac{2}{N} \mathbf{I} \mathbf{h}^T \mathbf{x} = \frac{2}{N} \begin{bmatrix} \mathbf{h}_1^T \\ \mathbf{h}_2^T \\ \vdots \\ \mathbf{h}_{2M}^T \end{bmatrix} \mathbf{x} = \frac{2}{N} \begin{bmatrix} \mathbf{h}_1^T \mathbf{x} \\ \mathbf{h}_2^T \mathbf{x} \\ \vdots \\ \mathbf{h}_{2M}^T \mathbf{x} \end{bmatrix}$$

De donde se obtiene,

$$\hat{a}_k = \frac{2}{N} \sum_{n=0}^{N-1} x[n] \cos\left(\frac{2\pi kn}{N}\right) \qquad \hat{b}_k = \frac{2}{N} \sum_{n=0}^{N-1} x[n] \sin\left(\frac{2\pi kn}{N}\right),$$

es decir,  $\hat{a}_k$  y  $\hat{b}_k$  son los coeficientes de Fourier de x[n].

La matriz de covarianza es:

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \sigma^2 (\mathbf{h}^T \mathbf{h})^{-1} = \frac{2\sigma^2}{N} \mathbf{I}.$$

Dado que la matriz de covarianza es diagonal, los estimadores son independientes.

## Modelo lineal con ruido gaussiano coloreado

- $\mathbf{x} \in \mathbb{R}^N$ : datos observados.
- $oldsymbol{ heta} \in \mathbb{R}^p$ : p parámetros desconocidos.

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w}$$

- $\mathbf{h} \in \mathbb{R}^{N \times p}$ : matriz de observación.
- $\mathbf{w} \in \mathbb{R}^N$ : ruido en observación es coloreado, muestras no son independientes. Se asume  $\mathbf{w} \sim \mathcal{N}(0, \mathbf{C})$ , con  $\mathbf{C}$  simétrica definida positiva.
- Para encontrar el estimador MVU, se puede proceder de forma análoga al caso con ruido blanco.
- En el caso con ruido coloreado, la PDF del ruido es una normal multivariada

$$p(\mathbf{w}) = \frac{1}{(2\pi |\mathbf{C}|)^{N/2}} \exp\left[-\frac{1}{2}\mathbf{w}^T \mathbf{C}^{-1}\mathbf{w}\right],$$

por lo que la PDF paramétrica de los datos es

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi)^N |\mathbf{C}|}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta}) \right].$$

# Modelo lineal con ruido gaussiano coloreado

C es una matriz de covarianza,

$$\mathbf{C} = \mathbb{E}\left((\mathbf{w} - \mathbb{E}(\mathbf{w}))(\mathbf{w} - \mathbb{E}(\mathbf{w}))^T\right) = \mathbb{E}(\mathbf{w}\mathbf{w}^T),$$

por lo que es simétrica y definida positiva (ver apéndice).

• Además  ${f C}^{-1}$  también es simétrica y definida positiva (Ejercicio). Por lo cual

$$\mathbf{C}^{-1} = \mathbf{D}^T \mathbf{D}^T$$

con **D** de dimensión  $N \times N$  invertible.

La matriz D actúa como un blanqueador (whitening),

$$\mathbb{E}[(\mathbf{D}\mathbf{w})(\mathbf{D}\mathbf{w})^T] = \mathbf{D}\mathbb{E}[\mathbf{w}\mathbf{w}^T]\mathbf{D}$$

$$= \mathbf{D}\mathbf{C}\mathbf{D}^T$$

$$= \mathbf{D}\mathbf{D}^{-1}(\mathbf{D}^T)^{-1}\mathbf{D}^T$$

$$= \mathbf{I}.$$

Como consecuencia se tiene que,

$$\mathbf{w}' = \mathbf{D}\mathbf{w} \sim \mathcal{N}(0, \mathbf{I}).$$

## Modelo lineal con ruido gaussiano coloreado

 Transformando el modelo original con operación de blanqueado, se obtiene

$$\mathbf{x}' = \mathbf{D}\mathbf{x}$$

$$= \mathbf{D}\mathbf{h}\boldsymbol{\theta} + \mathbf{D}\mathbf{w}$$

$$= \mathbf{h}'\boldsymbol{\theta} + \mathbf{w}',$$

donde se definió  $\mathbf{h}' = \mathbf{Dh}$ . Notar que  $\mathbf{w}' \sim \mathcal{N}(0, \mathbf{I})$ .

Como se vio anteriormente, el MVU en este caso (AWGN) es

$$\begin{split} \hat{\boldsymbol{\theta}} &= (\mathbf{h'}^T \mathbf{h'})^{-1} \mathbf{h'}^T \mathbf{x'} \\ &= (\mathbf{h}^T \mathbf{D}^T \mathbf{D} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{D}^T \mathbf{D} \mathbf{x} \\ &= (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} \mathbf{x} \end{split}$$

y su matriz de covarianza,

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = (\mathbf{h}'^T \mathbf{h}')^{-1} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1}.$$

• Si  $C = \sigma^2 I$ , se obtiene el resultado para el caso AWGN.

Nota: podríamos haber calculado la derivada de la función de verosimilitud y procedido igual que antes.

El resultado es el mismo (ejercicio).

# Ejemplo II

### Ejemplo: Nivel de DC en ruido coloreado

Como generalización del ejemplo de base, en este caso se observan N muestras de nivel de continua en ruido coloreado,

$$x[n] = A + w[n], \text{ con } n = 0, 1, \dots, N - 1, y \mathbf{w} \sim \mathcal{N}(0, \mathbf{C}),$$

donde C es la matriz de covarianza del ruido (simétrica, definida positiva).

El modelo es lineal,

$$x = 1 \cdot A + w, \quad h = 1 = [1, 1, ..., 1]^T$$

 Empleando el resultado del modelo lineal con ruido coloreado, el estimador MVU y la varianz es:

$$\hat{A} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} \mathbf{x} = \frac{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}}$$

y su varianza es,

$$\operatorname{var}(\hat{A}) = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} = \frac{1}{\mathbf{1}^1 \mathbf{C}^{-1} \mathbf{1}}$$

• En el caso en que el ruido es blanco y gaussiano, el MVU es la media muestra con varianza  $\sigma^2/N$ .

# Ejemplo II

#### Ejemplo: Nivel de DC en ruido coloreado

• Interpretación. Considerando la factorización  $\mathbf{C}^{-1} = \mathbf{D}^T \mathbf{D}$ , se obtiene

$$\hat{A} = \frac{\mathbf{1}^T \mathbf{D}^T \mathbf{D} \mathbf{x}}{\mathbf{1}^T \mathbf{D}^T \mathbf{D} \mathbf{1}} = \frac{(\mathbf{D} \mathbf{1})^T \mathbf{x}'}{(\mathbf{D} \mathbf{1})^T (\mathbf{D} \mathbf{1})} = \sum_{n=0}^{N-1} d_n x'[n], \quad \text{con } d_n = \frac{[\mathbf{D} \mathbf{1}]_n}{(\mathbf{D} \mathbf{1})^T (\mathbf{D} \mathbf{1})}$$

- El estimador consiste en primero blanquear los datos (x'[n]) y luego hacer un promedio ponderado de los datos blanqueados.
- El blanqueado tiene el efecto de decorrelacionar e igualar las varianzas de las muestras de ruido

Caso particular: muestras no correlacionadas pero de varianza distinta

$$\mathbf{C} = \mathsf{diag}(\sigma_0^2, \sigma_1^2, \dots, \sigma_{N-1}^2)$$

En este caso,

$$\hat{A} = \frac{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}} = \frac{\sum_{n=0}^{N-1} \frac{\mathbf{x}[n]}{\sigma_n^2}}{\sum_{n=0}^{N-1} \frac{1}{\sigma_n^2}}.$$

- Estimador le da más importancia a muestras con ruido de menor varianza
- ¿Qué sucede si alguna muestra tiene ruido con varianza  $\epsilon \approx 0$ ?

### Modelo lineal + señal conocida + ruido coloreado

• 
$$\mathbf{x} \in \mathbb{R}^N$$
: datos observados.

•  $\theta \in \mathbb{R}^p$ : p parámetros desconocidos.

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{s} + \mathbf{w}$$

- $\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{s} + \mathbf{w}$   $\mathbf{h} \in \mathbb{R}^{N \times p}$ : matriz de observación.
  - $\mathbf{s} \in \mathbb{R}^N$ : muestras de señal conocida.
  - $\mathbf{w} \in \mathbb{R}^N$ : Se asume  $\mathbf{w} \sim \mathcal{N}(0, \mathbf{C})$  (ruido coloreado).

Nota: El espacio  $\mathbb{R}$  puede ser remplazado por  $\mathbb{C}$ .

En este caso es fácil ver que el estimador MVU es,

$$\hat{\boldsymbol{\theta}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s})$$

y la matriz de covarianza del estimador es

$$\mathbf{C}_{\theta} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1}.$$

El estimador es **eficiente** ya que alcanza la CRLB para todo  $\theta$ .

# Ejemplo III

### Ejemplo: Nivel de DC y exponencial en ruido coloreado

Supongamos el siguiente modelo de observación

$$x[n] = A + r^n + w[n]$$
 con  $n = 0, 1, ..., N - 1$ , y  $\mathbf{w} \sim \mathcal{N}(0, \mathbf{C})$ ,

donde r es conocido. Se quiere determinar el MVU de A y su varianza.

El modelo es,

$$\mathbf{x} = \mathbf{1} \cdot A + \mathbf{s} + \mathbf{w},$$

y por lo tanto

$$\mathbf{h} = \mathbf{1} = [1, 1, 1, \dots, 1]^T$$
  
 $\mathbf{s} = [1, r, r^2, \dots, r^{N-1}]^T.$ 

 El estimador y su varianza se obtienen con las fórmulas de la slide anterior.

$$\hat{A} = \frac{\mathbf{1}^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{s})}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}}$$

y su varianza es

$$\operatorname{var}(\hat{A}) = \frac{1}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}}.$$

Estimadores MVU caso General

## Agenda

- Cómo podemos hacer para encontrar, si existe, un MVU cuando éste no es eficiente (sino bastaría con el teorema de la CRLB).
- Para eso vamos a definir la noción de estadístico suficiente.
- Veremos como evaluar si un estadístico suficiente insesgado es un MVU (no necesariamente eficiente).
- El enfoque anterior es limitante (se requiere un estimador candidato). Veremos si existen estadísticos suficientes, y cómo encontrarlos usando el teorema de Neyman-Fisher.
- Veremos como usar estadísticos suficientes para encontrar un MVU (si existe). Este es el teorema de Rao-Blackwell-Lehmann-Scheffe.

### Motivación

- Vimos previamente que la evaluación de la CRLB puede resultar en la determinación de un estimador eficiente (y por lo tanto un MVU).
- Un caso especial donde sucede esto son los modelos lineales.
- ¿Qué pasa cuando no existe un estimador eficiente? Aún así puede llegar a existir el estimador MVU, y lo querríamos encontrar.
- Estadístico suficiente: una función de los datos que contiene toda la información disponible sobre éstos para realizar la estimación.

### Estadísticos suficientes

**Ejemplo:** DC en WGN de N muestras de varianza  $\sigma^2$ 

Vimos que  $\hat{A}=\frac{1}{N}\sum_{0}^{N-1}x[n]$  es el estimador MVU,  $\mathrm{var}[\hat{A}]=\sigma^2/N$ .

Consideremos el estimador  $\check{A} = x[0]$ :

- Es insesgado
- $var(\check{A}) = \sigma^2 > \sigma^2/N$ . La performance muy pobre ¿Porqué?

No se utilizan datos que aportan información útil (muestras independientes)

### Preguntas:

- ¿Cuál es el conjunto de datos pertinentes para la estimación, i.e., que logran producir una estimación de mínima varianza?
- ¿Qué conjunto o conjuntos son **suficientes** para calcular  $\hat{A}$ ?

### Estadísticos suficientes

Supongamos los siguientes conjuntos:

$$S_A = \{x[0], x[1], x[2], \dots, x[N-1]\}$$

$$S_B = \{x[0] + x[1], x[2], x[3], \dots, x[N-1]\}$$

$$S_C = \left\{\sum_{n=0}^{N-1} x[n]\right\}$$

- Son los tres conjuntos suficientes para realizar la estimación?
   Si.
- ... pero  $S_C$  es el más compacto posible:  $\#S_C < \min(\#S_A, \#S_B)$ )
- Se dice que  $\sum_{n=0}^{N-1} x[n]$  es el estadístico suficiente minimal.
- Para estimar A, una vez conocido  $\sum_{n=0}^{N-1} x[n]$  no se precisa nada más ya que este estadístico **resume toda la información disponible**.

# Verificación de que un estadístico dado es suficiente

¿Cómo verificar que un estadístico  $T(\mathbf{x})$  es suficiente?

Verificando que una vez conocido su valor  $T(\mathbf{x}) = T_0$ , no queda información adicional para mejorar la estimación de A.

Esto sucede cuando  $p(\mathbf{x}|T(\mathbf{x}) = T_0; A)$  es independiente de A.

### **Ejemplo:** DC en WGN de N muestras de varianza $\sigma^2$

- Consideremos el estadístico  $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$
- Usando la Regla del Producto:

$$p(\mathbf{x}|T(\mathbf{x})=T_0;A) = \frac{p(\mathbf{x},T(\mathbf{x})=T_0;A)}{p(T(\mathbf{x})=T_0;A)} = \frac{p(\mathbf{x};A)\delta(T(\mathbf{x})-T_0)}{p(T(\mathbf{x})=T_0;A)}.$$

### Verificación de que un estadístico dado es suficiente

Se tiene que  $T(\mathbf{x}) \sim \mathcal{N}(NA, N\sigma^2)$ .

$$p(\mathbf{x}; A)\delta(T(\mathbf{x}) - T_0) = (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \delta(T(\mathbf{x}) - T_0)$$

$$= (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT(\mathbf{x}) + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0)$$

$$= (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT_0 + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0).$$

Por lo que.

$$\begin{split} p\Big(\mathbf{x}|T(\mathbf{x}) &= T_0; A\Big) \\ &= \frac{(2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (-2AT_0 + NA^2)\right]}{\frac{1}{\sqrt{2\pi N}\sigma^2} \exp\left[-\frac{1}{2N\sigma^2} (T_0 - NA)^2\right]} \delta(T(\mathbf{x}) - T_0) \\ &= \frac{\sqrt{N}}{(2\pi\sigma^2)^{(N-1)/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2\right] \exp\left[\frac{T_0^2}{2N\sigma^2}\right] \delta(T(\mathbf{x}) - T_0). \end{split}$$

- Como no depende de A, se concluye que  $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$  es un estadístico suficiente.
- Limitante. Primero hay que tener el estadístico, para luego verificar que es suficiente.

# Teorema de factorización de Neyman-Fisher

**Teorema Factorización de Neyman-Fisher.** Si se puede factorizar  $p(\mathbf{x}; \boldsymbol{\theta})$  como

$$p(\mathbf{x}; \boldsymbol{\theta}) = g(T(\mathbf{x}), \boldsymbol{\theta}) h(\mathbf{x}), \tag{1}$$

dónde g solo depende de  $\mathbf x$  a través de  $T(\mathbf x)$  y h es función únicamente de  $\mathbf x$ ; entonces  $T(\mathbf x)$  es un estadístico suficiente (E.S.) de  $\boldsymbol \theta$ .

Además, si  $T(\mathbf{x})$  es un estadístico suficiente de  $\theta$  entonces  $p(\mathbf{x};\theta)$  puede ser factorizada como (1).

Prueba: Ver [Kay 1993], Apéndice 5A

### **Ejemplo:** DC en WGN de N muestras de varianza $\sigma^2$

Veamos si podemos factorizar p(x; A):

$$p(\mathbf{x};A) = \underbrace{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp(-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2)}_{h(\mathbf{x})} \cdot \underbrace{\exp(-\frac{1}{2\sigma^2} (-2A \sum_{n=0}^{N-1} x[n] + NA^2))}_{g(T(\mathbf{x}),A)}.$$

$$\Rightarrow T(\mathbf{x}) = \sum_{n=1}^{N-1} x[n]$$
 es un E.S. de  $A$ .

**OBS:**  $T_2(\mathbf{x}) = 2T(\mathbf{x})$  es también un E.S. de A. Se puede ver que cualquier transformación bivectiva de un E.S. es también un E.S.

# Estadístico suficiente completo

#### Estadístico Completo.

- Un estadístico  $T(\mathbf{x})$  es completo si existe una única función g tal que  $g(T(\mathbf{x}))$  es insesgado.
- Un estadístico suficiente es completo: si es suficiente y es completo.

#### Proposición

Un estadístico suficiente  $T(\mathbf{x})$  es completo si y solo si:

$$\int_{-\infty}^{+\infty} v(T)p(T;\theta)dT = 0 \quad \forall \ \theta,$$

se cumple únicamente para la función v(T) = 0 para todo T.

Ejercicio: pensar la demostración.

## Búsqueda del MVU usando la suficiencia

#### Teorema de Rao-Blackwell-Lehemann-Scheffe.

Sea  $\check{\theta}$  un estimador insesgado de  $\theta$  y  $T(\mathbf{x})$  un estadístico suficiente de  $\theta$ .

#### **Entonces:**

- $\hat{\boldsymbol{\theta}} := \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})]$  es un estimador insesgado de  $\boldsymbol{\theta}$ , y  $\operatorname{var}(\hat{\boldsymbol{\theta}}) \leq \operatorname{var}(\check{\boldsymbol{\theta}}) \ \forall \ \boldsymbol{\theta}$ .
- Si además  $T(\mathbf{x})$  es completo,  $\hat{\boldsymbol{\theta}}$  es el MVU de  $\theta$ .

Prueba: Ver [Kay 1993], Apéndice 5B

#### Observaciones:

- Si  $T(\mathbf{x})$  no es completo, no sabemos si  $\hat{\boldsymbol{\theta}}$  es o no MVU.
- Reducción en varianza de  $\hat{\theta}$  con respecto a  $\check{\theta}$  es consecuencia de extraer toda la info disponible en los datos via el estadístico suficiente.

# Búsqueda del MVU usando la suficiencia

### Observaciones (cont.)

Tenemos que,

$$\hat{\boldsymbol{\theta}} := \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})] = \int \check{\boldsymbol{\theta}}p(\check{\boldsymbol{\theta}}|T(\mathbf{x}))d\check{\boldsymbol{\theta}} = g(T(\mathbf{x})).$$

donde además  $\hat{\theta}$  es un estimador insesgado (RBLS).

• Si T es completo, entonces la g tal que el estimador  $\hat{\theta}=g(T(\mathbf{x}))$  es insesgado, es única, independientemente del  $\check{\theta}$  que elijamos.

$$\Rightarrow \ \forall \ \theta, \ \ \mathrm{var}(\hat{\theta}) \leq \mathrm{var}(\check{\theta}) \ \forall \ \check{\theta} \ \text{insesgado (i.e.} \ \hat{\theta} \ \text{es el MVU)}.$$

• Por la observación anterior, si tenemos un E.S.  $T(\mathbf{x})$  y encontramos una g tal que  $g(T(\mathbf{x}))$  es insesgado, y verificamos que es única, entonces ya sabemos que  $\hat{\boldsymbol{\theta}} = g(T(\mathbf{x}))$  es el MVU.

# Resumen: Procedimiento para encontrar el MVU

- ① Aplicar el teorema de Neyman-Fisher para encontrar  $T(\mathbf{x})$  estadístico suficiente.
- 2 Determinar si  $T(\mathbf{x})$  es completo:
  - Tratando de encontrar g tal que  $g(T(\mathbf{x}))$  es insesgado y verifica ser única. Si es así,  $\hat{\boldsymbol{\theta}} = g(T(\mathbf{x}))$  es el MVU (fin, terminamos).
  - Usando la proposición (nos dice si T es completo pero no da g).
- $\bigcirc$  Si  $T(\mathbf{x})$  es completo, calcular el MVU como

$$\hat{\boldsymbol{\theta}} = \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})],$$

con  $\check{\theta}$  cualquier estimador insesgado.

# Ejemplo con media y varianza a estimar

Ejemplo: Nivel de DC en ruido blanco de varianza desconocida

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N - 1,$$

con  $w[n] \sim \mathcal{N}(0,\sigma^2)$  i.i.d. Tanto A como  $\sigma^2$  son desconocidos y deben ser estimados.

$$p(\mathbf{x}; (A, \sigma^2)) = \underbrace{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2 + \frac{2A}{2\sigma^2} \sum_{n=0}^{N-1} x[n] - \frac{NA^2}{2\sigma^2}\right)}_{f([T_1(\mathbf{x}), T_2(\mathbf{x})], [A, \sigma^2])} \cdot \underbrace{\frac{1}{h(\mathbf{x})}}_{h(\mathbf{x})}$$

donde

$$\mathbf{T}(\mathbf{x}) = \begin{bmatrix} T_1(\mathbf{x}) \\ T_2(\mathbf{x}) \end{bmatrix} = \left[ \sum_{n=0}^{N-1} x[n], \sum_{n=0}^{N-1} x^2[n] \right]^T$$

es un E.S. de acuerdo al teorema de factorización de Neyman-Fisher.

A continuación buscaremos una función  ${\bf g}$  que haga que  ${\bf g}({\bf T}({\bf x}))$  sea insesgado,

$$\mathbb{E}\left[\mathbf{g}(\mathbf{T}(\mathbf{x}))\right] = \begin{bmatrix} A \\ \sigma^2 \end{bmatrix}.$$

# Ejemplo con media y varianza desconocidas

Primero observar que

$$\mathbb{E}\left[\mathbf{T}(\mathbf{x})\right] = \begin{bmatrix} \mathbb{E}[T_1(\mathbf{x})] \\ \mathbb{E}[T_2(\mathbf{x})] \end{bmatrix} = \begin{bmatrix} \sum_{n=0}^{N-1} \mathbb{E}[x[n]] \\ \sum_{n=0}^{N-1} \mathbb{E}[x^2[n]] \end{bmatrix} = \begin{bmatrix} NA \\ N(\sigma^2 + A^2) \end{bmatrix}.$$

Una función g candidata natural es la siguiente

$$\mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{1}{N} T_2(\mathbf{x}) - \left[\frac{1}{N} T_1(\mathbf{x})\right]^2 \end{bmatrix} = \begin{bmatrix} \bar{x} \\ \sum_{n=0}^{N-1} x^2[n] - \bar{x}^2 \end{bmatrix}$$

Por un lado,

$$\mathbb{E}(\bar{x}) = A,$$

y por otro,

$$\mathbb{E}\left(\frac{1}{N}\sum_{n=0}^{N-1}x^{2}[n] - \bar{x}^{2}\right) = \sigma^{2} + A^{2} - \mathbb{E}(\bar{x}^{2}).$$

# Ejemplo con media y varianza desconocidas

Por otro lado sabemos que  $\bar{x}\sim \mathcal{N}(A,\sigma^2/N)$ , con lo cual,  $\mathbb{E}(\bar{x}^2)=A^2+\frac{\sigma^2}{N}$ . Por lo que

$$\mathbb{E}\left(\frac{1}{N}\sum_{n=0}^{N-1}x^2[n]-\bar{x}^2\right)=\sigma^2+A^2-\left(A^2+\frac{\sigma^2}{N}\right)=\frac{N-1}{N}\sigma^2.$$

Si multiplicamos este estadístico por N/(N-1) entonces obtenemos un estimador insesgado de  $\sigma^2$ ,

$$\mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{1}{N-1} \left[ T_2(\mathbf{x}) - N \left( \frac{1}{N} T_1(\mathbf{x}) \right)^2 \right] \end{bmatrix} = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \left[ \sum_{n=0}^{N-1} x^2 [n] - N \bar{x}^2 \right] \end{bmatrix}$$

Observar que esto puede ser escrito como

$$\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix},$$

que, asumiendo que  $T(\mathbf{x})$  es compelto, es por lo tanto el estimador MVU de  $\theta = [A,\sigma^2]^T$ .

**Ejercicio.** Probar que  $\hat{\theta}$  no es eficiente (sugerencia, calcular la CRLB y mostrar que la varianza del estimador MVU es estrictamente superior).

### Referencias

 Kay, S. M. (1993)
 Fundamentals of Statistical Signal Processing, Volume I: Estimation Theory, Capítulos 4 y 5.

# Apéndice I

• Derivada de una función escalar  $f: \mathbb{R} \to \mathbb{R}^n$  respecto a un vector  $\boldsymbol{\theta} \in \mathbb{R}^n$ ,

$$\frac{\partial f}{\partial \boldsymbol{\theta}} = \begin{bmatrix} \frac{\partial f}{\partial \theta_1} \\ \frac{\partial f}{\partial \theta_2} \\ \vdots \\ \frac{\partial f}{\partial \theta_n} \end{bmatrix}$$

• Si  $f(\theta) = \mathbf{w}^T \theta = \sum_{i=1}^n w_i \theta_i$ . Entonces

$$\frac{\partial \mathbf{w}^T \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} = \mathbf{w}.$$

• Si  $g(\theta) = \theta^T \mathbf{A} \theta = \sum_{i,j} a_{ij} \theta_i \theta_j$ . Entonces

$$\frac{\partial \boldsymbol{\theta}^T \mathbf{A} \boldsymbol{\theta}}{\boldsymbol{\theta}} = \begin{bmatrix} \sum_i a_{i1} \theta_i + \sum_j a_{1j} \theta_j \\ \sum_i a_{i2} \theta_i + \sum_j a_{2j} \theta_j \\ \vdots \\ \sum_i a_{in} \theta_i + \sum_j a_{nj} \theta_j \end{bmatrix} = \mathbf{A} \boldsymbol{\theta} + \mathbf{A}^T \boldsymbol{\theta}.$$

## Apéndice II

#### Ortogonalidad de la base DFT

$$\sum_{n=0}^{N-1} \cos \left(\frac{2\pi k n}{N}\right) \cos \left(\frac{2\pi l n}{N}\right) = \frac{1}{2} \sum_{n=0}^{N-1} \cos \left(\frac{2\pi (k+l) n}{N}\right) + \frac{1}{2} \sum_{n=0}^{N-1} \cos \left(\frac{2\pi (k-l) n}{N}\right)$$

Por otro lado,

$$\begin{split} \sum_{n=0}^{N-1} \cos\left(\frac{2\pi Mn}{N}\right) &= \operatorname{Re}\left[\sum_{n=0}^{N-1} \exp\left(\frac{2\pi Mn}{N}\right)\right] \\ &= \operatorname{Re}\left[\frac{1 - \exp(2\pi i M)}{1 - \exp(2\pi i M/N)}\right] \\ &= \left\{\begin{array}{ll} N & \text{si } M = 0 \\ 0 & \text{si } M \in \mathbb{N}, \ M \neq 0 \end{array}\right. \end{split}$$

Con lo cual,

$$\sum_{n=0}^{N-1} \cos \left( \frac{2\pi kn}{N} \right) \cos \left( \frac{2\pi ln}{N} \right) = \frac{N}{2} \delta_{kl}.$$

# Apéndice III

Propiedades de la matriz de covarianza

$$\mathbf{C} = \mathbb{E}\left[ (\mathbf{w} - \mathbb{E}(\mathbf{w}))(\mathbf{w} - \mathbb{E}(\mathbf{w}))^T \right].$$

• Supongamos para simplificar que  $\mathbb{E}\left[\mathbf{w}\right]=0$ . Entonces hay que probar que

$$\mathbb{E}[\mathbf{w}\mathbf{w}^T]$$

es simétrica (trivial) y definida positiva.

• Para ser semi-definida positiva hay que probar que si  $\mathbf{b} \neq 0$ , entonces  $\mathbf{b}^T \mathbf{C} \mathbf{b} > 0$ ,

$$\mathbf{b}^{T}\mathbf{C}\mathbf{b} = \mathbf{b}^{T}\mathbb{E}[\mathbf{w}\mathbf{w}^{T}]\mathbf{b}$$

$$= \mathbb{E}[\mathbf{b}^{T}\mathbf{w}\mathbf{w}^{T}\mathbf{b}]$$

$$= \mathbb{E}[(\mathbf{b}^{T}\mathbf{w})(\mathbf{b}^{T}\mathbf{w})^{T}]$$

$$= \mathbb{E}[|\mathbf{b}^{T}\mathbf{w}|^{2}]$$

$$\geq 0.$$