Estimación y Predicción en Series Temporales

Estimadores MVU, caso general

Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Estimadores MVU caso General

Agenda

- Cómo podemos hacer para encontrar, si existe, un MVU cuando éste no es eficiente (sino bastaría con el teorema de la CRLB).
- Para eso vamos a definir la noción de estadístico suficiente.
- Veremos como evaluar si un estadístico suficiente insesgado es un MVU (no necesariamente eficiente).
- El enfoque anterior es limitante (se requiere un estimador candidato). Veremos si existen estadísticos suficientes, y cómo encontrarlos usando el teorema de Neyman-Fisher.
- Veremos como usar estadísticos suficientes para encontrar un MVU (si existe). Este es el teorema de Rao-Blackwell-Lehmann-Scheffe.

Motivación

- Vimos previamente que la evaluación de la CRLB puede resultar en la determinación de un estimador eficiente (y por lo tanto un MVU).
- Un caso especial donde sucede esto son los modelos lineales.
- ¿Qué pasa cuando no existe un estimador eficiente? Aún así puede llegar a existir el estimador MVU, y lo querríamos encontrar.
- Estadístico suficiente: una función de los datos que contiene toda la información disponible sobre éstos para realizar la estimación.

Estadísticos suficientes

Ejemplo: DC en WGN de N muestras de varianza σ^2

Vimos que $\hat{A}=\frac{1}{N}\sum_{0}^{N-1}x[n]$ es el estimador MVU, $\mathrm{var}[\hat{A}]=\sigma^2/N$.

Consideremos el estimador $\check{A} = x[0]$:

- Es insesgado
- $var(\check{A}) = \sigma^2 > \sigma^2/N$. La performance muy pobre ¿Porqué?

No se utilizan datos que aportan información útil (muestras independientes)

Preguntas:

- ¿Cuál es el conjunto de datos pertinentes para la estimación, i.e., que logran producir una estimación de mínima varianza?
- ¿Qué conjunto o conjuntos son **suficientes** para calcular \hat{A} ?

Estadísticos suficientes

Supongamos los siguientes conjuntos:

$$S_A = \{x[0], x[1], x[2], \dots, x[N-1]\}$$

$$S_B = \{x[0] + x[1], x[2], x[3], \dots, x[N-1]\}$$

$$S_C = \left\{\sum_{n=0}^{N-1} x[n]\right\}$$

- Son los tres conjuntos suficientes para realizar la estimación?
 Si.
- ... pero S_C es el más compacto posible: $\#S_C < \min(\#S_A, \#S_B)$)
- Se dice que $\sum_{n=0}^{N-1} x[n]$ es el estadístico suficiente minimal.
- Para estimar A, una vez conocido $\sum_{n=0}^{N-1} x[n]$ no se precisa nada más ya que este estadístico **resume toda la información disponible**.

Verificación de que un estadístico dado es suficiente

¿Cómo verificar que un estadístico $T(\mathbf{x})$ es suficiente?

Verificando que una vez conocido su valor $T(\mathbf{x}) = T_0$, no queda información adicional para mejorar la estimación de A.

Esto sucede cuando $p(\mathbf{x}|T(\mathbf{x}) = T_0; A)$ es independiente de A.

Ejemplo: DC en WGN de N muestras de varianza σ^2

- Consideremos el estadístico $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$
- Usando la Regla del Producto:

$$p\left(\mathbf{x}|T(\mathbf{x})=T_0;A\right) = \frac{p(\mathbf{x},T(\mathbf{x})=T_0;A)}{p(T(\mathbf{x})=T_0;A)} = \frac{p(\mathbf{x},A)\delta(T(\mathbf{x})-T_0)}{p(T(\mathbf{x})=T_0;A)}.$$

Verificación de que un estadístico dado es suficiente

Se tiene que $T(\mathbf{x}) \sim \mathcal{N}(NA, N\sigma^2)$.

$$p(\mathbf{x}; A)\delta(T(\mathbf{x}) - T_0) = (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \delta(T(\mathbf{x}) - T_0)$$

$$= (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT(\mathbf{x}) + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0)$$

$$= (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT_0 + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0).$$

Por lo que.

$$\begin{split} p\Big(\mathbf{x}|T(\mathbf{x}) &= T_0; A\Big) \\ &= \frac{(2\pi\sigma^2)^{-\frac{N}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (-2AT_0 + NA^2)\right]}{\frac{1}{\sqrt{2\pi N}\sigma^2} \exp\left[-\frac{1}{2N\sigma^2} (T_0 - NA)^2\right]} \delta(T(\mathbf{x}) - T_0) \\ &= \frac{\sqrt{N}}{(2\pi\sigma^2)^{(N-1)/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2\right] \exp\left[\frac{T_0^2}{2N\sigma^2}\right] \delta(T(\mathbf{x}) - T_0). \end{split}$$

- Como no depende de A, se concluye que $T(\mathbf{x}) = \sum_{n=0}^{N-1} x[n]$ es un estimador suficiente.
- Limitante. Primero hay que tener el estadístico, para luego verificar que es suficiente.

Teorema de factorización de Neyman-Fisher

Teorema Factorización de Neyman-Fisher. Si se puede factorizar $p(\mathbf{x}; \boldsymbol{\theta})$ como

$$p(\mathbf{x}; \boldsymbol{\theta}) = g(T(\mathbf{x}), \boldsymbol{\theta}) h(\mathbf{x}), \tag{1}$$

dónde g solo depende de $\mathbf x$ a través de $T(\mathbf x)$ y h es función únicamente de $\mathbf x$; entonces $T(\mathbf x)$ es un estadístico suficiente (E.S.) de θ .

Además, si $T(\mathbf{x})$ es un estadístico suficiente de θ entonces $p(\mathbf{x}; \theta)$ puede ser factorizada como (1).

Prueba: Ver [Kay 1993], Apéndice 5A

Ejemplo: DC en WGN de N muestras de varianza σ^2

Veamos si podemos factorizar p(x; A):

$$p(\mathbf{x};A) = \underbrace{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp(-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2)}_{h(\mathbf{x})} \cdot \underbrace{\exp(-\frac{1}{2\sigma^2} (-2A \sum_{n=0}^{N-1} x[n] + NA^2))}_{g(T(\mathbf{x}),A)}.$$

$$\Rightarrow T(\mathbf{x}) = \sum_{n=1}^{N-1} x[n]$$
 es un E.S. de A .

OBS: $T_2(\mathbf{x}) = 2T(\mathbf{x})$ es también un E.S. de A. Se puede ver que cualquier transformación bivectiva de un E.S. es también un E.S.

Estadístico suficiente completo

Estadístico Completo.

- Un estadístico $T(\mathbf{x})$ es completo si existe una única función g tal que $g(T(\mathbf{x}))$ es insesgado.
- Un estadístico suficiente es completo: si es suficiente y es completo.

Proposición

Un estadístico suficiente $T(\mathbf{x})$ es completo si y solo si:

$$\int_{-\infty}^{+\infty} v(T)p(T;\theta)dT = 0 \quad \forall \ \theta,$$

se cumple únicamente para la función v(T) = 0 para todo T.

Ejercicio: pensar la demostración.

Búsqueda del MVU usando la suficiencia

Teorema de Rao-Blackwell-Lehemann-Scheffe.

Sea $\check{\theta}$ un estimador insesgado de θ y $T(\mathbf{x})$ un estadístico suficiente de θ .

Entonces:

- $\hat{\boldsymbol{\theta}} := \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})]$ es un estimador insesgado de $\boldsymbol{\theta}$, y $\operatorname{var}(\hat{\boldsymbol{\theta}}) \leq \operatorname{var}(\check{\boldsymbol{\theta}}) \ \forall \ \boldsymbol{\theta}$.
- Si además $T(\mathbf{x})$ es completo, $\hat{\boldsymbol{\theta}}$ es el MVU de θ .

Prueba: Ver [Kay 1993], Apéndice 5B

Observaciones:

- Si $T(\mathbf{x})$ no es completo, no sabemos si $\hat{\boldsymbol{\theta}}$ es o no MVU.
- Reducción en varianza de $\hat{\theta}$ con respecto a $\check{\theta}$ es consecuencia de extraer toda la info disponible en los datos via el estadístico suficiente.

Búsqueda del MVU usando la suficiencia

Observaciones (cont.)

Tenemos que,

$$\hat{\boldsymbol{\theta}} := \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})] = \int \check{\boldsymbol{\theta}}p(\check{\boldsymbol{\theta}}|T(\mathbf{x}))d\check{\boldsymbol{\theta}} = g(T(\mathbf{x})).$$

donde además $\hat{\theta}$ es un estimador insesgado (RBLS).

• Si T es completo, entonces la g tal que el estimador $\hat{\theta}=g(T(\mathbf{x}))$ es insesgado, es única, independientemente del $\check{\theta}$ que elijamos.

$$\Rightarrow \ \forall \ \theta, \ \ \mathrm{var}(\hat{\theta}) \leq \mathrm{var}(\check{\theta}) \ \forall \ \check{\theta} \ \text{insesgado (i.e.} \ \hat{\theta} \ \text{es el MVU)}.$$

• Por la observación anterior, si tenemos un E.S. $T(\mathbf{x})$ y encontramos una g tal que $g(T(\mathbf{x}))$ es insesgado, y verificamos que es única, entonces ya sabemos que $\hat{\boldsymbol{\theta}} = g(T(\mathbf{x}))$ es el MVU.

Resumen: Procedimiento para encontrar el MVU

- ① Aplicar el teorema de Neyman-Fisher para encontrar $T(\mathbf{x})$ estadístico suficiente.
- 2 Determinar si $T(\mathbf{x})$ es completo:
 - Tratando de encontrar g tal que $g(T(\mathbf{x}))$ es insesgado y verifica ser única. Si es así, $\hat{\boldsymbol{\theta}} = g(T(\mathbf{x}))$ es el MVU (fin, terminamos).
 - Usando la proposición (nos dice si T es completo pero no da g).
- Calcular el MVU como

$$\hat{\boldsymbol{\theta}} = \mathbb{E}[\check{\boldsymbol{\theta}}|T(\mathbf{x})],$$

con $\check{\theta}$ cualquier estimador insesgado.

Ejemplo con media y varianza a estimar

Ejemplo: Nivel de DC en ruido blanco de varianza desconocida

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N - 1,$$

con $w[n] \sim \mathcal{N}(0,\sigma^2)$ i.i.d. Tanto A como σ^2 son desconocidos y deben ser estimados.

$$p(\mathbf{x}; (A, \sigma^2)) = \underbrace{\frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x[n]^2 + \frac{2A}{2\sigma^2} \sum_{n=0}^{N-1} x[n] - \frac{NA^2}{2\sigma^2}\right)}_{f([T_1(\mathbf{x}), T_2(\mathbf{x})], [A, \sigma^2])} \cdot \underbrace{1}_{h(\mathbf{x})}$$

donde

$$\mathbf{T}(\mathbf{x}) = \begin{bmatrix} T_1(\mathbf{x}) \\ T_2(\mathbf{x}) \end{bmatrix} = \left[\sum_{n=0}^{N-1} x[n], \sum_{n=0}^{N-1} x^2[n] \right]^T$$

es un E.S. de acuerdo al teorema de factorización de Neyman-Fisher.

A continuación buscaremos una función ${\bf g}$ que haga que ${\bf g}({\bf T}({\bf x}))$ sea insesgado,

$$\mathbb{E}\left[\mathbf{g}(\mathbf{T}(\mathbf{x}))\right] = \begin{bmatrix} A \\ \sigma^2 \end{bmatrix}.$$

Ejemplo con media y varianza desconocidas

Primero observar que

$$\mathbb{E}\left[\mathbf{T}(\mathbf{x})\right] = \begin{bmatrix} \mathbb{E}[T_1(\mathbf{x})] \\ \mathbb{E}[T_2(\mathbf{x})] \end{bmatrix} = \begin{bmatrix} \sum_{n=0}^{N-1} \mathbb{E}[x[n]] \\ \sum_{n=0}^{N-1} \mathbb{E}[x^2[n]] \end{bmatrix} = \begin{bmatrix} NA \\ N(\sigma^2 + A^2) \end{bmatrix}.$$

Una función g candidata natural es la siguiente

$$\mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{1}{N} T_2(\mathbf{x}) - \left[\frac{1}{N} T_1(\mathbf{x})\right]^2 \end{bmatrix} = \begin{bmatrix} \bar{x} \\ \frac{1}{N} \sum_{n=0}^{N-1} x^2[n] - \bar{x}^2 \end{bmatrix}$$

Por un lado,

$$\mathbb{E}(\bar{x}) = A,$$

y por otro,

$$\mathbb{E}\left(\frac{1}{N}\sum_{n=0}^{N-1}x^{2}[n] - \bar{x}^{2}\right) = \sigma^{2} + A^{2} - \mathbb{E}(\bar{x}^{2}).$$

Ejemplo con media y varianza desconocidas

Por otro lado sabemos que $\bar{x}\sim \mathcal{N}(A,\sigma^2/N)$, con lo cual, $\mathbb{E}(\bar{x}^2)=A^2+\frac{\sigma^2}{N}$. Por lo que

$$\mathbb{E}\left(\frac{1}{N}\sum_{n=0}^{N-1}x^2[n]-\bar{x}^2\right)=\sigma^2+A^2-\left(A^2+\frac{\sigma^2}{N}\right)=\frac{N-1}{N}\sigma^2.$$

Si multiplicamos este estadístico por N/(N-1) entonces obtenemos un estimador insesgado de σ^2 ,

$$\mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \frac{1}{N} T_1(\mathbf{x}) \\ \frac{1}{N-1} \left[T_2(\mathbf{x}) - N \left(\frac{1}{N} T_1(\mathbf{x}) \right)^2 \right] \end{bmatrix} = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \left[\sum_{n=0}^{N-1} x^2 [n] - N \bar{x}^2 \right] \end{bmatrix}$$

Observar que esto puede ser escrito como

$$\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{T}(\mathbf{x})) = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix},$$

que es por lo tanto el estimador MVU de $\theta = [A, \sigma^2]^T$.

Ejercicio. Probar que $\hat{\theta}$ no es eficiente (sugerencia, calcular la CRLB y mostrar que la varianza del estimador MVU es estrictamente superior).

Referencias

• Kay, S. M. (1993)

Fundamentals of Statistical Signal Processing, Volume I:

Estimation Theory, Capítulo 5.