Estimación y Predicción en Series Temporales

Estimadores insesgados lineales óptimos (BLUE)

Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Agenda

- Repaso estimadores MVU en modelos lineales
- ② Estimadores Lineales e Insesgados Óptimos (BLUE)

Modelo lineal + ruido blanco gaussiano

Modelo lineal en ruido AWGN

- $\mathbf{x} \in \mathbb{R}^N$: datos observados.
- $\theta \in \mathbb{R}^p$: p parámetros desconocidos.

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

- $\mathbf{h} \in \mathbb{R}^{N \times p}$: matriz de observación, con N > p y rango p.
- $\mathbf{w} \in \mathbb{R}^N$: ruido en observación. Se asume $\mathbf{w} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$.

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp \left[-\frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{h}\boldsymbol{\theta}) \right]$$

• Tomando el logaritmo y derivando con respecto a θ se obtiene,

$$\frac{\partial \log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{\partial}{\partial \boldsymbol{\theta}} \left[-\log(2\pi\sigma^2)^{\frac{N}{2}} - \frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{h}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{h}\boldsymbol{\theta}) \right]
= -\frac{1}{2\sigma^2} \frac{\partial}{\partial \boldsymbol{\theta}} \left[\mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{h}\boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{h}^T \mathbf{h}\boldsymbol{\theta} \right]
= -\frac{1}{2\sigma^2} \left[-2\mathbf{h}^T \mathbf{x} + 2\mathbf{h}^T \mathbf{h}\boldsymbol{\theta} \right]
\begin{bmatrix} \mathbf{h}^T \mathbf{h} & \mathbf{h}^T \mathbf{h} \mathbf{h} \end{bmatrix}$$

Modelo lineal + ruido blanco gaussiano

CRLB en Modelos Lineales:

El modelo cumple la condición del teorema de CRLB dada por,

$$\frac{\log p(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \underbrace{\frac{\mathbf{h}^T \mathbf{h}}{\sigma^2}}_{\mathbf{I}(\boldsymbol{\theta})} \left[\underbrace{(\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}}_{\mathbf{g}(\mathbf{x})} - \boldsymbol{\theta} \right].$$

Por lo que tenemos

Estimador MVU

$$\hat{\boldsymbol{\theta}} = \mathbf{g}(\mathbf{x}) = (\mathbf{h}^T \mathbf{h})^{-1} \mathbf{h}^T \mathbf{x}$$

Matriz de Covarianza

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = \mathbf{I}^{-1}(\boldsymbol{\theta}) = \sigma^2(\mathbf{h}^T\mathbf{h})^{-1}$$

- Además, el estimador $\hat{\theta}$ es eficiente.
- Observación: Problema equivalente al problema de mínimos cuadrados.

Modelo lineal + ruido coloreado gaussiano

- $\mathbf{x} \in \mathbb{R}^N$: datos observados.
- $oldsymbol{ heta} \in \mathbb{R}^p$: p parámetros desconocidos.

$$\mathbf{x} = \mathbf{h} \boldsymbol{\theta} + \mathbf{w}$$
 • $\mathbf{h} \in \mathbb{R}^{N \times p}$: matriz de observación, con $N > p$ y rango p .

- $\mathbf{w} \in \mathbb{R}^N$: Se asume $\mathbf{w} \sim \mathcal{N}(0, \mathbf{C})$ (ruido coloreado).
- En este caso vimos que aplicando el blanqueo a los datos:

$$\mathbf{x}' = \mathbf{D}\mathbf{x} = \mathbf{D}\mathbf{h}\boldsymbol{\theta} + \mathbf{D}\mathbf{w}$$

con **D** matriz $N \times N$ invertible t.q. $\mathbf{C}^{-1} = \mathbf{D}^T \mathbf{D}$.

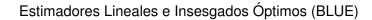
- Se plantea un nuevo problema lineal $\mathbf{x}' = \mathbf{h}' \boldsymbol{\theta} + \mathbf{w}'$ con $\mathbf{h}' = \mathbf{Dh}$ y $\mathbf{w}' = \mathbf{Dw} \sim \mathcal{N}(0, \mathbf{I})$
- El estimador MVU (y eficiente) es en este caso,

$$\hat{\boldsymbol{\theta}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} (\mathbf{x})$$

y la matriz de covarianza del estimador es

$$\mathbf{C}_{\theta} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1}.$$

Qué pasa cuando no conocemos la PDF de w? (esta clase)



Estimadores Lineales e Insesgados Óptimos (BLUE)

- En la práctica ocurre frecuentemente que aunque el estimador MVU existe, no puede ser encontrado.
 - No se conoce la PDF o no se puede asumir un modelo de los datos
 - No puede aplicarse CRLB o teoría de estadísticos suficientes
- En estos casos es razonable recurrir a estimadores subóptimos
 - No se conoce la pérdida de desempeño del estimador porque no se conoce la varianza del MVU.
 - Estimador puede usarse si cumple requisitos de varianza del problema.
- Una estrategia es restringir el estimador a ser lineal con los datos, y buscar el estimador lineal insesgado y de varianza mínima (BLUE)
- Virtud del estimador BLUE: solo se necesita conocer el primer y segundo momento de la PDF, por lo que es apropiado en aplicaciones prácticas.

Mejor Estimador Lineal Insesgado

Best Linear Unbiased Estimator (BLUE)

Se observa el conjunto de datos $\{x[0], x[1], \ldots, x[N-1]\}$ cuya PDF $p(\mathbf{x}; \theta)$ depende del parámetro desconocido θ que se quiere estimar.

 Se dice que un estimador es lineal si se se restringe a ser lineal con los datos,

$$\hat{\theta} = \sum_{n=0}^{N-1} a_n x[n].$$

- Estimador BLUE: estimador lineal, insesgado y tiene varianza mínima entre todos los estimadores lineales.
- Hay que determinar los coeficientes a_n para que el estimador cumpla estas condiciones.

Para determinar el BLUE se impone que el estimador $\hat{\theta}$ sea lineal e insesgado y se determinan los coeficientes a_n que minimizan la varianza.

Estimador lineal

$$\hat{\theta} = \sum_{n=0}^{N-1} a_n x[n] = \mathbf{a}^T \mathbf{x}$$

Condición de estimador insesgado

$$\mathbb{E}(\hat{\theta}) = \sum_{n=0}^{N-1} a_n \mathbb{E}(x[n]) = \theta, \quad \forall \theta.$$

• Para satisfacer la condición de insesgado, $\mathbb{E}(x[n])$ tiene que ser lineal con el parámetro desconocido θ ,

$$\mathbb{E}(x[n]) = s[n]\theta,$$

con s[n] conocido.

Nota. Si esto no se cumple, es imposible satisfacer la condición de insesgado.

Ejemplo. si $\mathbb{E}(x[n]) = \cos \theta$, la condición de insesgado sería $\sum_{n=0}^{N-1} a_n \cos \theta = \theta$. No existen coeficientes a_n que cumplan esto para todo θ .

 Condición necesaria para ser insesgado, implica que el BLUE solo es aplicable en estimación de amplitud de señalas conocidas en ruido,

$$x[n] = \theta s[n] + w[n].$$

- Se puede generalizar mediante transformaciones no lineales de los datos (e.g. $y[n] = x[n]^2$ para estimar σ^2 en WGN).
- Continuando con la condición de no sesgado,

$$\sum_{n=0}^{N-1} a_n \mathbb{E}(x[n]) = \theta$$

$$\sum_{n=0}^{N-1} a_n s[n] \theta = \theta$$

$$\sum_{n=0}^{N-1} a_n s[n] = 1$$

es decir,

$$\mathbf{a}^T\mathbf{s}=1,$$

con $\mathbf{s} = [s[0], s[1], \dots, s[N-1]]^T$. (Notar que hay infinitos \mathbf{a}^T posibles.)

Por otro lado, la varianza del estimador es:

$$var(\hat{\theta}) = \mathbb{E}\left[\left(\hat{\theta} - \mathbb{E}(\hat{\theta})\right)^{2}\right]$$

$$= \mathbb{E}\left[\left(\mathbf{a}^{T}\mathbf{x} - \mathbb{E}(\mathbf{a}^{T}\mathbf{x})\right)^{2}\right]$$

$$= \mathbb{E}\left[\left(\mathbf{a}^{T}(\mathbf{x} - \mathbb{E}(\mathbf{x}))^{2}\right]$$

$$= \mathbb{E}\left[\mathbf{a}^{T}(\mathbf{x} - \mathbb{E}(\mathbf{x}))(\mathbf{x} - \mathbb{E}(\mathbf{x}))^{T}\mathbf{a}\right]$$

$$= \mathbf{a}^{T}\mathbb{E}\left[(\mathbf{x} - \mathbb{E}(\mathbf{x}))(\mathbf{x} - \mathbb{E}(\mathbf{x}))^{T}\right]\mathbf{a}$$

$$= \mathbf{a}^{T}\mathbf{C}\mathbf{a}$$

 Hay que encontrar a de forma de minimizar la varianza manteniendo la restricción impuesta de estimador insesgado,

$$\mathbf{a}_* = \underset{\mathbf{a}}{\operatorname{arg \, min}} \ \mathbf{a}^T \mathbf{C} \mathbf{a} \quad \text{sujeto a} \quad \mathbf{a}^T \mathbf{s} = 1$$

Se puede resolver utilizando multiplicadores de Lagrange.

• El Lagrangiano es:

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^T \mathbf{C} \mathbf{a} + \lambda (\mathbf{a}^T \mathbf{s} - 1)$$

El gradiente respecto a a es:

$$\frac{\partial \mathcal{L}(\mathbf{a}, \lambda)}{\partial \mathbf{a}} = 2\mathbf{C}\mathbf{a} + \lambda \mathbf{s}$$

• Imponiendo $\frac{\partial \mathcal{L}(\mathbf{a},\lambda)}{\partial \mathbf{a}} = \mathbf{0}$, se tiene que

$$\mathbf{a} = -\frac{\lambda}{2} \mathbf{C}^{-1} \mathbf{s}. \tag{1}$$

 Sustituyendo el valor de a en la restricción, se encuentra el multiplicador de Lagrange,

$$\mathbf{a}^T \mathbf{s} = -\frac{\lambda}{2} \mathbf{s}^T \mathbf{C}^{-1} \mathbf{s} = 1,$$

con lo cual

$$-\frac{\lambda}{2} = \frac{1}{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s}}$$

 Sustituyendo el valor del multiplicador en (1), se obtiene el valor de a óptimo,

$$\mathbf{a}_* = \frac{\mathbf{C}^{-1}\mathbf{s}}{\mathbf{s}^T \mathbf{C}^{-1}\mathbf{s}}.$$

El estimador BLUE es entonces

$$\hat{\theta} = \mathbf{a}_*^T \mathbf{x} = \frac{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s}}$$

Su varianza es,

$$var(\hat{\theta}) = \mathbf{a}_*^T \mathbf{C} \mathbf{a}_* = \frac{1}{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s}}$$

• Notar que el estimador es insesgado (usando que $\mathbb{E}(x[n]) = s[n]\theta), \forall \theta$),

$$\begin{split} \mathbb{E}(\hat{\theta}) &= \frac{\mathbf{s}^T \mathbf{C}^{-1} \mathbb{E}(\mathbf{x})}{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s}} \\ &= \frac{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s} \theta}{\mathbf{s}^T \mathbf{C}^{-1} \mathbf{s}} \\ &= \theta. \end{split}$$

- Observación: Para determinar el BLUE solo se requiere conocer:
 - s (media escalada) y C (matrix de covarianza de x) Es decir, los dos primeros momentos de p(x) en lugar de la PDF completa.

Ejemplo I

Ejemplo: Nivel de DC en ruido blanco

Se quiere estimar A a partir de las observaciones

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N - 1,$$

donde w[n] es ruido blanco con varianza σ^2 y PDF no está especificada.

- En este caso, $\mathbb{E}(x[n])=A$, con lo cual s[n]=1, para todo n. Es decir $\mathbf{s}=\mathbf{1}.$
- La matriz de covarianza de x[n] es $C = \sigma^2 I$. Con lo cual $C^{-1} = \frac{1}{\sigma^2} I$.
- Usando la fórmula para el estimador BLUE vista anteriormente se obtiene,

$$\hat{A} = \frac{\mathbf{1}^T \frac{1}{\sigma^2} \mathbf{I} \mathbf{x}}{\mathbf{1}^T \frac{1}{\sigma^2} \mathbf{I} \mathbf{1}} = \frac{1}{N} \sum_{n=0}^{N-1} x[n] = \bar{x}.$$

La varianza del estimador BLUE es.

$$\operatorname{var}(\hat{A}) = \frac{1}{\mathbf{1}^T \frac{1}{-2} \mathbf{I} \mathbf{1}} = \frac{\sigma^2}{N}.$$

Media muestral es el BLUE independientemente de PDE del ruido

Ejemplo II

Ejemplo: Nivel de DC en ruido blanco de varianza no constante

Se quiere estimar A a partir de las observaciones

$$x[n] = A + w[n], \quad n = 0, 1, \dots, N - 1,$$

donde w[n] es ruido blanco con $var(w[n]) = \sigma_n^2$ y PDF no está especificada.

- Como en el caso anterior, s = 1.
- La matriz de covarianza es ahora

$$\mathbf{C} = \begin{bmatrix} \sigma_0^2 & 0 & \cdots & 0 \\ 0 & \sigma_1^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{N-1}^2 \end{bmatrix}$$

$$\mathbf{C} = \begin{bmatrix} \sigma_0^2 & 0 & \cdots & 0 \\ 0 & \sigma_1^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{N-1}^2 \end{bmatrix} \quad \text{con lo cual, } \mathbf{C}^{-1} = \begin{bmatrix} \frac{1}{\sigma_0^2} & 0 & \cdots & 0 \\ 0 & \frac{1}{\sigma_1^2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\sigma_{N-1}^2} \end{bmatrix}.$$

Ejemplo II

Ejemplo: Nivel de DC en ruido blanco de varianza no constante

El estimador BLUE es,

$$\hat{A} = \frac{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}} = \frac{\sum_{n=0}^{N-1} \frac{x[n]}{\sigma_n^2}}{\sum_{n=0}^{N-1} \frac{1}{\sigma_n^2}}.$$

Y su varianza es,

$$\operatorname{var}(\hat{A}) = \frac{1}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}} = \frac{1}{\sum_{n=0}^{N-1} \frac{1}{\sigma_n^2}}$$

- El estimador BLUE da más peso a las muestras con menor varianza (para igualar contribución de ruido en cada muestra).
- El estimador encontrado es idéntico al estimador MVU encontrado en el caso de ruido Gaussiano no correlacionado.

• Se quiere encontrar el BLUE para el caso de un vector ${\pmb{\theta}}$ de p parámetros

$$\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_p]^T.$$

• Para que el estimador sea lineal con los datos, se requiere

$$\hat{\theta}_i = \sum_{n=0}^{N-1} a_{in} x[n] = \mathbf{a}_i^T \mathbf{x}, \quad i = 1, 2, \dots, p,$$

donde a_{in} son los coeficientes a estimar.

En notación matricial,

$$\hat{\boldsymbol{\theta}} = \mathbf{a}\mathbf{x}, \quad \mathbf{a} \quad \text{matrix } p \times N \ \text{con filas } \mathbf{a}_i^T.$$

• La condición para que el estimador $\hat{\theta}$ sea insesgado es,

$$\mathbb{E}(\hat{\theta}_i) = \sum_{n=0}^{N-1} a_{in} \mathbb{E}(x[n]) = \theta_i, \quad \forall \theta_i, \quad i = 1, 2, \dots, p$$

que en notación matricial es

$$\mathbb{E}(\hat{\boldsymbol{\theta}}) = \mathbf{a}\mathbb{E}(\mathbf{x}) = \boldsymbol{\theta}, \quad \forall \boldsymbol{\theta}.$$

• Análogamente al caso escalar, para satisfacer la condición de estimador insesgado, $\mathbb{E}(\mathbf{x})$ tiene que ser lineal con $\boldsymbol{\theta}$,

$$\mathbb{E}(\mathbf{x}) = \mathbf{h}\boldsymbol{\theta}$$
, con h matriz $N \times p$

• Sustituyendo en la condición de insesgado del estimador lineal $\mathbb{E}(\hat{\theta}) = a\mathbb{E}(\mathbf{x}) = ah\theta = \theta \quad (\forall \theta),$

$$ah = I$$
.

• Denotando la fila i-ésima de ${\bf a}$ como ${\bf a}_i^T$ y la columna j-ésima de ${\bf h}$ como ${\bf h}_j$, tenemos

$$\mathbf{a} = egin{bmatrix} \mathbf{a}_1^T \ \mathbf{a}_2^T \ dots \ \mathbf{a}_p^T \end{bmatrix} \quad \mathbf{h} = \left[\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_p
ight],$$

podemos re-escribir la condición para estimador insesgado como,

$$\mathbf{a}_{i}^{T}\mathbf{h}_{j} = \delta_{ij}, \quad i = 1, 2, \dots, p; \ j = 1, 2, \dots, p.$$

Realizando un razonamiento similar al caso escalar, la varianza es

$$\operatorname{var}(\hat{\theta}_i) = \mathbb{E}\left[\left(\hat{\theta}_i - \mathbb{E}(\hat{\theta}_i)\right)^2\right] = \mathbb{E}\left[\left(\mathbf{a}_i^T\mathbf{x} - \mathbb{E}(\mathbf{a}_i^T\mathbf{x})\right)^2\right] = \mathbf{a}_i^T\mathbf{C}\mathbf{a}_i$$

 Hay que encontrar a de forma de minimizar la varianza manteniendo la condición de insesgado. Para encontrar la fila i-ésima de a hay que resolver,

$$\mathbf{a}_{i*} = \mathop{\arg\min}_{\mathbf{a}_i} \mathbf{a}_i^T \mathbf{C} \mathbf{a}_i \quad \text{ sujeto a } \quad \mathbf{a}_i^T \mathbf{h}_j = \delta_{ij} \quad \text{con } \ (i,j) \in [1,2,\dots,p]^2.$$

 En este caso tenemos p restricciones y la función i-ésima de Lagrange queda,

$$J_i = \mathbf{a}_i^T \mathbf{C} \mathbf{a}_i + \sum_{i=1}^p \lambda_j^{(i)} \left(\mathbf{a}_i^T \mathbf{h}_j - \delta_{ij} \right).$$

 Resolviendo (Kay 1993, Apéndice 6B), se obtienen los coeficientes óptimos,

$$\mathbf{a}_{i*} = \mathbf{C}^{-1}\mathbf{h}(\mathbf{h}^T\mathbf{C}^{-1}\mathbf{h})^{-1}\mathbf{e}_i,$$

donde $e_i = [0, 0, 1, 0, \dots, 0]$, donde el 1 está en la posición *i*-ésima,

y además,

$$\mathbf{a}_* = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1}.$$

El estimador BLUE en el caso vectorial queda,

$$\hat{\boldsymbol{\theta}} = \mathbf{a}_* \mathbf{x} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} \mathbf{x}$$

y su matriz de covarianza es

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1}.$$

Observación

 El estimador BLUE es el mismo que el estimador MVU para el modelo lineal general

$$\mathbf{x} = \mathbf{h}\boldsymbol{\theta} + \mathbf{w}, \quad \mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{C}).$$

¿Por qué?

Teorema de Gauss-Markov. Si los datos observador ${\bf x}$ tinene la forma del modelo lineal general

$$x = h\theta + w$$

donde

- \mathbf{x} : $N \times 1$ vector de observaciones
- $\mathbf{h}: N \times p$ matriz de observación conocida, con $N \geq p$ y rango p.
- $\theta: p \times 1$ vector de parámetros a estimar
- $\mathbf{w}: N \times 1$ vector de ruido con PDF arbitraria, media nula y covarianza $\mathbf{C}.$

Entonces, el estimador BLUE de θ es

$$\hat{\boldsymbol{\theta}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} \mathbf{x},$$

y la varianza es

$$\operatorname{var}(\hat{\theta}_i) = \left[(\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \right]_{ii}$$

Además, la matriz de covarianza del estimador es

$$\mathbf{C}_{\hat{\boldsymbol{\theta}}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1}.$$

Consideraciones sobre la optimalidad del BLUE

Modelo lineal con ruido gaussiano

 En el modelo lineal general con ruido gaussiano se encontró que el estimador MVU es

$$\hat{\boldsymbol{\theta}} = (\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h})^{-1} \mathbf{h}^T \mathbf{C}^{-1} \mathbf{x}.$$

Obs. El estimador MVU es lineal en los datos.

 Restringir el estimador a ser lineal no conduce a un estimador subóptimo, ya que el MVU pertenece a la clase de operadores lineales.

Ejemplo: Estimación de nivel de DC en WGN

En ese caso, el MVU es la media muestral

$$\hat{\theta} = \bar{\mathbf{x}} = \frac{1}{N} \sum_{n=0}^{N-1} x[n],$$

que es lineal en los datos.

 Si el modelo es lineal y los datos son Gaussianos, el BLUE es también el MVU.

Consideraciones sobre la optimalidad del BLUE

Modelo lineal con ruido no gaussiano

 Si el modelo es lineal pero los datos no son Gaussianos (ruido no Gaussiano), el estimador MVU no es lineal con los datos.

Ejemplo: Estimación de DC en ruido blanco uniforme. Asumimos,

$$x[n] \sim \mathcal{U}(0,\beta)$$

el parámetro que quiero estimar es $\theta = \frac{\beta}{2}$ (nivel de DC).

 El MVU, encontrado mediante estadísticos suficientes es (Kay 1993, Cap. 5)

$$\hat{\theta}_{\mathsf{MVU}} = \frac{N+1}{2N} \max \ x[n],$$

que no es lineal en los datos.

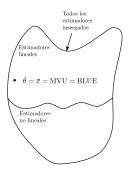
- Restringiendo el estimador a ser lineal, el BLUE es la media muestral.
- La varianza de los estimadores es:

$$\mathrm{var}(\hat{\theta}_{\mathrm{MVU}}) = \frac{\beta^2}{4N(N+2)} \qquad \qquad \mathrm{var}(\hat{\theta}_{\mathrm{BLUE}}) = \frac{\beta^2}{12N}$$

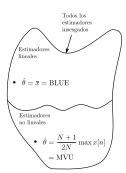
 Si el modelo es lineal y los datos no son Gaussianos, el BLUE es subóptimo.

Consideraciones sobre la optimalidad del BLUE

Nivel de DC en WGN El BLUE es óptimo



Media en ruido uniforme El BLUE es subóptimo



- Si el MVU pertenece a la clase de estimadores lineales, no se pierde desempeño con el BLUE.
- Si el MVU pertenece a la clase de estimadores no lineales, hay pérdida de desempeño (puede ser significativa).

Ejemplo: Estimación de la varianza en WGN

Se tienen las observaciones,

$$x[n] \sim \mathcal{N}(0, \sigma^2)$$
 $n = 0, 1, ..., N - 1,$

y se quiere estimar σ^2 .

 Empleando Cramér-Rao, se puede demostrar que el estimador MVU (que además es estimador eficiente) es:

$$\sigma_{\text{MVU}}^2 = \frac{1}{N} \sum_{n=0}^{N-1} x^2 [n].$$

- Obs. El MVU no es lineal en los datos.
- Se intenta calcular el BLUE en este caso, se tiene que

$$\widehat{\sigma^2} = \sum_{n=0}^{N-1} a_n x[n],$$

con lo cual

$$\mathbb{E}(\widehat{\sigma^2}) = \sum_{n=0}^{N-1} a_n \mathbb{E}(x[n]) = 0$$

 Cualquier estimador lineal es totalmente inapropiado en este caso (estimador lineal siempre es sesgado).

Ejemplo: Estimación de la varianza en WGN

• Sin embargo, el BLUE puede calcularse a partir de los datos transformados como $y[n]=x^2[n]$,

$$\widehat{\sigma^2} = \sum_{n=0}^{N-1} a_n y[n] = \sum_{n=0}^{N-1} a_n x^2[n].$$

La restricción de insesgado puede cumplirse, ya que,

$$\mathbb{E}(\widehat{\sigma^2}) = \sum_{n=0}^{N-1} a_n \mathbb{E}(x^2[n]) = \sum_{n=0}^{N-1} a_n \sigma^2 = \sigma^2.$$

• Teniendo en cuenta que $\mathbb{E}(x^2[n]) = \sigma^2$, el modelo con los datos transformados puede expresarse como

$$y[n] = x^{2}[n] = \underbrace{\mathbb{E}(x^{2}[n])}_{\sigma^{2}} + \underbrace{(x^{2}[n] - \mathbb{E}(x^{2}[n])}_{w[n]}$$
$$= \sigma^{2} + w[n]$$

Ejemplo: Estimación de la varianza en WGN

Ahora el modelo es,

$$y[n] = \sigma^2 + w[n], \quad \text{con } w[n] = x^2[n] - \sigma^2.$$

- La transformación de los datos hace que el problema se reduzca a un problema de estimación de amplitud de una señal en ruido.
- Usando las ecuaciones derivadas para el estimador BLUE con $\mathbf{s}=\mathbf{1},$ se obtiene,

$$\widehat{\sigma^2} = \frac{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{y}}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}} \qquad \text{var}(\widehat{\sigma^2}) = \frac{1}{\mathbf{1}^T \mathbf{C}^{-1} \mathbf{1}}$$

- Debemos calcular la matriz de covarianza del ruido w[n].
- Por construcción del modelo transformado, la media w[n] es nula,

$$\mathbb{E}(w[n]) = \mathbb{E}(x^2[n]) - \sigma^2 = 0.$$

El elemento (i,j) de la matriz de covarianza es

$$\mathbf{C}_{ij} = \mathbb{E}(w[i]w[j]) = \begin{cases} \mathbb{E}(w^2[i]) & i = j \\ \mathbb{E}(w[i])\mathbb{E}(w[j]) = 0 & i \neq j \end{cases}$$

Ejemplo: Estimación de la varianza en WGN

La matriz de covarianza es diagonal, y sus elementos de diagonal valen

$$[\mathbf{C}]_{ii} = \mathbb{E}(w^2[i])$$

$$= \mathbb{E}((x^2[n] - \sigma^2)^2)$$

$$= \mathbb{E}(x^4[n]) - 2\sigma^2 \mathbb{E}(x^2[n]) + \mathbb{E}^2(x^2[n])$$

$$= 3\sigma^4 - 2\sigma^4 + \sigma^4$$

$$= 2\sigma^4.$$

Con lo cual

$$\mathbf{C} = 2\sigma^4 \mathbf{I}$$
 y su inversa, $\mathbf{C}^{-1} = \frac{1}{2\sigma^4} \mathbf{I}$.

El estimador y su varianza son,

$$\widehat{\sigma^2} = \frac{\mathbf{1}^T \frac{1}{2\sigma^4} \mathbf{I} \mathbf{y}}{\mathbf{1}^T \frac{1}{2\sigma^4} \mathbf{I} \mathbf{1}} = \frac{1}{N} \sum_{n=0}^{N-1} y[n] = \frac{1}{N} \sum_{n=0}^{N-1} x^2[n]$$
$$\operatorname{var}(\widehat{\sigma^2}) = \frac{1}{\mathbf{1}^T \frac{1}{2\sigma^4} \mathbf{I} \mathbf{1}} = \frac{2\sigma^4}{N}.$$

Alcanza la CRLB (Kay 1993, Cap. 3).

Referencias

 Kay, S. M. (1993)
 Fundamentals of Statistical Signal Processing, Volume I: Estimation Theory, Capítulo 6.