# Estimación y Predicción en Series Temporales

Procesos Estocásticos

#### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Biblio: Haykin, *Adaptive Filter Theory*, 4ta./5ta. edición. Capítulo 1 y Apéndice E.

## Intro y Agenda

#### Veremos dos aspectos básicos:

- 1 Propiedades de la matriz de correlación y de la densidad espectral de potencia.
- 2 Modelización de un proceso de este tipo como la salida de un filtro lineal discreto excitado por ruido blanco.
  - Un proceso estocástico no es tan solo una única función del tiempo, sino que representa un número infinito de realizaciones diferentes del proceso.
- A una realización particular del proceso le llamamos serie temporal.
- **Def:** Un proceso estocástico es estrictamente estacionario (SSS) si sus propiedades estadísticas son invariantes en el tiempo. Específicamente, para que un proceso estocástico representado por la serie

$$\mathbf{u}(n) = (u(n), u(n-1), \dots, u(n-M+1))$$
 sea SS, la

## Caracterización parcial de un proceso

En la práctica no es posible determinar la función de probabilidad conjunta con muchas variables y debemos recurrir a una caracterización parcial del proceso con el primer y segundo momento.

#### Consideremos un proceso

$$\mathbf{u}(n) = [u(n), u(n-1), \dots, u(n-M+1)].$$

- Función valor medio:  $\mu(n) = \mathbb{E}[u(n)]$
- Función de autocorrelación:  $r(n, n-k) = \mathbb{E}[u(n)u^*(n-k)], k \in \mathbb{Z}$
- Función de autocovarianza:

$$c(n, n-k) = \mathbb{E}[(u(n) - \mu(n))(u(n-k) - \mu(n-k))^*], k \in \mathbb{Z}$$

• Obs:  $c(n, n - k) = r(n, n - k) - \mu(n)\mu^*(n - k)$ .

Le llamamos a este conjunto de funciones *carcterización parcial* del proceso.

#### Ventajas de la caracterización parcial:

 Es posible medir o estimar estas cantidades (e.g. mediante procedimientos de Monte Carlo).

# Caracterización parcial de un proceso

Si el proceso es SSS, las ecuaciones se reducen a,  $\forall$  n:

$$\mu(n) = \mu \text{ constante}$$
 
$$r(n,n-k) = r(k)$$
 
$$c(n,n-k) = c(k)$$

Obs.: en el caso k=0, tenemos  $r(0)=\mathbb{E}[|u(n)|^2]$  y  $c(0)=\sigma_u^2$ .

**Def:** Un proceso se dice *estacionario en sentido amplio (WSS)* si  $\mu(n) = \mu$  constante, y  $r(n, n-k) = r(k) \ \forall \ n$ .

**Thm (Doob):** Un proceso  $\{u(n)\}$  SS es WSS  $\Leftrightarrow$   $\mathbb{E}[|u(n)|^2] < +\infty \ \forall \ n.$  Obs.: Si un proceso Gaussiano es WSS

⇒ también es SS

# Ergodicidad: Teorema ergódico en la media

- Las esperanzas son medias sobre los ensambles o realizaciones.
- También podemos definir medias en el tiempo.
- Si el proceso es ergódico en la media, podemos intercambiar ambos promedios. Para esto, debemos probar que los promedios temporales convergen a los promedios sobre realizaciones, en algún sentido estadístico. Un criterio de convergencia muy utilizado es es el error cuadrático medio.

Sea u(n) WSS, con  $\mu=\mathbb{E}[u(n)]$  y  $c(k)=E[(u(n)-\mu)(u(n-k)-\mu)^*].$  Consideremos el promedio temporal  $\hat{\mu}(N)=\frac{1}{N}\sum_{n=0}^{N-1}u(n).$ 

- $\hat{\mu}(N)$  es un estimador insesgado de  $\mu$  para todo N.
- Decimos que u(n) es ergódico en la media en el sentido del MSE si

$$\lim_{N \to +\infty} \mathbb{E}[|\hat{\mu}(N) - \mu|^2] = 0$$

# Ergodicidad en media

$$\mathbb{E}[|\hat{\mu}(N) - \mu|^2] = \stackrel{operando}{=} \frac{1}{N^2} \sum_{n=0}^{N-1} \sum_{k=0}^{N-1} c(n-k)$$

$$\stackrel{l=n-k}{=} \frac{1}{N} \sum_{n=-N+1}^{N-1} (1-|l|/N)c(l).$$

Tenemos entonces una CNS para la ergodicidad en media:

$$\lim_{N \to +\infty} \frac{1}{N} \sum_{n=-N+1}^{N-1} (1 - |l|/N)c(l) = 0$$

(Teorema de ergodicidad en la media)

# Ergodicidad en correlación

El teorema de ergodicidad en la media puede ser utilizado para otros promedios temporales del proceso. Por ejemplo, aplicándolo a

$$\hat{r}(k,N) = \frac{1}{N} \sum_{n=0}^{N-1} u(n)u^*(n-k), \quad k = 0, 1, \dots, N-1,$$

diremos que u(n) es ergódico en correlación en el sentido del MSE si  $\_$ 

$$\lim_{N \to +\infty} \mathbb{E}[|\hat{r}(k,N) - r(k)|^2] = 0, \quad \forall \ k$$

#### Matriz de correlación

Consideramos el proceso estocástico

$$\mathbf{u}^{T}(n) = [u(n), u(n-1), \dots, u(n-M+1)].$$

Su matriz de (auto)correlación es  $\mathbf{R} = \mathbb{E}[\mathbf{u}(n)\mathbf{u}^H(n)].$ 

#### Matriz de correlación de un proceso WSS

• Si el proceso es WSS desaparece la dependencia en n:

$$\mathbf{R} = \begin{bmatrix} r(0) & r(1) & \dots & r(M-1) \\ r(-1) & r(0) & \dots & r(M-2) \\ \vdots & \ddots & \ddots & \vdots \\ r(-M+1) & \dots & r(-1) & r(0) \end{bmatrix}$$

• Obs:  $r(0) \in \mathbb{R}$ ,  $r(k) \in \mathbb{C} \ \forall \ k \neq 0$ .

# Propiedades de la matriz de correlación de un proceso WSS

#### Prop. 1: R es Hermítica

Esto es  $\mathbf{R} = \mathbf{R}^H$ . Esto surge inmediatamente de la definición de r(k), que verifica  $r(-k) = r^*(k)$ . Entonces:

- Para definir  $\mathbf{R}$ , sólo necesitamos r(k) para  $k = 0, 1, \dots, M-1$ .
- Si el proceso es real, entonces R es real y simétrica.

#### Prop. 2: R es Toeplitz

Esto quiere decir que dentro de cada diagonal, sus elementos son iguales.

- Es consecuencia del carácter WSS del proceso.
- Hay algoritmos específicos para inversión y descomposiciones de matrices que aprovechan la estructura Toeplitz para bajar el costo computacional

# Propiedades de la matriz de correlación de un proceso WSS

#### Prop. 3: R es semi-definida positiva

- Si bien puede ser singular, rara vez ocurre (casos patológicos)
- Dem: Sea  $\mathbf{x}$  un vector complejo, consideremos  $y = \mathbf{x}^H \mathbf{u}(n)$ . Tenemos:  $0 \leq \mathbb{E}[|y^2|] = \mathbb{E}[yy^*] = \mathbb{E}[\mathbf{x}^H \mathbf{u}(n)\mathbf{u}^H(n)\mathbf{x}] = \mathbf{x}^H \mathbf{R} \mathbf{x}$ . Para que valga la igualdad, debe haber una dependencia lineal entre las variables aleatorias que constituyen  $\mathbf{u}(n)$  (cosa que ocurre esencialmente sólo cuando  $\mathbf{u}(n)$  es el muestreo de  $K \leq M$  sinusioides).
- Podemos considerar en la práctica que R es definida positiva.

#### Prop. 4: Relación entre las matrices $R_M$ y $R_{M+1}$

- Queremos encontrar  $\mathbf{q} \neq \mathbf{0}$  tal que  $\mathbf{R}\mathbf{q} = \lambda \mathbf{q}$  para cierto  $\lambda$ .
- De forma equivalente,  $(\mathbf{R} \lambda \mathbf{I})\mathbf{q} = \mathbf{0} \Leftrightarrow \det(\mathbf{R} \lambda \mathbf{I}) = 0$ .
- Veremos propiedades de los valores y vectores propios de R, muchas de ellas son consecuencia de que R es hermítica y semi-definida positiva.

Prop. 1: Los v. p. de  $\mathbf{R}$ ,  $\lambda_1, \lambda_2, \dots, \lambda_M$  son reales positivos.

Dem.:

$$\mathbf{R}\mathbf{q}_i = \lambda_i \mathbf{q}_i \Rightarrow \mathbf{q}_i^H \mathbf{R} \mathbf{q}_i = \lambda_i \mathbf{q}_i^H \mathbf{q}_i \Leftrightarrow \lambda_i = \underbrace{\frac{\mathbf{q}_i^H \mathbf{R} \mathbf{q}_i}{\mathbf{q}_i^H \mathbf{q}_i}}_{\text{coef. de Rayleigh de } \mathbf{q}_i} \geq 0.$$

Prop. 2: Sea k>0 entero. Si  $\lambda$  es v.p de  $\mathbf{R}$ ,  $\lambda^k$  es v.p de  $\mathbf{R}^k$ . Si además  $\lambda>0$ ,  $\lambda^{-k}$  es v.p de  $\mathbf{R}^{-k}$ .

*Dem.*: basta con multiplicar recursivamente por  ${\bf R}$  la igualdad  ${\bf R}{\bf q}=\lambda{\bf q}.$ 

Prop. 3: Los  $q_i$  asociados a los v. p.  $\lambda_i$ ,  $i=1,\ldots,M$  son ortogonales entre sí.

$$\mathbf{R}\mathbf{q}_{i} = \lambda_{i}\mathbf{q}_{i} \Rightarrow \mathbf{q}_{j}^{H}\mathbf{R}\mathbf{q}_{i} = \lambda_{i}\mathbf{q}_{j}^{H}\mathbf{q}_{i},$$

$$\mathbf{R}\mathbf{q}_{j} = \lambda_{j}\mathbf{q}_{j} \Rightarrow \mathbf{q}_{j}^{H}\underbrace{\mathbf{R}^{H}}_{\mathbf{R}} = \lambda_{j}\mathbf{q}_{j}^{H} \Rightarrow \mathbf{q}_{j}^{H}\mathbf{R}\mathbf{q}_{i} = \lambda_{j}\mathbf{q}_{j}^{H}\mathbf{q}_{i}.$$

Restando las ecuaciones en azul,  $0 = (\lambda_i - \lambda_j) \mathbf{q}_j^H \mathbf{q}_i$ , por lo que  $\forall i \neq j, \ \mathbf{q}_i^H \mathbf{q}_i = 0$ .

#### Prop. 4: Teorema Espectral

Sea  $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_M)$ .

Sean  $\mathbf{q}_1, \dots, \mathbf{q}_M$  correspondientes a  $\lambda_1, \dots, \lambda_M$  distintos.

Sea 
$$\mathbf{Q} = [\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M]$$
, con  $\mathbf{q}_i^H \mathbf{q}_j = \left\{ egin{array}{ll} 1 & ext{si } i = j, \\ 0 & ext{si } i 
eq j. \end{array} \right.$ 

#### Entonces:

- $\mathbf{Q}$  es unitaria i.e.  $\mathbf{Q}^H \mathbf{Q} = \mathbf{I}$ , o de forma equivalente  $\mathbf{Q}^{-1} = \mathbf{Q}^H$ .
- $\Lambda = \mathbf{Q}^H \mathbf{R} \mathbf{Q}$ .
- $\mathbf{R} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^H = \sum_{i=1}^M \lambda_i \mathbf{q}_i \mathbf{q}_i^H$  (descomposición espectral).

#### Prop. 5

$$\operatorname{Tr}(\mathbf{R}) = \sum_{i=1}^{M} \lambda_i.$$

#### Prop. 6 (surge del Teorema de los círculos de Gershgorin)

$$\lambda_{max} \le \sum_{k=0}^{M-1} |r(k)|, \quad \lambda_{min} \ge r(0) - \sum_{k=1}^{M-1} |r(k)|.$$

#### Prop. 7: sobre el número de condición

La matriz de correlación  ${\bf R}$  es mal condicionada si el cociente  $\lambda_{max}/\lambda_{min}$  es grande. Definiciones:

- Número de condición:  $\chi(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ .
- De forma general la norma de una matriz  $\mathbf{A}$  inducida por una norma vectorial dada se define como se define como  $\|\mathbf{A}\| = \max \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}$ .
- La norma espectral se define como la norma inducida por la norma 2,

$$\|A\|_S^2 = \max \frac{\|\mathbf{A}\mathbf{x}\|_2^2}{\|\mathbf{x}\|_2^2} = \max \frac{\mathbf{x}^H \mathbf{A}^H \mathbf{A}\mathbf{x}}{\mathbf{x}^H \mathbf{x}} = \lambda_{max}(\mathbf{A}^H \mathbf{A})$$
. Como  $\mathbf{A}^H \mathbf{A}$  es hermítica y definida positiva, sus v.p. son positivos,  $\Rightarrow \|A\|_S = \sqrt{\lambda_{max}(\mathbf{A}^H \mathbf{A})}$ .

#### Prop. 7 (número de condición, continuación)

Aplicación de la norma espectral a R:

 ${f R}^H={f R}\Rightarrow {\sf Si}\; \lambda_{max}$  es el mayor v.p. de  ${f R},\,\lambda_{max}^2$  mayor v.p de

 $\mathbf{R}^H \mathbf{R} \Rightarrow \|\mathbf{R}\|_S = \lambda_{max}.$ 

De la misma forma,  $\|\mathbf{R}^{-1}\|_S = 1/\lambda_{min}$ .

Finalmente,

$$\chi(\mathbf{R}) = \frac{\lambda_{max}}{\lambda_{min}}.$$

Si  $\chi(\mathbf{R})$  es grande, se dice que  $\mathbf{R}$  está mal condicionada.

Resolver problemas inversos con matrices de número de condición grande conduce a fuertes inestabilidades, amplificación del ruido, etc. ¿Porqué? Justificar y discutir posibles soluciones al problema.

#### Descomposición de Karhunen-Loève

Sea  $\mathbf{u}(n) = [u(n), u(n-1), \dots, u(n-M+1)]$  una realización de un proceso WSS, de media nula y matriz de correlación  $\mathbf{R}$ . Sean  $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_M$  los vectores propios asociados a los valores propios de  $\mathbf{R}$ . Entonces vale la expansión

$$\mathbf{u}(n) = \sum_{i=1}^{M} c_i(n) \mathbf{q}_i$$
, con  $c_i(n) = \mathbf{q}_i^H \mathbf{u}(n)$ .

¿Cuánto valen media y correlación de los  $c_i(n)$ ?

$$\mathbb{E}[c_i(n)] = \mathbf{q}_i^H \mathbb{E}[\mathbf{u}(n)] = 0, \quad \mathbb{E}[c_i(n)c_j^*(n)] = \begin{cases} \lambda_i & i = j, \\ 0 & i \neq j \end{cases}$$

Además,  $\sum_{i=1}^{M} |c_i(n)|^2 = \|\mathbf{u}(n)\|^2$ .

Supongamos  $\lambda_1>\lambda_2>\cdots>\lambda_M$ , y que tenemos información a priori que para p< M, los  $\lambda_{p+1},\ldots,\lambda_M$  son muy pequeños. Consideramos la aproximación:

$$\hat{\mathbf{u}} = \sum_{i=1}^{p} c_i(n) \mathbf{q}_i$$

$$\mathbf{c}(n) = [c_1(n), c_2(n), \dots, c_p(n)]$$
 representación de rango bajo de  $\mathbf{u}(n)$ .

¿Cuánto vale el error cuadrático medio de aproximación?  $\mathbf{e}(n) = \mathbf{u}(n) - \hat{\mathbf{u}}(n) = \sum_{i=n+1}^{M} c_i(n) \mathbf{q}_i$ .

$$\epsilon = \mathbb{E}[\|\mathbf{e}(n)\|^2] = \mathbb{E}[\mathbf{e}(n)^H \mathbf{e}(n)]$$

$$= \mathbb{E}\left[\sum_{i=p+1}^M \sum_{j=p+1}^M c_i^*(n)c_j(n)\mathbf{q}_i^H \mathbf{q}_j\right]$$

$$= \sum_{i=p+1}^M \sum_{j=p+1}^M \mathbb{E}[c_i^*(n)c_j(n)]\mathbf{q}_i^H \mathbf{q}_j = \sum_{i=p+1}^M \lambda_i.$$

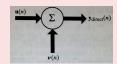
#### Aplicación: Transmisión de $\mathbf{u}(n)$ por un canal ruidoso

Suponemos ruido del canal  $\mathbf{v}(n)$  aditivo, WGN, independiente de la señal. Tenemos

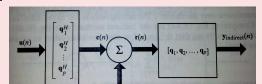
- $\mathbb{E}[\mathbf{u}(n)\mathbf{v}^H(n)] = \mathbf{0}$
- $\mathbb{E}[\mathbf{v}(n)\mathbf{v}^H(n)] = \sigma^2\mathbf{I}$

#### Transmisión:

Directa:



Indirecta:



#### Aplicación: Transmisión de $\mathbf{u}(n)$ por un canal ruidoso

#### Transmisión directa:

$$y_D(n) = u(n) + v(n)$$

$$\epsilon_D = \mathbb{E}[\|\mathbf{y}_D(n) - \mathbf{u}(n)\|^2] = \mathbb{E}[\|\mathbf{v}(n)\|^2]$$

$$= \sum_{i=1}^M \mathbb{E}[|v_i(n)|^2] = M\sigma^2.$$

#### Transmisión indirecta:

$$\begin{cases} \mathbf{c}(n) = \underbrace{[\mathbf{q}_1, \dots, \mathbf{q}_p, \mathbf{0}, \dots, \mathbf{0}]^H}_{\tilde{\mathbf{Q}}^H} \mathbf{u}(n) \\ \mathbf{r}(n) = \mathbf{c}(n) + \mathbf{v}(n) \end{cases}$$

$$\Rightarrow \mathbf{y}_I = \tilde{\mathbf{Q}}^H[c_1(n), \dots, c_p(n), 0, \dots, 0]^T + \tilde{\mathbf{Q}}^H[v_1(n), \dots, v_p(n), 0, \dots, 0]^T$$

#### Aplicación: Transmisión de $\mathbf{u}(n)$ por un canal ruidoso

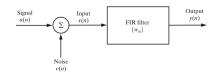
Transmisión indirecta (cont):

$$\Rightarrow \epsilon_I = \mathbb{E}[\|\mathbf{y}_I(n) - \mathbf{u}(n)\|^2] = \mathbb{E}\left[\|\underbrace{\mathbf{u}(n) - \mathbf{u}(n)}_{-\sum_{i=p+1}^M \sqrt{\lambda_i} \mathbf{q}_i} + \sum_{i=1}^p v_i(n) \mathbf{q}_i\|^2\right]$$
$$= \sum_{i=p+1}^M \lambda_i + p\sigma^2 \ (= \text{ error de aprox. señal + ruido filtrado}).$$

Ejercicio: establecer en qué condiciones es mejor la transmisión indirecta a la directa.

$$\epsilon_I < \epsilon_D \Leftrightarrow \sum_{i=p+1}^M \lambda_i + p\sigma^2 < M\sigma^2 \Leftrightarrow \sum_{i=p+1}^M \lambda_i < (M-p)\sigma^2.$$

# Filtros propios (Eigenfilters)



- u(n) WSS, media cero, mat. de correlación  ${\bf R},\ v(n)$  WGN,  $\sigma^2$
- u(n) y v(n) no correlacionados:  $\mathbb{E}[u(n)v^*(m)] = 0 \ \forall \ m, n.$

**Objetivo:** encontrar el filtro óptimo  $\mathbf{w}$  que maximice la SNR a la salida.

Ejercicio: Calcular la potencia media a la salida, y sus contribuciones debido a la señal y al ruido  $y(n) = w * (u + w)(n) = \sum_{k=0}^{M-1} w(k)(u(n-k) + v(n-k))$ 

$$\mathbb{E}[|y(n)|^2] = \sum_{k,k'} w(k) \mathbb{E}\left[ (u(n-k) + v(n-k))(u(n-k') + v(n-k'))^* \right]$$

# Filtros propios (Eigenfilters)

Ejercicio: encontrar  $\mathbf{w}$  que maximice  $SNR = \frac{\mathbf{w}^H \mathbf{R} \mathbf{w}}{\sigma^2 \mathbf{w}^H \mathbf{w}}$ .

Filtro óptimo:

$$\left\{ \begin{array}{l} \max_{\mathbf{w}} SNR \\ \text{sujeto a } \mathbf{w}^H \mathbf{w} = 1 \end{array} \right. \Leftrightarrow \left\{ \begin{array}{l} \max_{\mathbf{w}} \mathbf{w}^H \mathbf{R} \mathbf{w} \\ \text{sujeto a } \mathbf{w}^H \mathbf{w} = 1 \end{array} \right.$$

 $\Leftrightarrow$ 

 ${f w}$  vector propio asociado al mayor valor propio de  ${f R}$   $(\lambda_{max},{f q}_{max})$ 

$$\left\{ egin{array}{l} \mathbf{w}_{opt} = \mathbf{q}_{max} \ \mathsf{SNR}_{opt} = rac{\lambda_{max}}{\sigma^2} \end{array} 
ight.$$

## Densidad Espectral de Potencia

La matriz de correlación es una descripción temporal de las propiedades estadísticas de segundo orden del proceso.

Aplicándo la DTFT a la secuencia de autocorrelaciones  $\{r(k)\}$  obtenemos la densidad espectral de potencia (o espectro de potencia) del proceso.

#### Def.:

$$S(\omega) = \sum_{k=-M+1}^{M+1} r(k) \exp(-i\omega k), \quad -\pi \le \omega < \pi.$$

Tenemos además la fórmula de inversión

$$r(k) = \frac{1}{2\pi} \int_{\pi}^{\pi} S(\omega) \exp(i\omega k) d\omega, \quad k = 0, \pm 1, \pm 2, \dots, \pm M - 1.$$

# Densidad Espectral de Potencia: Filtrado de un proceso

$$\mathbf{u}(n), S_u(\omega) \longrightarrow \overline{\{h(l)\}, H(\omega)} \longrightarrow \mathbf{y}(n), S_y(\omega)$$

#### ¿Cuánto vale $S_u(\omega)$ ?

Para cada realización de  $\mathbf{u}(n)$ , tenemos  $y(n) = \sum_{l=0}^{M-1} h(l)u(n-l)$ .

$$r_y(k) = \mathbb{E}[y(n)y^*(n-k)] = \sum_{l=0}^{M-1} \sum_{l'=0}^{M-1} h(l)h^*(l')\mathbb{E}[u(n-l)u^*(n-k-l')]$$

$$= \sum_{l=0}^{M-1} \sum_{l'=0}^{M-1} h(l)h^*(l')r_u(k+l'-l) = \sum_{l=0}^{M-1} h(l) \sum_{l'=0}^{M-1} h^*(l')r_u(k+l'-l)$$

#### Entonces

# Densidad Espectral de Potencia: Propiedades

# Prop.1: La DEP de un proceso WSS discreto es $2\pi$ -periódica

$$S(\omega + 2n\pi) = \sum_{k=-M+1}^{M-1} r(k) \exp(-i(\omega + 2n\pi)k))$$
$$= \sum_{k=-M+1}^{M-1} r(k) \exp(-i2n\pi) \exp(-i\omega k) = S(\omega)$$

#### Prop.2: La DEP de un proceso WSS discreto es real

$$S(\omega) = r(0) + \sum_{k=1}^{M-1} r(k) \exp(-i\omega k) + \sum_{k=-M+1}^{-1} r(k) \exp(-i\omega k)$$

#### Prop.3: La DEP de un proceso WSS discreto real es par

$$S(-\omega) = \sum_{k=-M+1}^{M-1} r(k) \exp(i\omega k)^{l=-k} \sum_{l=-M+1}^{M-1} r(-l) \exp(-i\omega l)^{l=-k}$$

$$= \sum_{l=-M+1}^{M-1} r^*(l) \exp(-i\omega l)^{r^*(l)=r(l)} \sum_{l=-M+1}^{M-1} r(l) \exp(-i\omega l)^{l=-k}$$

# Prop.4: El área bajo la curva $\omega \mapsto S(\omega)/2\pi$ es el valor cuadrático medio del proceso, o su potencia

Si k = 0, de la fórmula de inversión

$$r(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} S(\omega) d\omega.$$

#### Prop.5: La DEP es positiva

Definimos el filtro  $H(\omega):=1\!\!1_{\{|\omega-\omega_c|\leq\Delta\omega\}}.$  La salida y de filtrar  $\mathbf{u}(n)$ por H conduce a  $S_u(\omega) = S_u(\omega)|H(\omega)|^2$ . Luego,

$$0 \le \mathbb{E}[y^2(n)] = r_y(0) = \frac{1}{2\pi} \int_{\omega_c - \Delta\omega}^{\omega_c + \Delta\omega} S_u(\omega)$$

$$0 \le \mathbb{E}[y^{2}(n)] = r_{y}(0) = \frac{1}{2\pi} \int_{\omega_{c} - \Delta\omega}^{\omega_{c} - \Delta\omega} S_{u}(\omega)$$
$$\sim_{\Delta\omega \to 0} \frac{1}{2\pi} \int_{\omega_{c} - \Delta\omega}^{\omega_{c} + \Delta\omega} \left( S_{u}(\omega_{c}) + \frac{dS}{d\omega}(\omega_{c})(\omega - \omega_{c}) \right) d\omega = \frac{1}{2\pi} 2\Delta\omega S_{u}(\omega_{c})$$

$$\Rightarrow S(\omega_c) > 0 \ \forall \in [-\pi, \pi).$$

# Prop.6: Si $\lambda_m$ , $m=1,\ldots,M$ son los v.p de R, entonces

 $\min_{\omega} S(\omega) \leq \lambda_m \leq \max_{\omega} S(\omega)$ . Además,  $\chi(\mathbf{R}) = \frac{\lambda_{max}}{\lambda_{min}} \leq \frac{S_{max}}{S_{min}}$ .

Sabemos que 
$$\lambda_m = \frac{\mathbf{q}_m^H \mathbf{R} \mathbf{q}_m}{\mathbf{q}_m^H \mathbf{q}_m}$$
, con  $\mathbf{q}_m = [q_m(1), q_m(1), \dots, q_m(M)]^T$ .

$$\mathbf{q}_m^H \mathbf{R} \mathbf{q}_m = \sum_{k=1}^m \sum_{l=1}^m q_m(k)^* r(l-k) q_m(l)$$
$$= \frac{1}{2\pi} \sum_{l=1}^m \sum_{l=1}^m q_m(k)^* q_m(l) \int_0^\pi S(\omega) \exp(i\omega(l-k)) d\omega$$

### Prop. 6 (cont.)

Si llamamos  $Q'(\omega)$  a la DTFT de  $\mathbf{q}_m^*$ , i.e.

$$Q'(\omega) = \sum_{k=1}^{M} \mathbf{q}_{m}^{*}(k) \exp(-i\omega k)$$
, tenemos que

$$\mathbf{q}_m^H \mathbf{R} \mathbf{q}_m = \frac{1}{2\pi} \int_{-\pi}^{\pi} S(\omega) |Q'(\omega)|^2 d\omega.$$

De la misma forma,

$$\mathbf{q}_m^H \mathbf{q}_m = \frac{1}{2\pi} \int_{-\pi}^{\pi} |Q'(\omega)|^2 d\omega.$$

Luego,

$$\lambda_m = \frac{\int_{-\pi}^{\pi} S(\omega) |Q'(\omega)|^2 d\omega}{\int_{-\pi}^{\pi} |Q'(\omega)|^2 d\omega},$$

por lo que

$$\min S(\omega) \le \lambda_m \le \max S(\omega).$$