# Estimación y Predicción en Series Temporales

Filtro de Wiener

#### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

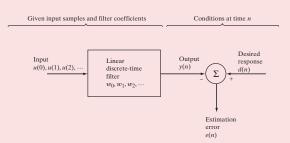
2022

Biblio: Haykin, Adaptive Filter Theory 4<sup>a</sup> edición, Capítulo 2. Hayes, Statistical Digital Signal Processing and Modeling (1996), Cap. 7.

#### Introducción

Estudiaremos una clase de filtros en tiempo discreto, óptimos en un sentido que definiremos más adelante, llamados *Filtros de Wiener*.

#### Filtrado lineal óptimo: planteo del problema



- $\{u(n)\}, \{d(n)\}$ : realizaciones de procesos estocásticos conjuntamente WSS, de media nula (si no, basta con restárselas).
- y(n): estimación de la respuesta deseada en tiempo n.

### Restricciones y opciones de diseño

#### Sobre el filtro

- Restricciones: lineal y discreto.
- Opciones: FIR o IIR. Trataremos la teoría para IIRs (siendo los FIRs un caso particular), pero nos focalizaremos en los FIRs por ser inherentemente estables.
- Obs: Cuando tratemos con filtros adaptivos, tener que lidiar con IIRs y sus posibles inestabilidades hacen del problema difícil de manejar. Por esta razón en general en filtros adaptivos se utilizan FIRs, a pesar que los IIR son mucho menos demandantes computacionalmente.

#### Sobre el criterio estadístico de optimalidad

- E[|e(n)|]: convexo, no diferenciable. Corresponde a distribuciones de Laplace.
- $\mathbb{E}[|e(n)|^2]$ : convexo, diferenciable. Corresponde a distribuciones Gaussianas. Es matemáticamente más sencillo de tratar (podemos calcular gradientes).
- Otros.

## Posibles Aplicaciones

Dependiendo de cómo están vinculadas u(n) y d(n), varios problemas fundamentales pueden ser planteados como un filtrado de Wiener:

- Filtrado: u(n) = d(n) + v(n), con v(n) ruido. Estimar d(n) a partir de muestras ruidosas con un filtro causal, i.e. a partir de las muestras u(n), u(n-1), u(n-2),....
- Suavizado: idem salvo que el filtro puede ser no causal. Por ejemplo, estimar d(n) offline a partir de todo el registro de datos disponibles (previos y posteriores a n).
- Predicción: si d(n) = u(n+1) y el filtro es causal, se busca estimar u(n+1) a partir de u(n) y sus muestras previas.
- Deconvolución: u(n) = h \* d(n) + v(n). El objetivo es encontrar algún filtro de respuesta al impulso g(n) tal que podamos estimar  $\hat{d}(n) = g * u(n)$ .
- Otros.

## Filtrado de Wiener: Solución al problema

- Objetivo: encontrar  $w_0, w_1, w_2, \ldots$  tales que se minimice  $J_n(\mathbf{w}) = \mathbb{E}[|e(n)^2|] = J(\mathbf{w}).$
- Desarrollaremos la solución matemática a este problema de optimización estadística abordando dos enfoques diferentes pero complementarios:
  - El principio de ortogonalidad (característicos de los espacios de Hilbert)
  - La superficie de performance del error e(n).

## Las ecuaciones normales o de Wiener-Hopf (1)

- Entrada:  $u(0), u(1), u(2), \dots$  Resp. al impulso del filtro:  $w_0, w_1, w_2, \dots$   $\bigg\}$  complejas e in
- Salida del filtro:

$$\begin{split} y(n) &= \sum_{k=0}^{+\infty} w_k^* u(n-k), \ n = 0, 1, 2, \dots \\ &= \mathbf{w}^H \mathbf{u}(n), \ \text{con } \mathbf{w}^T = [w_0, w_1, w_2, \dots], \\ &\mathbf{u}(n)^T = [u(n), u(n-1), u(n-2), \dots] \end{split}$$

- $\bullet \ e(n) = d(n) y(n).$
- Recordemos que  $\{u(n)\}, \{d(n)\}$  son realizaciones de procesos estocásticos conjuntamente WSS, de media nula

## Las ecuaciones normales o de Wiener-Hopf (2)

Queremos ver bajo qué condiciones en  ${\bf w}$  (o cual es el filtro tal que)  $J({\bf w})=\mathbb{E}[e^*(n)e(n)]$  alcanza el mínimo.

Definamos 
$$\mathbf{p}^T = [p(0), p(-1), p(-2), \dots] = \mathbb{E}[\mathbf{u}(n)d^*(n)].$$

#### Ejercicio:

- ① Escribir  $J(\mathbf{w})$  como función de  $\mathbf{w}$ ,  $\mathbf{R} = \mathbb{E}[\mathbf{u}(n)\mathbf{u}(n)^H]$ ,  $\mathbf{p}$  y  $\sigma_d^2 = \mathbb{E}[|d(n)|^2]$ , y verificar que es cuadrática y convexa en  $\mathbf{w}$ .
- 2 Escribir el sistema de ecuaciones que debe verificar  $\mathbf{w}_o = \arg\min_{\mathbf{w}} J(\mathbf{w})$ , conocido como *ecuaciones normales*.

$$\begin{split} J(\mathbf{w}) = & \mathbb{E}[(d^*(n) - \mathbf{u}^H(n)\mathbf{w})(d(n) - \mathbf{w}^H\mathbf{u}(n))] \\ = & \mathbb{E}[|d(n)|^2 + \mathbf{w}^H\mathbb{E}[\mathbf{u}(n)\mathbf{u}(n)^H]\mathbf{w} - \mathbf{w}^H\mathbb{E}[\mathbf{u}(n)d^*(n)] - \mathbb{E}[d(n)\mathbf{u}^H(n)]\mathbf{w} \\ = & \mathbf{w}^H\mathbf{R}\mathbf{w} - \mathbf{p}^H\mathbf{w} - \mathbf{w}^H\mathbf{p} + \sigma_d^2. \end{split}$$

Es convexa ya que  ${\bf R}$  es def. positiva, por lo que admite un único mínimo local.

Sabemos que  $\nabla_{\mathbf{w}} = 2 \frac{\partial}{\partial \mathbf{w}^*}$  (ver Haykin, Apéndice B).

## Principio de ortogonalidad

#### Breve paréntesis: $\mathbb{E}[X^HY]$ como producto interno

- $X_1, X_2, Y$  vectores aleatorios,  $\mathbb{E}[X_1] = \mathbb{E}[X_2] = \mathbb{E}[Y] = 0, a \in \mathbb{C}$ .
- $\langle X, Y \rangle := \mathbb{E}[X^H Y]$  define un producto interno:
  - $\langle X, X \rangle \geq 0$ ,  $y \langle X, X \rangle = 0 \Leftrightarrow X = 0$  c.s.
  - < X, Y > = < Y, X > \*
  - $< aX_1 + X_2, Y >= a^* < X_1, Y > + < X_2, Y >$  (linealidad de  $\mathbb{E}[\cdot]$ ).
- $< X,Y> = \mathbb{E}[X^HY] = 0 \Leftrightarrow X,Y$  no correlacionados (o ortogonales para este p. i.).

$$\mathbf{R}\mathbf{w}_{o} = \mathbf{p} \Leftrightarrow \mathbb{E}[\mathbf{u}(n)\mathbf{u}(n)^{H}]\mathbf{w}_{o} = \mathbb{E}[\mathbf{u}(n)d^{*}(n)]$$

$$\Leftrightarrow \mathbb{E}[\mathbf{u}(n)(d^{*}(n) - \mathbf{u}(n)^{H}\mathbf{w}_{o})] = \mathbb{E}[\mathbf{u}(n)e_{o}^{*}(n)] = \mathbf{0}.$$

$$\Leftrightarrow \mathbb{E}[u(n-k)e_{o}^{*}(n)] = 0 \ \forall \ k = 0, 1, 2, \dots$$

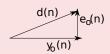
 $\Rightarrow$  La CNS para que J alcance el mínimo es que el error  $e(n)=e_o(n)$  sea ortogonal a todas las muestras involucradas al tiempo n.

 $Ae_{n}(n)$ 

#### Principio de ortogonalidad (cont.)

Cuando el filtro opera en condición óptima  $\mathbf{w} = \mathbf{w}_o$ , la estimación de la respuesta deseada y el error de estimación son ortogonales:

$$\mathbb{E}[y_o(n)e^*(n)] = \mathbb{E}[\mathbf{w}_o^H \mathbf{u}(n)e_o^*(n)] = \mathbf{w}_o^H \mathbb{E}[\mathbf{u}(n)e_o^*(n)] = 0.$$



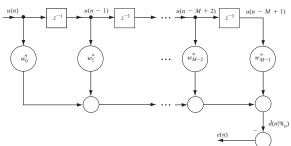
## Error cuadrático medio mínimo

$$e_o(n) = d(n) - y_o(n), \ y_o(n) = \hat{d}(n), \ J_{min} = \mathbb{E}[|e_o(n)|^2]$$

Por el principio de ortogonalidad, sabemos que  $e_o(n) \perp y_o(n)$ , de dónde

 $d(n) = a(n) + a(n) \rightarrow \mathbb{E}[|d(n)|^2] - \mathbb{E}[|a(n)|^2] + \mathbb{E}[|a(n)|^2]$ 

## Solución de las ecs. normales para filtros transversales



Ahora estamos en dimensión finita:

$$\mathbf{u}(n)^{T} = [u(n), u(n-1), \dots, u(n-M+1)]$$

$$\mathbf{w}^{T} = [w_{0}, w_{1}, \dots, w_{M-1}], \quad \mathbf{w}_{o}^{T} = [w_{o,0}, w_{o,1}, \dots, w_{o,M-1}]$$

$$\mathbf{p}^{T} = [p(0), p(-1), \dots, p(-M+1)]$$

 $\mathbf{w}_o = \mathbf{R}^{-1}\mathbf{p}$   $\longrightarrow$  Necesitamos conocer: matriz de correlación de  $\mathbf{u}(n)$  y las correlaciones cruzadas entre u(n-k) y d(n),  $k=0,1,\ldots,M-1$ .

## Superficie de performance del error

$$J(\mathbf{w}) = \mathbf{w}^{H} \mathbf{R} \mathbf{w} - \mathbf{p}^{H} \mathbf{w} - \mathbf{w}^{H} \mathbf{p} + \sigma_{d}^{2}.$$

$$J_{min} = J(\mathbf{w}_{o}) = \mathbf{p}^{H} \mathbf{R}^{-H} \mathbf{R} \mathbf{R}^{-1} \mathbf{p} - \mathbf{p}^{H} \mathbf{R}^{-1} \mathbf{p} - \mathbf{p}^{H} \mathbf{R}^{-H} \mathbf{p} + \sigma_{d}^{2}.$$

$$= \sigma_{d}^{2} - \mathbf{p}^{H} \mathbf{R}^{-1} \mathbf{p}$$

$$= \sigma_{d}^{2} - \mathbf{p}^{H} \mathbf{w}_{o}.$$

Se puede ver fácilmente que

$$J(\mathbf{w}) = J_{min} + (\mathbf{w} - \mathbf{w}_o)^H \mathbf{R} (\mathbf{w} - \mathbf{w}_o)$$

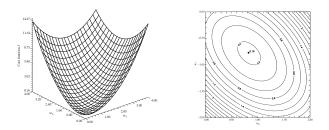
#### Forma canónica de la superficie de error

Sabemos que  $\mathbf{R} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^H$  (R hermítica, teorema espectral). Luego,

$$J(\mathbf{w}) = J_{min} + (\mathbf{w} - \mathbf{w}_o)^H \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^H (\mathbf{w} - \mathbf{w}_o)$$

$$= J_{min} + \mathbf{v}^H \mathbf{\Lambda} \mathbf{v}, \text{ con } \mathbf{v} = \mathbf{Q}^H (\mathbf{w} - \mathbf{w}_o) \text{ la proyección de } (\mathbf{w} - \mathbf{w}_o) \text{ la proyección de } (\mathbf{w} - \mathbf{w}_o)$$
en los ejes principales de  $\mathbf{R}$  (... de la superfittifia

# Superficie de performance del error: ejemplo de un filtro con dos taps



En la forma canónica,  $J_{min}$  se alcanza en  $(\mathbf{w} - \mathbf{w}_o) = (0,0)$ , y los ejes están orientados según los ejes principales de las elipses de las curvas de nivel.

### Filtro de Wiener IIR (no causal)

- Dado el proceso  $\{u(n)\}$ , buscamos el filtro  $\{h(n)\}$  que produzca la salida más cercana a  $\{d(n)\}$  en el sentido MSE.
- Si bien la formulación es la misma que para los FIR, ahora tenemos un número infinito de incógnitas {h(n)}:

$$e(n) = d(n) - \sum_{k=-\infty}^{+\infty} h(k)u(n-k), \ n \in \mathbb{Z}$$
$$J(\{h\}) = \mathbb{E}\left[|e(n)|^2\right] = \mathbb{E}\left[e(n)e^*(n)\right].$$

Calculando  $\nabla_{h(k)}J$  tenemos

$$\nabla_{h(k)}J = 2\frac{\partial J}{\partial h^*(k)} = -2\mathbb{E}[e(n)u^*(n-k)], \ k \in \mathbb{Z}.$$

Igualando a cero obtenemos el principio de ortogonalidad:

$$\mathbb{E}[e(n)u^*(n-k)] = 0, \ k \in \mathbb{Z}.$$

Remplazando e(n) y usando la estacionaridad conjunta de  $\{d(n)\}$  y  $\{u(n)\}$  tenemos las ecuaciones de Wiener-Hopf para el filtro IIR:

$$\sum_{k=-\infty}^{+\infty} h(k)r_u(n-k) = r_{du}(n), \ n \in \mathbb{Z}$$

Si bien no podemos proceder a expresar el sistema matricialmente, podemos expresarlo fácilmente en Fourier ya que  $h * r_u(n) = r_{du}(n)$ :

$$H(\omega)S_u(\omega) = S_{du}(\omega) \Rightarrow \left| H(\omega) = \frac{S_{du}(\omega)}{S_u(\omega)} \right|$$

De esta forma, procediendo como hicimos para el caso FIR,

$$J_{min} = r_d(0) - \sum_{k=-\infty}^{+\infty} h(k) r_{du}^*(k) = r_d(0) - \frac{1}{2\pi} \int_{-\pi}^{\pi} H(\omega) S_{du}^*(\omega) d\omega,$$

$$J_{min} = \frac{1}{2\pi} \int_{-\pi}^{\pi} \left[ S_u(\omega) - H(\omega) S_{du}^*(\omega) \right] d\omega$$

#### Filtro de Wiener IIR causal

En este caso el filtro debe verificar h(n) = 0 para todo n < 0. La salida del filtro viene dada por

$$y(n) = h * u(n) = \sum_{k=0}^{+\infty} h(k)u(n-k).$$

De esta forma las ecuaciones de Wiener-Hopf para un IIR causal quedan

$$\sum_{k=0}^{+\infty} h(k)r_u(n-k) = r_{du}(n), \ n \in \mathbb{N}$$

- La restricción  $n \ge 0$  is importante ya que ahora no podemos expresar  $r_{du}(n)$  como la convolución de h y u.
- Las ecuaciones de Wiener-Hopf para este caso se pueden resolver, pero el procedimiento es más complejo (ver Hayes, §7.3.2).