Estimación y Predicción en Series Temporales

Filtro Adaptativo LMS

Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Haykin, Adaptive Filter Theory, 4.ª edición, Cap. 5 y 6). Hayes, Statistical Digital Signal Processing and Modeling (1996), Cap. 9.

Introducción - Motivación

- El algoritmo de steepest descent supone el conocimiento de ∇_wJ(w(n)) y una elección correcta de μ.
- En muchos casos es imposible contar con esta información, y debemos estimar $\nabla_{\mathbf{w}}J(\mathbf{w}(n))$ a partir de los datos.
- Entre los algoritmos que estiman el gradiente, el LMS es el más simple: no necesita medir correlaciones ni inversiones matriciales.
- La forma de hacerlo es substituir \mathbf{p} y \mathbf{R} en la expresión de $\nabla_{\mathbf{w}} J(\mathbf{w}(n))$ por estimaciones. LMS utiliza la estimación más trivial: los valores instantáneos.

$$\nabla_{\mathbf{w}} J(\mathbf{w}(n)) = -2\mathbf{p} + 2\mathbf{R}\mathbf{w}(n)$$
$$\widehat{\mathbf{R}}(n) = \mathbf{u}(n)\mathbf{u}(n)^{H}$$
$$\widehat{\mathbf{p}}(n) = \mathbf{u}(n)d^{*}(n)$$

El algoritmo LMS

De esta forma, $\widehat{\nabla_{\mathbf{w}}J}(\mathbf{w}(n)) = -2\mathbf{u}(n)d^*(n) + 2\mathbf{u}(n)\mathbf{u}(n)^H\widehat{\mathbf{w}}(n)$.

$$\begin{split} \text{Teníamos} \ \ \mathbf{w}(n+1) &= \mathbf{w}(n) - \frac{1}{2}\mu\nabla_{\mathbf{w}}J(\mathbf{w}(n)) \\ &\Rightarrow \ \widehat{\mathbf{w}}(n+1) = \widehat{\mathbf{w}}(n) + \mu\mathbf{u}(n)[d^*(n) - \mathbf{u}^H(n)\widehat{\mathbf{w}}(n)]. \end{split}$$

O de forma equivalente,

$$\begin{cases} y(n) &= \widehat{\mathbf{w}}^{H}(n)\mathbf{u}(n) \\ e(n) &= d(n) - y(n) \\ \widehat{\mathbf{w}}(n+1) &= \widehat{\mathbf{w}}(n) + \mu e^{*}(n)\mathbf{u}(n) \end{cases}$$

Observaciones

- ① $\mu e^*(n)\mathbf{u}(n)$ es la corrección en el estimado de $\mathbf{w}(n)$.
- ② Dirección del gradiente muy ruidosa, puede estar muy lejos de la real.
- (3) A pesar de que los estimados de R y p son instantáneos, la performance global es buena. ¿Porqué? Porque el mismo algoritmo, al acumular, promedia los estimados.

Complejidad del método LMS

Si el filtro tiene M coeficientes:

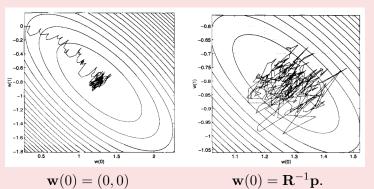
	×	+
Cálculo de la salida $y(n) = \widehat{\mathbf{w}}^H(n)\mathbf{u}(n)$	M	M-1
Actuallización de coeficientes	M	M
Cálculo del error $e(n) = d(n) - y(n)$	_	1
$\mu e^*(n)$	1	_
TOTAL:	2M + 1	$\overline{2M}$.

Convergencia del algoritmo LMS

- LMS estima el gradiente mediante valores instantáneos.
 En general, la corrección aplicada a los coeficientes del filtro no va a ser en la dirección de máxima pendiente.
- Como $\mathbb{E}[\widehat{\nabla}_{\mathbf{w}}J(\mathbf{w}(n))] = -2\mathbb{E}[\mathbf{u}(n)e^*(n)] = \nabla_{\mathbf{w}}J(\mathbf{w}(n))$, la corrección se hace, en media, en la dirección de máxima pendiente.

Ejemplo: convergencia típica de LMS





Convergencia de LMS: marco estadístico

- Suponemos u(n) y d(n) conjuntamente WSS.
- Nos interesa saber las condiciones para las cuales

$$\lim_{n\to+\infty} \mathbb{E}[\mathbf{w}(n)] = \mathbf{w}_o = \mathbf{R}^{-1}\mathbf{p}.$$

Tomando esperanzas en las ecuaciones del LMS:

$$\mathbb{E}[\widehat{\mathbf{w}}(n+1)] = \mathbb{E}[\widehat{\mathbf{w}}(n)] + \mu \mathbb{E}[\mathbf{u}(n)d^*(n)] - \mu \mathbb{E}[\mathbf{u}(n)\mathbf{u}^H(n)\widehat{\mathbf{w}}(n)].$$

El último término es difícil de evaluar; supondremos para simplificar que $\mathbf{u}(n)$ y $\mathbf{w}(n)$ son estadísticamente independientes. Esta hipótesis es claramente no cierta del todo, pero conduce a resultados que condicen relativamente con las simulaciones.

De esta forma,

$$\mathbb{E}[\widehat{\mathbf{w}}(n+1)] = \mathbb{E}[\widehat{\mathbf{w}}(n)] + \mu \mathbb{E}[\mathbf{u}(n)d^*(n)] - \mu \mathbb{E}[\mathbf{u}(n)\mathbf{u}^H(n)]\mathbb{E}[\widehat{\mathbf{w}}(n)]$$
$$= (\mathbf{I} - \mu \mathbf{R})\mathbb{E}[\widehat{\mathbf{w}}(n)] + \mu \mathbf{p}.$$

Convergencia de LMS: marco estadístico (cont.)

- La ecuación anterior es la misma que fue obtenida para el algoritmo de máxima pendiente, por lo que vale el mismo análisis.
- Por lo tanto: Para un proceso WSS, el algoritmo LMS converge en media si $0 < \mu < \frac{2}{\lambda_{max}}$, y si la hipótesis de independencia se satisface.

La condición anterior tiene dos inconvenientes:

- ① La convergencia de la media de $\mathbf{w}(n)$ no implica que permanezca acotado.
- ② No conocemos λ_{max} .

Para el segundo punto, tenemos una forma razonable de solucionarlo: sabemos que $\lambda_{max} \leq \sum_{k=1}^{M} \lambda_k = \operatorname{Traza}(\mathbf{R})$. Luego, como \mathbf{R} es Toeplitz, $\operatorname{Traza}(\mathbf{R}) = Mr(0) = M\mathbb{E}[|u(n)|^2]$.

Tenemos entonces una condición suficiente para la convergencia del algoritmo LMS: $0 < \mu < \frac{2}{M\mathbb{E}[|u(n)|^2]}$.

Podemos por ejemplo estimar $\mathbb{E}[|u(n)|^2] = \frac{1}{N} \sum_{k=0}^{N-1} |u(n-k)|^2$.

Criterios de convergencia (cont.)

Algunos criterios posibles:

- Convergencia de la media: $\mathbb{E}[\hat{\mathbf{w}}(n) \mathbf{w}_o] \xrightarrow{n \to +\infty} \mathbf{0}$ (la solución de Wiener). Criterio de poco valor práctico, cualquier secuencia de valor medio cero converge en este sentido.
- Convergencia en media: $\mathbb{E}[\|\hat{\mathbf{w}}(n) \mathbf{w}_o\|] \stackrel{n \to +\infty}{\longrightarrow} \mathbf{0}$. Más fuerte. Difícil de probar debido a la singularidad en $\mathbf{0}$.
- Convergencia en media cuadrática:

$$\mathcal{D}(n) := \mathbb{E}[\|\hat{\mathbf{w}}(n) - \mathbf{w}_o\|^2] \overset{n \to +\infty}{\longrightarrow} \mathbf{0}, \ \ (\mathcal{D}(n): \ \mathsf{Desv\'{io}} \ \mathsf{del} \ \mathsf{error} \ \mathsf{cuadrate})$$

Es fácil de minimizar (funcional convexo diferenciable). Otra condición para describir la convergencia del LMS es

$$J(\mathbf{w}(n)) = \mathbb{E}[|e^2(n)|] \stackrel{n \to +\infty}{\longrightarrow} \text{cte.}$$

Convergencia en media cuadrática del método LMS

Definimos el error en exceso como: $J_{ex}(n) = J(\mathbf{w}(n)) - J_{min}$. Es fácil mostrar que

$$\lambda_{min}(\mathbf{R})\mathcal{D}(n) \leq J_{ex}(n) \leq \lambda_{max}(\mathbf{R})\mathcal{D}(n), \ \forall \ n.$$

Entonces el decaimiento de $J_{ex}(n)$ y $\mathcal{D}(n)$ son matemáticamente equivalentes. Nos focalizaremos entonces en el estudio de $J(\mathbf{w}(n))$.

Tenemos

$$J(\mathbf{w}(n)) = J_{min} + (\mathbf{w}(n) - \mathbf{w}_o)^T \mathbf{R}(\mathbf{w}(n) - \mathbf{w}_o)$$
$$= J_{min} + \mathbf{c}(n)^T \mathbf{R} \mathbf{c}(n)$$
$$= J_{min} + J_{ex}(n).$$

El cálculo de $J_{ex}(n)$ no es sencillo (ver Haykin). Es posible establecer la siguiente propiedad asintótica:

$$\begin{cases} J(\infty) &= J_{min} + J_{ex}(\infty) \\ &= \frac{J_{min}}{1 - \mu \sum_{k=0}^{M-1} \lambda_k / (2 - \mu \lambda_k)} \end{cases} \Leftrightarrow \begin{cases} 1. & 0 < \mu < 2/\lambda_{max} \\ 2. & \mu \sum_{k=0}^{M-1} \lambda_k / (2 - \mu \lambda_k) < 1 \end{cases}$$

Convergencia en media cuadrática del método LMS (cont.)

Luego,

$$J_{ex}(\infty) = J(\infty) - J_{min} = \mu J_{min} \frac{\sum_{k=0}^{M-1} \lambda_k / (2-\mu\lambda_k)}{1 - \mu \sum_{k=0}^{M-1} \lambda_k / (2-\mu\lambda_k)}.$$

Si $\mu \ll 2/\lambda_{max}$ (cierto en general), entonces:

- $\mu \lambda_k \ll 2 \Rightarrow$ la condición (2) anterior se vuelve $\mu < 2/\text{Tr}[\mathbf{R}]$.
- $J(\infty) \approx J_{min} \frac{1}{1 \frac{1}{2}\mu \text{Tr}[\mathbf{R}]}$
- $J_{ex}(\infty) \approx \mu J_{min} \frac{\frac{1}{2} \text{Tr}[\mathbf{R}]}{1 \frac{1}{2} \mu \text{Tr}[\mathbf{R}]} \approx \frac{1}{2} \mu J_{min} \text{Tr}[\mathbf{R}]$

Defs.: Desajuste, valor propio promedio

Desajuste:
$$\mathcal{M} = \frac{J_{ex}(\infty)}{J_{min}} \stackrel{\mu \ll 2/\lambda_{max}}{\approx} \mu \frac{\frac{1}{2} \text{Tr}[\mathbf{R}]}{1 - \frac{1}{6} \mu \text{Tr}[\mathbf{R}]} \approx \frac{1}{2} \mu \text{Tr}[\mathbf{R}]$$

OBS: recordar que $Tr[\mathbf{R}]$ = potencia en los retardos, potencia en el vector de observación.



Convergencia en media cuadrática del método LMS (cont.)

- Supongamos que aproximamos la curva de aprendizaje (promedio de realizaciones o ensambles) por una sola exponencial.
- La constante de tiempo será (siguiendo el mismo rationale que para máxima pendiente): $\tau_{mse,av} = \frac{1}{2\mu\lambda_{av}}$.
- Teníamos: $\mathcal{M} pprox rac{\mu}{2} \sum_{k=1}^M \lambda_k$ $\Rightarrow \mathcal{M} pprox rac{\mu}{2} M \lambda_{av} pprox rac{M}{4 au_{mse,av}}.$

Observaciones:

- 1 Para $\tau_{mse,av}$ fijo, $\mathcal{M} \propto M$.
- 2 $\mathcal{M} \propto \frac{1}{ au_{mse,av}} \propto \frac{1}{ ext{tiempo para alcanzar el valor final}}$
- $\left. \begin{array}{l} \mathcal{M} \propto \mu \\ \tau_{mse,av} \propto 1/\mu \end{array} \right\} \Rightarrow \mu \text{ es elección de compromiso.}$

Comparación: Máxima pendiente y LMS

- El error cuadrático medio es mínimo cuando $\mathbf{w}(n) = \mathbf{w}_o$.
- El algoritmo de máxima pendiente:
 - Converge a \mathbf{w}_o cuando $n \to +\infty$. Puede hacerlo porque utiliza el valor exacto del gradiente para cada iteración.
 - Tiene una curva de aprendizaje (n → J(n)) bien definida, constituída por exponenciales decrecientes según los modos, tantos como el orden del filtro.
- El algoritmo LMS:
 - Utiliza estimadores ruidosos del gradiente y por lo tanto sólo puede aproximarse a w_o y luego fluctuar entorno a éste.
 - Definimos el error cuadrático medio como $J(\infty)$, y el error cuadrático medio en exceso como $J_{ex}(\infty) = J(\infty) J_{min}$.
 - La curva de aprendizaje es ruidosa. Para analizar la dinámica del filtro necesitamos estudiar $\mathbb{E}[J(n)]$. En la práctica el ensamble de promedios se aproxima con 50 a 200 simulaciones independientes.

Discusión

Los tres factores que afectan el comportamiento del algoritmo son: μ , M, y $\{\lambda_i\}$. Podemos resumir los efectos individuales de la siguiente forma:

μ :

- Se puede interpretar como la memoria del algoritmo, ya que determina el peso relativo que se le asigna a las nuevas observaciones.
- Cuando μ es grande, la adaptación es rápida. Utilizando menor cantidad de datos, el error en exceso es mayor.
- Cuando μ es pequeño, la adaptación es más lenta. El filtro utiliza más datos (tiene más memoria), el error en exceso es menor.

M:

- Las propiedades de convergencia del error cuadrático medio $\mathbb{E}[J(n)]$ dependen de M.
- $\mathbb{E}[\mathbf{w}(n)]$ no depende de M.
- $\mathbb{E}[J(n)]$ converge $\Leftrightarrow 0 < \mu < \frac{2}{\sum_{k=1}^{M} \lambda_k}$. En este caso se dice que el LMS converge en media cuadrática.
- $\mathbb{E}[\hat{\mathbf{w}}(n)]$ converge $\Leftrightarrow 0 < \mu < \frac{2}{\lambda_{max}}$. En este caso se dice que LMS converge en la media.
- Dado que $\lambda_{max} \leq \sum_{k=1}^{M} \lambda_k$, si $\mathbb{E}[J(n)]$ converge $\Rightarrow \mathbb{E}[\hat{\mathbf{w}}(n)]$ converge.

$\{\lambda_i\}$:

- Cuando los valores propios de R están muy separados, tenemos:
 - J_{ex} queda determinado fundamentalmente por los λ_i grandes.
 - El tiempo de convergencia de $\mathbb{E}[\hat{\mathbf{w}}(n)]$ está limitado por los λ_i pequeños.
 - $J_{ex}(\infty) \approx \frac{1}{2} \mu J_{min} \text{Tr}[\mathbf{R}], \ \mathcal{M} = \frac{J_{ex}}{J_{min}} \approx \frac{1}{2} \mu \text{Tr}[\mathbf{R}]$

Resumen del algoritmo LMS

- Parámetros: M: número de coeficientes; μ : paso de ajuste, $0 < \mu < \frac{2}{\text{potencia de entrada}} = \frac{2}{Mr(0)}$.
- Condiciones iniciales: $\hat{\mathbf{w}}(0) = \mathbf{0}$.
- Datos: $\mathbf{u}(n)$: vector de entrada; d(n): respuesta deseada
- Valores a calcular: $\hat{\mathbf{w}}(n+1)$
- Cálculo:

$$e(n) = d(n) - \hat{\mathbf{w}}^{H}(n)\mathbf{u}(n)$$
$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \mu \mathbf{u}(n)e^{*}(n)$$

Algoritmo LMS en un entorno no estacionario

El entorno no estacionario puede deberse a dos motivos:

- ① La estadística de la respuesta deseada varía en el tiempo. Ejemplo: identificación de sistemas. En este caso ${f R}$ queda fija y ${f p}$ cambia.
- $\{u(n)\}$ no estacionario. Ejemplo: ecualizador de canal variante en el tiempo. En este caso \mathbf{R} y \mathbf{p} cambian.

El algoritmo tiene la tarea de encontrar el mínimo de la superficie de error y también seguir ("track") la posición de éste.

Sea $\mathbf{w}_o(n)$ el valor óptimo en el tiempo n (cambia).

$$\varepsilon(n) = \hat{\mathbf{w}}(n) - \mathbf{w}_o(n) \\
= \underbrace{\hat{\mathbf{w}}(n) - \mathbb{E}[\hat{\mathbf{w}}(n)]}_{\varepsilon_1(n)} + \underbrace{\mathbb{E}[\hat{\mathbf{w}}(n)] - \mathbf{w}_o(n)}_{\varepsilon_2(n)}$$

 $\varepsilon_1(n)$: errores en la estimación del gradiente (*weight vector noise*):

 $\varepsilon_2(n)$: retraso en el proceso adaptativo (*weight vector lag*).

LMS Normalizado (NLMS)

Una de las dificultades en la implementación del LMS es la elección de μ .

Para un proceso estacionario:

- LMS converge en la media si $0 < \mu < \frac{2}{\lambda_{max}}$.
- LMS converge en media cuadrática si $0 < \mu < \frac{2}{\text{Tr}[\mathbf{R}]}$.

En general no conocemos ${f R}$ y se debe estimar, o al menos estimar su traza. Una forma de hacerlo es

$$Tr[\mathbf{R}] = M\mathbb{E}[|u(n)^2|],$$

y la condición de media cuadrática puede substituírse por

$$\begin{array}{l} 0<\mu<\frac{2}{M\mathbb{E}[|u(n)^2|]},\\ \mathbb{E}[|u(n)^2|]\approx\frac{1}{M}\sum_{k=1}^M|u(n-k+1)|^2 \end{array} \right\} \Rightarrow \begin{array}{l} \text{convergencia en media}\\ \text{cuadrática vale si}\\ 0<\mu<\frac{2}{\mathbf{u}(n)^H\mathbf{u}(n)}. \end{array}$$

LMS Normalizado (NLMS) (cont.)

Una forma de incorporar esto en LMS es usando

$$\mu(n) = \frac{\beta}{\mathbf{u}(n)^H \mathbf{u}(n)} = \frac{\beta}{\|\mathbf{u}(n)\|^2}, \ \ \text{con} \ 0 < \beta < 2.$$

Esto da lugar al algoritmo adaptivo conocido como NLMS (Normalized LMS):

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \beta \frac{\mathbf{u}(n)}{\|\mathbf{u}(n)\|^2} e^*(n), \quad 0 < \beta < 2$$

Observaciones:

- ① En LMS la corrección es proporcional a $\mathbf{u}(n)$. Cuando es grande, podemos tener el problema de amplificar el ruido en el cálculo del gradiente.
- ② En el NLMS podemos tener problemas con valores de $\|\mathbf{u}(n)\|$ chicos. Una alternativa que corrige este problema es:

$$\hat{\mathbf{w}}(n+1) = \hat{\mathbf{w}}(n) + \beta \frac{\mathbf{u}(n)}{\|\mathbf{u}(n)\|^2 + \varepsilon} e^*(n), \quad 0 < \beta < 2, \quad \varepsilon > 0 \text{ chical}$$