# Estimación y Predicción en Series Temporales

Optimalidad basada en la densidad condicional y filtro de Kalman

#### Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

#### Biblio:

- Brown and Hwang, Introduction to Random Signals and Applied Kalman Filtering, 3ra edición, 1996.
- Anderson and Moore, Optimal Filtering, 1979 (re-edición Dover 2005).

### Introducción - Motivación

En la derivación del filtro de Kalman presentada en la clase anterior nos restringimos a:

- Filtros lineales
- Error cuadrático medio como índice de performance.

Hoy veremos que en el caso que los ruidos de estado y de medida son Gaussianos, los resultados son más generales.

## Esperanza condicional

Sean  $\mathcal{Y}_k = \{\mathbf{y}_0, \mathbf{y}_1, \dots, \mathbf{y}_k\}$  las medidas tomadas hasta el tiempo k.

Calculemos la norma del error de estimación  $\mathbf{e}_k = \mathbf{x}_k - \hat{\mathbf{x}}_k$ , conocido  $\mathcal{Y}_k$ , i.e.  $\mathbb{E}[\mathbf{e}_k^H \mathbf{e}_k | \mathcal{Y}_k]$ . La idea es encontrar el estimador  $\hat{\mathbf{x}}_k$  que la minimice.

# Minimización de la esperanza condicional

$$\mathbb{E}[\mathbf{e}_k^H \mathbf{e}_k | \mathcal{Y}_k] = \mathbb{E}[(\mathbf{x}_k - \hat{\mathbf{x}}_k)^H (\mathbf{x}_k - \hat{\mathbf{x}}_k) | \mathcal{Y}_k]$$
$$= \mathbb{E}[\mathbf{x}_k^H \mathbf{x}_k - \mathbf{x}_k^H \hat{\mathbf{x}}_k - \hat{\mathbf{x}}_k^H \mathbf{x}_k + \hat{\mathbf{x}}_k^H \hat{\mathbf{x}}_k | \mathcal{Y}_k].$$

Ejercicio: observando que todo estimador es función de los datos, i.e.  $\hat{\mathbf{x}}_k = \mathrm{fct}(\mathcal{Y}_k)$ , demostrar que el estimador óptimo es  $\hat{\mathbf{x}}_k = \mathbb{E}[\mathbf{x}_k|\mathcal{Y}_k]$ . Como el estimador es función de los datos,

$$\mathbb{E}[\mathbf{e}_k^H \mathbf{e}_k | \mathcal{Y}_k] = \mathbb{E}[\mathbf{x}_k^H \mathbf{x}_k | \mathcal{Y}_k] - \mathbb{E}[\mathbf{x}_k^H | \mathcal{Y}_k] \hat{\mathbf{x}}_k - \hat{\mathbf{x}}_k^H \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k] + \hat{\mathbf{x}}_k^H \hat{\mathbf{x}}_k$$

$$= \mathbb{E}[\mathbf{x}_k^H \mathbf{x}_k | \mathcal{Y}_k] + (\hat{\mathbf{x}}_k - \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k])^H (\hat{\mathbf{x}}_k - \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k])$$

$$- \mathbb{E}[\mathbf{x}_k^H | \mathcal{Y}_k] \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k].$$

El término en azul es el único que depende de  $\hat{\mathbf{x}}_k$ , y es inmediato ver que el MSE se minimiza si y sólo si

$$\hat{\mathbf{x}}_k = \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k]$$

Esta fórmula es general para cualquier estimador que minimiza el MSE, independientemente del modelo y las densidades de los ruidos.

#### El caso Gaussiano

Suponemos ahora que tenemos un estimador óptimo a priori  $\hat{\mathbf{x}}_k^-$  con matriz de covarianza de error  $\mathbf{P}_k^-$  asociada.

Consideramos la variable  $\mathbf{x}_k$ , que por definición ya está implícitamente condicionada por las medidas  $\mathcal{Y}_{k-1}$ .

• Densidad de probabilidad de  $\mathbf{x}_k$ :  $f_{\mathbf{x}_k}(\mathbf{x}_k) = \mathcal{N}(\mathbf{x}_k; \hat{\mathbf{x}}_k^-, \mathbf{P}_k^-)$ 

• 
$$\mathbf{y}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k \Rightarrow$$

$$\begin{cases} f_{\mathbf{y}_k}(\mathbf{y}_k) = \mathcal{N}(\mathbf{y}_k; \mathbf{C}_k \hat{\mathbf{x}}_k^-, \mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^H + \mathbf{R}_k) \\ f_{\mathbf{y}_k|\mathbf{x}_k}(\mathbf{y}_k) = \mathcal{N}(\mathbf{y}_k; \mathbf{C}_k \mathbf{x}_k, \mathbf{R}_k) \end{cases}$$

Usando la fórmula de Bayes tenemos

$$f_{\mathbf{x}_k|\mathcal{Y}_k} = f_{\mathbf{x}_k|\mathbf{y}_k} = \frac{f_{\mathbf{y}_k|\mathbf{x}_k}f_{\mathbf{x}_k}}{f_{\mathbf{y}_k}} = \frac{\mathcal{N}(\mathbf{y}_k; \mathbf{C}_k\mathbf{x}_k, \mathbf{R}_k)\mathcal{N}(\mathbf{x}_k; \hat{\mathbf{x}}_k^-, \mathbf{P}_k^-)}{\mathcal{N}(\mathbf{y}_k; \mathbf{C}_k\hat{\mathbf{x}}_k^-, \mathbf{C}_k\mathbf{P}_k^-\mathbf{C}_k^H + \mathbf{R}_k)}$$

Haciendo cuentas (ejercicio) se obtiene para la variable  $\mathbf{x}_k | \mathcal{Y}_k$ :

$$\hat{\mathbf{x}}_k = \mathbb{E}[\mathbf{x}_k | \mathcal{Y}_k] = \hat{\mathbf{x}}_k^- + \mathbf{P}_k^- \mathbf{C}_k^H (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^H + \mathbf{R}_k)^{-1} (\mathbf{y}_k - \mathbf{C}_k \hat{\mathbf{x}}_k^-) \\
\mathbf{P}_k = \text{Cov}[\mathbf{x}_k | \mathcal{Y}_k] = ((\mathbf{P}_k^-)^{-1} + \mathbf{C}_k^H \mathbf{R}^{-1} \mathbf{C}_k)^{-1}$$

### El caso Gaussiano

#### Tenemos entonces:

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{P}_k^- \mathbf{C}_k^H (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^H + \mathbf{R}_k)^{-1} (\mathbf{y}_k - \mathbf{C}_k \hat{\mathbf{x}}_k^-)$$

$$\mathbf{P}_k = ((\mathbf{P}_k^-)^{-1} + \mathbf{C}_k^H \mathbf{R}^{-1} \mathbf{C}_k)^{-1}$$

#### Observaciones:

- La expresión para la actualización del estimador de x<sub>k</sub> es idéntica a la del filtro de Kalman.
- Se puede demostrar que la expresión de covarianza del error de estimación en k es equivalente a la obtenida para el filtro de Kalman.
- Como resultado de la optimización vemos que la elección de actualizar el estimador  $\hat{\mathbf{x}}_k$  como el promedio de la predicción  $\hat{\mathbf{x}}_k^-$  y del error de predicción de la observación  $\mathbf{y}_k$  ponderados por la ganancia de Kalman,
  - $\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k(\mathbf{y}_k \mathbf{C}_k \hat{\mathbf{x}}_k^-)$ , fue acertada, al menos para el caso Gaussiano.
- En ningún momento impusimos que el filtro fuese lineal.
   Surgió naturalmente de imponer: (i) Ruidos Gaussianos:

# Modelo de estado a partir de un modelo ARMA

$$y(k+n) + \alpha_{n-1}y(k+n-1) + \dots + \alpha_0y(k) = \beta_m w(k+m) + \beta_{m-1}w(k+m-1) + \dots + \beta_0w(k).$$

- Imponemos que esto vale para m = n 1,  $k = 0, 1, 2, \ldots$
- Definimos una variable temporal r(k) que cumple

$$r(k+n) + \alpha_{n-1}r(k+n-1) + \dots + \alpha_0 r(k) = w(k).$$
 (\*)

Definimos los estados como:

$$x_1(k) = r(k)$$

$$x_2(k) = r(k+1)$$

$$\vdots$$

$$x_n(k) = r(k+n-1).$$

# Modelo de estado a partir de un modelo ARMA (cont.)

De esta forma, remplazando en (\*) podemos escribir:

$$\begin{bmatrix} x_1(k+1) \\ x_2(k+1) \\ \vdots \\ x_n(k+1) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & 0 & \dots \\ 0 & 0 & 1 & 0 & \dots \\ \vdots & & & & \\ -\alpha_0 & -\alpha_1 & -\alpha_2 & \dots & -\alpha_{n-1} \end{bmatrix} \begin{bmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_n(k) \end{bmatrix} + \begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix} w$$

Luego, para obtener y(k):

$$y(k) = [\beta_0 \ \beta_1 \ \dots \ \beta_m] \begin{bmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_n(k) \end{bmatrix}.$$

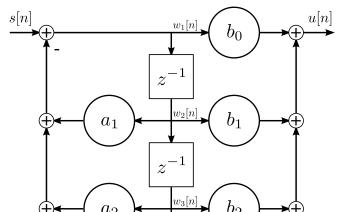
# Modelo de estado a partir de un modelo ARMA (cont.)

En forma de diagrama de bloque, calculando primero la transferencia correspondiente a (\*),

$$R(z)z^{n} + \alpha_{n-1}R(z)z^{n-1} + \dots + \alpha_{0}R(z) = W(z)$$

$$\Rightarrow R(z) = \frac{W(z)}{z^{n} + \alpha_{n-1}z^{n-1} + \dots + \alpha_{0}},$$

tenemos:



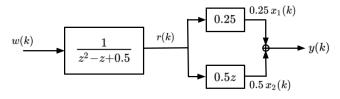
# Ejemplo

Tenemos el siguiente proceso ARMA:

$$y(k+2)-y(k+1)+\frac{1}{2}y(k)=\frac{1}{2}w(k+1)+\frac{1}{4}w(k), \quad k=0,1,2,\dots$$

Representar el proceso como diagrama de bloques, y proponer una representación en variables de estado.

#### Solución:



$$\begin{bmatrix} x_1(k+1) \\ x_2(k+1) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -0.5 & 1 \end{bmatrix} \begin{bmatrix} x_1(k) \\ x_2(k) \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} w(k).$$
$$y(k) = \begin{bmatrix} 0.25 & 0.5 \end{bmatrix} \begin{bmatrix} x_1(k) \\ x_2(k) \end{bmatrix}.$$

## Forma alternativa del filtro de Kalman discreto

En la formulación original teníamos

$$\begin{split} \mathbf{P}_k = & (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}_k^- \\ \mathbf{K}_k = & \mathbf{P}_k^- \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{R}_k)^{-1} \end{split}$$

Sustituyendo, tenemos

$$\mathbf{P}_k = \mathbf{P}_k^- - \mathbf{P}_k^- \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{R}_k)^{-1} \mathbf{C}_k \mathbf{P}_k^-.$$

• Se puede demostrar que si  $\mathbf{P}_k$ ,  $\mathbf{P}_k^-$  y  $\mathbf{R}_k$  son invertibles, entonces

$$\mathbf{P}_k^{-1} = (\mathbf{P}_k^-)^{-1} + \mathbf{C}_k^T \mathbf{R}_k^{-1} \mathbf{C}_k.$$

•  $\mathbf{K}_k = \mathbf{P}_k^- \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}_k^- \mathbf{C}_k^T + \mathbf{R}_k)^{-1}$ . Insertando  $\mathbf{P}_k \mathbf{P}_k^{-1}$  y  $\mathbf{R}_k^{-1} \mathbf{R}_k$  obtenemos

$$\mathbf{K}_{k} = \mathbf{P}_{k} \mathbf{P}_{k}^{-1} \mathbf{P}_{k}^{-} \mathbf{C}_{k}^{T} \mathbf{R}_{k}^{-1} \mathbf{R}_{k} (\mathbf{C}_{k} \mathbf{P}_{k}^{-} \mathbf{C}_{k}^{T} + \mathbf{R}_{k})^{-1}$$
$$= \mathbf{P}_{k} \mathbf{P}_{k}^{-1} \mathbf{P}_{k}^{-} \mathbf{C}_{k}^{T} \mathbf{R}_{k}^{-1} (\mathbf{C}_{k} \mathbf{P}_{k}^{-} \mathbf{C}_{k}^{T} \mathbf{R}_{k}^{-1} + \mathbf{I})^{-1}$$

Sustituyendo  $\mathbf{P}_{k}^{-1}$  en la expresión previa,

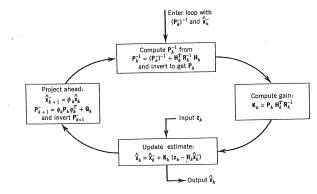
$$\mathbf{K}_1 = \mathbf{P}_1 \mathbf{C}_1^T \mathbf{R}^{-1}$$

# Forma alternativa del filtro de Kalman discreto (cont.)

Tenemos así una formulación alternativa del filtro de Kalman, con

$$\mathbf{P}_k^{-1} = (\mathbf{P}_k^-)^{-1} + \mathbf{C}_k^T \mathbf{R}_k^{-1} \mathbf{C}_k$$
$$\mathbf{K}_k = \mathbf{P}_k \mathbf{C}_k^T \mathbf{R}_k^{-1}$$

Obs. En esta formulación se calcula primero  $\mathbf{P}_k^{-1}$ .



En la Figura:  $\mathbf{H}_k = \mathbf{C}_k$ ,  $\mathbf{z}_k = \mathbf{y}_k$ .

# Ejemplo (ejercicio): estimación de una constante x escalar

$$x \text{ constante} \Rightarrow \Phi_k = 1, \mathbf{Q}_k = 0.$$

• Tenemos N medidas independientes entre si y de x en t=0, con varianza  $\sigma_v^2$ :

$$\mathbf{y}_k = \begin{bmatrix} 1\\1\\\vdots\\1 \end{bmatrix} x + \begin{bmatrix} v_1\\v_2\\\vdots\\v_N \end{bmatrix}, \ \mathbf{R}_k = \sigma_v^2 \mathbf{I}_N.$$

• Condiciones iniciales:  $\hat{x}_0^- = 0$ ,  $\mathbf{P}_0^- = +\infty$  (esto último no es posible en la formulación anterior porque la ganancia queda  $\infty/\infty$ ).

**Ejercicio:** plantear el filtro y obtener la primera estimación  $\hat{x}_0$ .

# Estimación de una constante: solución

$$\mathbf{1} \ \mathbf{P}_{0}^{-1} = (\mathbf{P}_{0}^{-})^{1} + \mathbf{C}_{0}^{T} \mathbf{R}_{0}^{-1} \mathbf{C}_{0} = \\ (+\infty)^{-1} + \begin{bmatrix} 1 & \dots & 1 \end{bmatrix} \frac{\mathbf{I}_{N}}{\sigma_{v}^{2}} \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = \frac{N}{\sigma_{v}^{2}}$$

2

$$\mathbf{K}_0 = \mathbf{P}_0 \mathbf{C}_0^T \mathbf{R}_0^{-1}$$

$$= \frac{\sigma_v^2}{N} \begin{bmatrix} 1 & \dots & 1 \end{bmatrix} \operatorname{diag}(1/\sigma_v^2, \dots, 1/\sigma_v^2) = \frac{1}{N} \begin{bmatrix} 1 & \dots & 1 \end{bmatrix}$$

3 
$$\hat{x}_0 = \hat{x}_0^- + \mathbf{K}_0(\mathbf{y}_0 - \mathbf{C}_0\hat{x}_0^-) = \mathbf{K}_0\mathbf{y}_0 = \frac{1}{N}\sum_{n=1}^N \mathbf{y}_0(n).$$

#### Predicción

El objetivo es proyectar N pasos hacia adelante (hasta ahora fue N=1).

$$\hat{\mathbf{x}}(k+N|k) = \mathbf{\Phi}(k+N,k)\hat{\mathbf{x}}(k|k)$$
$$\mathbf{P}(k+N|k) = \mathbf{\Phi}(k+N,k)\mathbf{P}(k|k)\mathbf{\Phi}^{T}(k+N,k) + \mathbf{Q}(k+N,k).$$

Dos tipos de predicción: 1. N fijo 2. k fijo, N = 1, 2, 3, ...

