Estimación y Predicción en Series Temporales

Modelos de estado no-lineales: EKF y UKF

Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Biblio:

- Anderson and Moore, Optimal Filtering, 1979 (re-edición Dover 2005).
- Julier, S.J. and Uhlmann, J.K., Unscented filtering and nonlinear estimation, Proceedings of the IEEE, vol.92, no.3, pp.401,422, Mar 2004.
- Wan, E. A., and R. van der Merwe. The unscented Kalman filter, in S. Haykin, ed., Kalman Filtering and Neural Networks, Wiley, New York, Chapter 7, 2001

Introducción - Motivación

Consideremos los modelos de estado en sus versiones general y lineal:

$$\begin{cases} \mathbf{x}_{k+1} &= \mathbf{f}_{k+1}(\mathbf{x}_k, \mathbf{v}_{k+1}) \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_k, \mathbf{n}_k) \end{cases} \qquad \begin{cases} \mathbf{x}_{k+1} &= \mathbf{F}_{k+1}\mathbf{x}_k + \mathbf{G}_{k+1}\mathbf{v}_{k+1} \\ \mathbf{y}_k &= \mathbf{H}_k\mathbf{x}_k + \mathbf{U}_k\mathbf{n}_k \end{cases}$$

Hasta ahora hemos visto sobre el filtro de Kalman, que:

- Si los ruidos no son necesariamente Gaussianos, el filtro de Kalman es óptimo entre todos los filtros lineales, en el sentido del MSE.
- Si los ruidos son Gaussianos, el filtro de Kalman es universalmente óptimo (i.e. aún dentro del conjunto de los filtros no-lineales) en el sentido del MSE.
- Todo proceso ARMA se puede representar como un filtro de Kalman, pasando a una representación en variables de estado.

Hoy nos concentraremos en dos técnicas para modelos no-lineales:

1 Extended Kalman Filter (EKF): básicamente una

El filtro de Kalman Extendido (EKF)

La linealización

Consideramos ahora un modelo en el espacio de estados no-lineal, de la forma:

$$\begin{cases} \mathbf{x}_{k+1} &= \mathbf{f}_{k+1}(\mathbf{x}_k, \mathbf{v}_{k+1}) \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_k, \mathbf{n}_k). \end{cases}$$

El filtro de Kalman extendido se basa en una aproximación de primer orden del modelo, seguido del loop de Kalman con ecuaciones lineales.

- La ecuación de estado se linealiza entorno a $(\mathbf{x}, \mathbf{v}) = (\mathbf{x}_{k|k}, 0)$.
- La ecuación de medida se linealiza entorno a $(\mathbf{x}, \mathbf{n}) = (\mathbf{x}_{k|k-1}, 0).$

$$\begin{cases} \mathbf{x}_{k+1} &= \mathbf{f}_{k+1}(\mathbf{x}_{k|k}, 0) + \mathbf{F}_{k+1}(\mathbf{x}_k - \mathbf{x}_{k|k}) + \mathbf{G}_{k+1}\mathbf{v}_{k+1} \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_{k|k-1}, 0) + \mathbf{H}_k(\mathbf{x}_k - \mathbf{x}_{k|k-1}) + \mathbf{U}_k\mathbf{n}_k, \end{cases}$$

dónde

$$\partial \mathbf{f}_{t+1}$$
 $\partial \mathbf{f}_{t+1}$

El filtro de Kalman Extendido (EKF)

Las iteraciones de Kalman

Las ecuaciones para el EKF quedan entonces:

- Inicialización: \mathbf{x}_0 , \mathbf{P}_0 .
- Para $k = 0, 1, 2, \ldots$, calcular:

$$\begin{split} \hat{\mathbf{x}}_{k|k-1} &= \mathbf{f}_k(\hat{\mathbf{x}}_{k-1|k-1}, 0) \\ \mathbf{P}_{k|k-1} &= \mathbf{F}_k \mathbf{P}_{k-1|k-1} \mathbf{F}_k^T + \mathbf{G}_k \mathbf{Q}_k \mathbf{G}_k^T \\ \mathbf{K}_k &= \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{U}_k \mathbf{R}_k \mathbf{U}_k^T)^{-1} \\ \hat{\mathbf{x}}_{k|k} &= \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{y}_k - \mathbf{h}_k (\hat{\mathbf{x}}_{k|k-1}, 0)) \\ \mathbf{P}_{k|k} &= (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} \end{split}$$

Observaciones y comentarios:

- El problema del filtro EKF es que la linealización del modelo introduce un sesgo en $\hat{\mathbf{x}}_{k|k}$ y una covarianza errónea.
- La calidad de la aproximación debida a la linealización será mejor cuanto menor sean $\|\mathbf{x} - \hat{\mathbf{x}}_{k|k}\|^2$ y $\|\mathbf{x} - \hat{\mathbf{x}}_{k|k-1}\|^2$.

El Unscented Kalman Filter (UKF)

Julier & Uhlmann 1996

Este método busca dejar de lado las aproximaciones y trabajar directamente sobre las transformaciones no lineales, mapeando un conjunto de puntos bien elegidos.

La transformación unscented

- Sea $\mathbf{x} \sim \mathcal{N}(\bar{\mathbf{x}}, \mathbf{P_x})$ un vector aleatorio de \mathbb{R}^n , $\mathbf{g} : \mathbb{R}^n \to \mathbb{R}^m$ una función, e $\mathbf{y} = \mathbf{g}(\mathbf{x}) \in \mathbb{R}^m$.
- La unscented transform busca calcular estimadores insesgados de \bar{y} y de P_v .
- En lugar de linealizar ${\bf g}$ como en el EKF, la propuesta es evaluar $\bar{{\bf y}}$ y ${\bf P_y}$ (1er y 2do momento de ${\bf y}$) mediante estimaciones empíricas ponderadas, calculadas a partir de la transformación exacta ${\bf g}$ de un conjunto de puntos bien elegidos alrededor de $\bar{{\bf x}}$, denominados σ -puntos.

UKF: Los σ -puntos

Tenemos $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{x} \sim \mathcal{N}(\bar{\mathbf{x}}, \mathbf{P_x})$. Los 2n+1 σ -puntos y sus pesos correspondientes se definen como:

$$\mathcal{X}_{0} = \bar{\mathbf{x}} \qquad W_{0} = \frac{\kappa}{\kappa + n}$$

$$\mathcal{X}_{i} = \bar{\mathbf{x}} + (\sqrt{(\kappa + n)}\mathbf{P}_{\mathbf{x}})_{i} \qquad W_{i} = \frac{1}{2(\kappa + n)}, \ i = 1, \dots, n$$

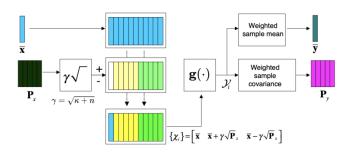
$$\mathcal{X}_{i} = \bar{\mathbf{x}} - (\sqrt{(\kappa + n)}\mathbf{P}_{\mathbf{x}})_{i-n} \qquad W_{i} = \frac{1}{2(\kappa + n)}, \ i = n + 1, \dots, 2n.$$

donde κ es un escalar y $(\sqrt{\mathbf{P_x}})_i$ representa a la i-ésima columna de alguna factorización de $\mathbf{P_x}$, e.g. Cholesky, i.e.

$$\mathbf{P_x} = \sqrt{\mathbf{P_x}} \times \sqrt{\mathbf{P_x}}^T = \sum_{i=1}^n (\sqrt{\mathbf{P_x}})_i (\sqrt{\mathbf{P_x}})_i^T.$$

UKF: Los σ -puntos

2001)



Transformada *Unscented*. Adaptada de (Wan and Van der Merwe,

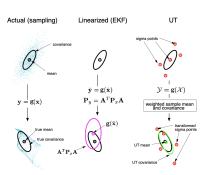
Justificación de la elección de los σ -puntos

Veamos porqué Julier & Uhlmann (1996) proponen esta elección.

A partir de los σ -puntos y sus transformados, se pueden calcular estadísticos empíricos de x y de y. Sea $\mathcal{Y}_i = \mathbf{g}(\mathcal{X}_i)$, definimos

$$\bar{\mathcal{X}} = \sum_{i=0}^{2n} W_i \mathcal{X}_i
\mathbf{P}_{\mathcal{X}} = \sum_{i=0}^{2n} W_i (\mathcal{X}_i - \bar{\mathcal{X}}) (\mathcal{X}_i - \bar{\mathcal{X}})^T
\bar{\mathcal{Y}} = \sum_{i=0}^{2n} W_i \mathcal{Y}_i
\mathbf{P}_{\mathcal{Y}} = \sum_{i=0}^{2n} W_i (\mathcal{Y}_i - \bar{\mathcal{Y}}) (\mathcal{Y}_i - \bar{\mathcal{Y}})^T$$

Ejercicio: Demostrar que media y covarianza empíricas de $\mathcal{X} = \{\mathcal{X}_i\}_{i=0}^{2n}$ coinciden con las de \mathbf{x} .



Propagación de media y matriz de covarianza: (a) Monte Carlo en la imagen de g, (b) Linealización (UKF), (c) Transformada *Unscented*. Figura adaptada de (Wan and Van der Merwe. 2001)

Justificación de la elección de los σ -puntos (cont.)

Resta ver qué pasa con la media y covarianza empíricas de los $\{\mathcal{Y}_i\}_{i=1}^{2n+1}$ en relación a \mathbf{y} .

Suponemos que $\mathbf{g}=[g_1,g_2,\ldots,g_m]^T$, $g_i:\mathbb{R}^n\to\mathbb{R}$, admite un desarrollo de Taylor entorno a $\bar{\mathbf{x}}$. Entonces tenemos

$$\mathbf{g}(\bar{\mathbf{x}} + \boldsymbol{\delta}) = \mathbf{g}(\bar{\mathbf{x}}) + D_{\boldsymbol{\delta}}\mathbf{g}(\bar{\mathbf{x}}) + \frac{1}{2}D_{\boldsymbol{\delta}}^2\mathbf{g}(\bar{\mathbf{x}}) + \dots,$$

dónde

$$\begin{split} D_{\boldsymbol{\delta}}\mathbf{g}(\bar{\mathbf{x}}) &= \nabla^T \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\delta} \\ D_{\boldsymbol{\delta}}^2\mathbf{g}(\bar{\mathbf{x}}) &= D_{\boldsymbol{\delta}}[\nabla^T \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\delta}] = \nabla^T [\nabla^T \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\delta}] \boldsymbol{\delta} \\ &= [\text{Tr}(\nabla^2 g_1(\bar{\mathbf{x}}) \boldsymbol{\delta} \boldsymbol{\delta}^T), \dots, \text{Tr}(\nabla^2 g_m(\bar{\mathbf{x}}) \boldsymbol{\delta} \boldsymbol{\delta}^T)]^T, \end{split}$$

con $\nabla \mathbf{g}$ la matriz Jacobiana de \mathbf{g} , y $\nabla^2 g_i$ la matriz Hessiana de g_i (Apéndice)

Justificación de la elección de los σ -puntos (cont.)

Luego,

$$\bar{\mathbf{y}} = \mathbb{E}[\mathbf{g}(\mathbf{x})] = \mathbb{E}[\mathbf{g}(\bar{\mathbf{x}} + \boldsymbol{\delta})]
= \mathbf{g}(\bar{\mathbf{x}}) + \mathbb{E}[\nabla^T \mathbf{g}(\bar{\mathbf{x}})\boldsymbol{\delta}] + \frac{1}{2}\mathbb{E}[[\operatorname{Tr}(\nabla^2 g_1(\bar{\mathbf{x}})\boldsymbol{\delta}\boldsymbol{\delta}^T), \dots, \operatorname{Tr}(\nabla^2 g_m(\bar{\mathbf{x}})\boldsymbol{\delta}\boldsymbol{\delta}^T)]^T] + \dots$$

Como $\mathbf{x} = \bar{\mathbf{x}} + \boldsymbol{\delta}$, tenemos $\boldsymbol{\delta} \sim \mathcal{N}(\mathbf{0}, \mathbf{P_x})$, por lo que $\mathbb{E}[\boldsymbol{\delta}] = 0$ y $\mathbb{E}[\boldsymbol{\delta}\boldsymbol{\delta}^T] = \mathbf{P_x}$:

$$\bar{\mathbf{y}} = \mathbf{g}(\bar{\mathbf{x}}) + \frac{1}{2} [\text{Tr}(\nabla^2 g_1(\bar{\mathbf{x}}) \mathbf{P_x}), \dots, \text{Tr}(\nabla^2 g_m(\bar{\mathbf{x}}) \mathbf{P_x})]^T + \dots$$

Por otra parte, considerando $\sigma_i = (\sqrt{(\kappa + n)\mathbf{P_x}})_i$,

$$\bar{\mathbf{y}} = W_0 \mathbf{g}(\bar{\mathbf{x}}) + \sum_{i=1}^n W_i (\mathbf{g}(\bar{\mathbf{x}} + \boldsymbol{\sigma}_i) + \mathbf{g}(\bar{\mathbf{x}} - \boldsymbol{\sigma}_i))$$

$$= \mathbf{g}(\bar{\mathbf{x}}) + \mathbf{0} + \frac{1}{2} \mathbb{E}[[\operatorname{Tr}(\nabla^2 g_1(\bar{\mathbf{x}}) \sum_{i=1}^{2n} \frac{\boldsymbol{\sigma}_i \boldsymbol{\sigma}_i^T}{2(\kappa + n)}, \dots, \operatorname{Tr}(\nabla^2 g_m(\bar{\mathbf{x}}) \sum_{i=1}^{2n} \frac{\boldsymbol{\sigma}_i \boldsymbol{\sigma}_i^T}{2(\kappa + n)})]^T] + \dots$$

$$= \mathbf{g}(\bar{\mathbf{x}}) + \frac{1}{2} [\operatorname{Tr}(\nabla^2 g_1(\bar{\mathbf{x}}) \mathbf{P}_{\mathbf{x}}), \dots, \operatorname{Tr}(\nabla^2 g_m(\bar{\mathbf{x}}) \mathbf{P}_{\mathbf{x}})]^T + \dots$$

En ambos casos, debido a la simetría de los σ -puntos entorno a $\bar{\mathbf{x}}$, los términos impares se anulan, por los que la media empírica de los $\{\mathcal{Y}_i\}_{i=0}^{2n}$ coincide con $\bar{\mathbf{y}}$ hasta el tercer orden.

Justificación de la elección de los σ -puntos (cont.)

Ahora vemos qué pasa con P_y y P_y .

$$\begin{aligned} \mathbf{P}_{\mathbf{y}} &= \mathbb{E}[(\mathbf{g}(\bar{\mathbf{x}} + \boldsymbol{\delta}) - \mathbf{g}(\bar{\mathbf{x}}))(\mathbf{g}(\bar{\mathbf{x}} + \boldsymbol{\delta}) - \mathbf{g}(\bar{\mathbf{x}}))^{T}] \\ &= \mathbb{E}[(\nabla^{T} \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\delta})(\nabla^{T} \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\delta})^{T}] + \dots = \nabla^{T} \mathbf{g}(\bar{\mathbf{x}}) \mathbb{E}[\boldsymbol{\delta} \boldsymbol{\delta}^{T}] \nabla \mathbf{g}(\bar{\mathbf{x}}) + \dots \\ &= \nabla^{T} \mathbf{g}(\bar{\mathbf{x}}) \mathbf{P}_{\mathbf{x}} \nabla \mathbf{g}(\bar{\mathbf{x}}) + \dots \end{aligned}$$

Por otro lado,

$$\mathbf{P}_{\mathcal{Y}} = \sum_{i=0}^{2n} W_i (\mathcal{Y}_i - \bar{\mathcal{Y}}) (\mathcal{Y}_i - \bar{\mathcal{Y}})^T$$

$$= \frac{1}{2(n+\kappa)} \times 2 \sum_{i=1}^n (\nabla^T \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\sigma}_i + \dots) (\nabla^T \mathbf{g}(\bar{\mathbf{x}}) \boldsymbol{\sigma}_i + \dots)^T$$

$$= \nabla^T \mathbf{g}(\bar{\mathbf{x}}) \mathbf{P}_{\mathbf{x}} \nabla \mathbf{g}(\bar{\mathbf{x}}) + \dots$$

Por los que ambas coinciden en el primer orden. Ajustando κ para que $n+\kappa=3$, se puede mostrar que las medias pueden coincidir hasta orden 4. Sin embargo, la covarianza empírica ponderada puede volverse semidefinida negativa. Este problema fue resuelto por Julier en 2002, introduciendo la scaled unscented transformation.

Scaled Unscented Transform

La idea es escalar la distancia entre los σ -puntos remplazando \mathcal{X}_i por

$$\mathcal{X}'_i = \mathcal{X}_0 + \alpha(\mathcal{X}_i - \mathcal{X}_0)$$
, con α el factor de escala.

• En este caso W_0 debe ser diferente. Llamando $\lambda = \alpha^2(\kappa + n) + n$, la scaled unscented transform se resume así:

$$\mathcal{X}_{0} = \bar{\mathbf{x}} \qquad W_{0}^{(m)} = \frac{\lambda}{\lambda + n}, \quad W_{0}^{(c)} = \frac{\lambda}{\lambda + n} + (1 - \alpha^{2} + \alpha$$

donde $0 \le \alpha \le 1$, κ puede ser seteado a 0, y $\beta = 2$ es el valor óptimo en el caso Gaussiano.

De esta forma, las medias y covarianzas empíricas de \mathbf{x} e \mathbf{y} quedan:

$$\bar{\mathcal{X}} = \sum_{i=0}^{2n} W_i^{(m)} \mathcal{X}_i$$

Unscented Kalman Filter (UKF)

El UKF se obtiene juntando las formulas del filtro de Kalman con las de la Unscented Transform. Considerando nuevamente el modelo no-lineal

$$\begin{cases} \mathbf{x}_{k+1} &= \mathbf{f}_{k+1}(\mathbf{x}_k, \mathbf{v}_{k+1}) \\ \mathbf{y}_k &= \mathbf{h}_k(\mathbf{x}_k, \mathbf{n}_k), \end{cases}$$

y usando una representación de estado aumentada $\mathbf{x}_k^a = [\mathbf{x}_k^T \ \mathbf{v}_k^T \ \mathbf{n}_k^T]^T$ con su correspondiente matriz de covarianza, el UKF se resume como:

1 Inicialización:
$$\mathbf{x}_{0|0}$$
, $\mathbf{P}_{0|0}$

Iteraciones: para $k = 1, 2, \ldots$,

$$\mathbf{P}^{a} \qquad = \left[\begin{array}{ccc} \mathbf{P}_{k-1|k-1} & 0 & 0 \\ 0 & \mathbf{Q}_{k} & 0 \\ 0 & 0 & \mathbf{R}_{k} \end{array} \right]$$

$$\mathcal{X}^{a} = \begin{bmatrix} \mathbf{x}_{k-1|k-1}^{a} \mid \mathbf{x}_{k-1|k-1}^{a} \pm \sqrt{(n+\lambda)\mathbf{P}^{a}} \end{bmatrix} = \begin{bmatrix} \mathcal{X}_{k-1|k-1}^{x} \\ \mathcal{X}_{k}^{v} \\ \mathcal{X}_{k}^{n} \end{bmatrix}$$

$$\mathcal{X}_{k|k-1}^{x} = \mathbf{f}_{k}(\mathcal{X}_{k-1|k-1}^{x}, \mathcal{X}_{k}^{v})$$

$$\mathbf{x}_{k|k-1} = \sum_{i=0}^{2n} W_{i}^{(m)} \mathcal{X}_{k|k-1,i}^{x}$$

$$\begin{array}{ll} \mathbf{P}_{k|k-1}^{\mathbf{x}} &= \sum_{i=0}^{2n} W_i^{(c)} (\mathcal{X}_{k|k-1,i}^x - \mathbf{x}_{k|k-1}) (\mathcal{X}_{k|k-1,i}^x - \mathbf{x}_{k|k-1})^T \end{array}$$

$$\mathcal{Y}_{k|k-1} = \mathbf{h}(\mathcal{X}_{k|k-1}^x, \mathcal{X}_k^n)$$

$$\mathbf{y}_{k|k-1} = \sum_{i=0}^{2n} W_i^{(m)} \mathcal{Y}_{k|k-1,i}$$

$$\mathbf{P}_{k|k-1}^{\mathbf{y}} = \sum_{i=0}^{2n} W_i^{(c)} (\mathcal{Y}_{k|k-1,i} - \mathbf{y}_{k|k-1}) (\mathcal{Y}_{k|k-1,i} - \mathbf{y}_{k|k-1})^T$$

$$\begin{array}{ll} \mathbf{P}_{k|k-1}^{\mathbf{x}\mathbf{y}} &= \sum_{i=0}^{2n} W_i^{(c)} (\mathcal{X}_{k|k-1,i}^x - \mathbf{x}_{k|k-1}) (\mathcal{Y}_{k|k-1,i} - \mathbf{y}_{k|k-1})^T \end{array}$$

$$\mathbf{K}_k = \mathbf{P}_{k|k-1}^{\mathbf{x}\mathbf{y}} (\mathbf{P}_{k|k-1}^{\mathbf{y}})^{-1}$$

$$\mathbf{x}_{k|k} = \mathbf{x}_{k|k-1} + \mathbf{K}_k(\mathbf{y}_k - \mathbf{y}_{k|k-1})$$

$$\mathbf{P}_{k|k} = \mathbf{P}_{k|k-1} - \mathbf{K}_k \mathbf{P}_{k|k-1}^{\mathbf{y}} \mathbf{K}_k^T.$$

Apéndice

Consideramos el caso n=2, m=1, i.e. $\mathbf{g}(\bar{\mathbf{x}})=g_1(x_1,x_2)$.

$$D_{\boldsymbol{\delta}}\mathbf{g}(\bar{\mathbf{x}}) = \nabla^T \mathbf{g}(\bar{\mathbf{x}})\boldsymbol{\delta} = \frac{\partial g_1}{\partial x_1} \delta_1 + \frac{\partial g_1}{\partial x_2} \delta_2$$

$$\begin{split} D_{\boldsymbol{\delta}}^{2}\mathbf{g}(\bar{\mathbf{x}}) &= D_{\boldsymbol{\delta}}[\nabla^{T}\mathbf{g}(\bar{\mathbf{x}})\boldsymbol{\delta}] = \nabla^{T}[\nabla^{T}\mathbf{g}(\bar{\mathbf{x}})\boldsymbol{\delta}]\boldsymbol{\delta} \\ &= \left[\frac{\partial^{2}g_{1}}{\partial x_{1}^{2}}\delta_{1} + \frac{\partial^{2}g_{1}}{\partial x_{1}\partial x_{2}}\delta_{2}, \frac{\partial^{2}g_{1}}{\partial x_{2}\partial x_{1}}\delta_{1} + \frac{\partial^{2}g_{1}}{\partial x_{2}^{2}}\delta_{2}\right] \begin{bmatrix} \delta_{1} \\ \delta_{2} \end{bmatrix} \\ &= \frac{\partial^{2}g_{1}}{\partial x_{1}^{2}}\delta_{1}^{2} + \frac{\partial^{2}g_{1}}{\partial x_{1}\partial x_{2}}\delta_{1}\delta_{2} + \frac{\partial^{2}g_{1}}{\partial x_{2}\partial x_{1}}\delta_{1}\delta_{2} + \frac{\partial^{2}g_{1}}{\partial x_{2}^{2}}\delta_{2}^{2} \\ &= \operatorname{Tr}\left(\begin{bmatrix} \frac{\partial^{2}g_{1}}{\partial x_{1}^{2}} & \frac{\partial^{2}g_{1}}{\partial x_{1}\partial x_{2}} & \frac{\partial^{2}g_{1}}{\partial x_{1}\partial x_{2}} \\ \frac{\partial^{2}g_{1}}{\partial x_{1}\partial x_{2}} & \frac{\partial^{2}g_{1}}{\partial x_{2}^{2}} \end{bmatrix} \begin{bmatrix} \delta_{1}^{2} & \delta_{1}\delta_{2} \\ \delta_{1}\delta_{2} & \delta_{2}^{2} \end{bmatrix}\right) = \operatorname{Tr}(\nabla^{2}g_{1}(\bar{\mathbf{x}})\boldsymbol{\delta}\boldsymbol{\delta}^{T}) \end{split}$$