Estimación y Predicción en Series Temporales

Convergencia de RLS

Departamento de Procesamiento de Señales

Instituto de Ingeniería Eléctrica Facultad de Ingeniería

2022

Biblio:

Haykin, Adaptive Filter Theory, 4ta edición, 2002.
 Capítulo 9: "Recursive Least Squares Adaptive Filters".

Introducción

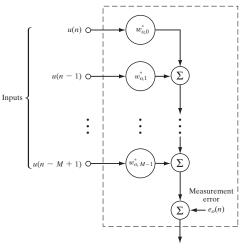
Estudiaremos la convergencia del algoritmo en los siguientes aspectos:

- Convergencia de $\mathbb{E}[\hat{\mathbf{w}}(n)]$
- Convergencia de $\hat{\mathbf{w}}(n)$ en media cuadrática
- Convergencia en media de la media cuadrática de $\alpha(n)$

Recordemos que

$$\begin{split} &\alpha(n) = d(n) - \hat{\mathbf{w}}^H(n-1)\mathbf{u}(n) & \text{(error a priori)} \\ &\hat{\mathbf{w}}(n) = \hat{\mathbf{w}}(n-1) + \mathbf{k}(n)\alpha^*(n) & \text{(actualización óptima)} \\ &\mathcal{E}_{min}(n) = d(n) - \hat{\mathbf{w}}^H(n)\mathbf{u}(n) & \text{(error a posteriori)} \end{split}$$

Introducción (2)



Tenemos $d(n) = e_0(n) + \mathbf{w}_0^H(n)\mathbf{u}(n)$. Observation Suponemos $\mathbf{w}_0(n) = \mathbf{w}_0$ constante (estacionario). En este caso el menor error se obtiene con $\lambda = 1$.

Convergencia del RLS en valor medio

Comenzamos con $\Phi(0)=\delta {f I}$ con delta $\delta>0$ pequeño para asegurar que $\Phi(n)\succ 0$. La ecuación normal nos da

$$\hat{\mathbf{w}}(n) = \mathbf{\Phi}^{-1}(n)\boldsymbol{\theta}(n), \quad n > M \tag{1}$$

Si
$$\lambda = 1$$
, $\Phi(n) = \sum_{i=1}^{n} \mathbf{u}(i)\mathbf{u}(i)^{H} + \Phi(0)$

$$\mathbf{y} \ \boldsymbol{\theta}(n) = \sum_{i=1}^{n} \mathbf{u}(i)d^{*}(i) = \sum_{i=1}^{n} \mathbf{u}(i)(e_{0}(i) + \mathbf{w}_{0}^{H}\mathbf{u}(i))^{*}$$

$$= \sum_{i=1}^{n} \mathbf{u}(i)\mathbf{u}^{H}(i)\mathbf{w}_{0} + \sum_{i=1}^{n} \mathbf{u}(i)e_{0}^{*}(i)$$

$$= \Phi(n)\mathbf{w}_{0} - \Phi(0)\mathbf{w}_{0} + \sum_{i=1}^{n} \mathbf{u}(i)e_{0}^{*}(i)$$
(2)

Sustituyendo (2) en (1),

$$\hat{\mathbf{w}}(n) = \mathbf{w}_0 - \mathbf{\Phi}^{-1}(n)\mathbf{\Phi}(0)\mathbf{w}_0 + \mathbf{\Phi}^{-1}(n)\sum_{i=1}^n \mathbf{u}(i)e_0^*(i).$$

Convergencia del RLS en valor medio (2)

$$\hat{\mathbf{w}}(n) = \mathbf{w}_0 - \mathbf{\Phi}^{-1}(n)\mathbf{\Phi}(0)\mathbf{w}_0 + \mathbf{\Phi}^{-1}(n)\sum_{i=1}^n \mathbf{u}(i)e_0^*(i).$$

Para calcular $\mathbb{E}[\hat{\mathbf{w}}(n)]$ necesitamos la propiedad: $\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$. Luego,

$$\mathbb{E}[\hat{\mathbf{w}}(n)] = \mathbf{w}_0 + \mathbb{E}\left[\mathbf{\Phi}^{-1}(n)\sum_{i=1}^n \mathbf{u}(i)e_0^*(i) - \mathbf{\Phi}^{-1}(n)\mathbf{\Phi}(0)\mathbf{w}_0\right]$$
$$= \mathbf{w}_0 + \mathbb{E}\left[\mathbb{E}\left[\mathbf{\Phi}^{-1}(n)\sum_{i=1}^n \mathbf{u}(i)e_0^*(i) - \mathbf{\Phi}^{-1}(n)\mathbf{\Phi}(0)\mathbf{w}_0\right] | \mathbf{u}(1), \dots, \mathbf{u}(n)\right]$$

Obs.:

- \bullet \bullet \bullet (*n*) está totalmente determinada por $\mathbf{u}(1), \dots, \mathbf{u}(n)$.
- 2 $e_0(i)$ es independiente de $\mathbf{u}(n) \ \forall i$.
- **3** $\mathbb{E}[e_0(i)] = 0.$

Asumiendo ergodicidad en autocorrelación de $\{u(n)\},\$

 $\mathbf{R} \approx \frac{1}{n} \mathbf{\Phi}(n) \ \forall n > M,$

$$\mathbb{E}[\hat{\mathbf{w}}(n)] = \mathbf{w}_0 - \frac{1}{n} \mathbf{R}^{-1} \mathbf{\Phi}(0) \mathbf{w}_0 = \mathbf{w}_0 - \frac{\delta}{n} \mathbf{R}^{-1} \mathbf{w}_0 = \mathbf{w}_0 - \frac{\delta}{n} \mathbf{p}, \quad n > M.$$

Obs.: Si optamos por $\Phi(0) = 0$, la convergencia se da para n > M no hay que esperar a $n \to +\infty$

Convergencia de los coeficientes en media cuadrática

Ignorando los efectos de la inicialización ($n \gg \delta$ o $\delta = 0$),

$$\boldsymbol{\epsilon}(n) = \hat{\mathbf{w}}(n) - \mathbf{w}_0 = \boldsymbol{\Phi}^{-1}(n) \sum_{i=1}^n \mathbf{u}(i) e_0^*(i).$$

$$\mathbf{K}(n) = \mathbb{E}_{u,e}[\boldsymbol{\epsilon}(n)\boldsymbol{\epsilon}^{H}(n)]$$

$$= \mathbb{E}_{u,e}[\boldsymbol{\Phi}^{-1}(n)\sum_{i=1}^{n}\sum_{j=1}^{n}\mathbf{u}(i)e_{0}^{*}(i)e_{0}^{*}(j)\mathbf{u}^{H}(j)\boldsymbol{\Phi}^{-1}(n)]$$

$$= \mathbb{E}_{u}[\boldsymbol{\Phi}^{-1}(n)\sum_{i=1}^{n}\sum_{j=1}^{n}\mathbf{u}(i)\underbrace{\mathbb{E}_{e}[e_{0}^{*}(i)e_{0}^{*}(j)]}_{\sigma^{2}\delta_{ij}}\mathbf{u}^{H}(j)\boldsymbol{\Phi}^{-1}(n)]$$

$$= \sigma^{2}\mathbb{E}_{u}[\boldsymbol{\Phi}^{-1}(n)\underbrace{\sum_{j=1}^{n}\mathbf{u}(i)\mathbf{u}^{H}(i)}_{\boldsymbol{\Phi}(n)}\boldsymbol{\Phi}^{-1}(n)]$$

$$= \sigma^{2}\mathbb{E}[\boldsymbol{\Phi}^{-1}(n)].$$

Convergencia de los coeficientes en media cuadrática (2)

Suponemos ahora (similar a como hicimos para LMS):

- $\mathbf{u}(1), \mathbf{u}(2), \dots, \mathbf{u}(n)$ i.i.d.
- $\mathbf{u}(1), \mathbf{u}(2), \dots, \mathbf{u}(n)$ provienen de procesos gaussianos de matriz de autocorrelación \mathbf{R} .

Se puede ver (Haykin) que $\Phi^{-1}(n)$ sigue una distribución de Wishart compleja, y que cumple

$$\mathbb{E}[\mathbf{\Phi}^{-1}(n)] = \frac{1}{n}\mathbf{R}^{-1}, \quad n > M.$$

Luego, podemos escribir $\mathbf{K}(n) = \frac{\sigma^2}{n} \mathbf{R}^{-1}, \quad n > M$. El desvío cuadrático medio vale $\mathbb{E}[\mathbf{K}(n) \boldsymbol{\epsilon}(n)] = \mathbb{E}[\mathrm{Tr}[\boldsymbol{\epsilon}(n) \boldsymbol{\epsilon}^H(n)]]$

$$= \operatorname{Tr}[\mathbf{K}(n)] = \frac{\sigma^2}{n} \operatorname{Tr}[\mathbf{R}^{-1}(n)] = \frac{\sigma^2}{n} \sum_{i=1}^{M} \frac{1}{\lambda_i}, \quad n > M.$$

Obs.:

1 El error aumenta proporcionalmente al λ_{min}^{-1} (problemas con situaciones mel condicionadas)

Curva de aprendizaje

Tenemos dos tipos de errores: $\alpha(n)$ error a prior, e(n) error a posteriori.

Veremos que:

- $\alpha(n)$ grande al principio, luego decae.
- e(n) pequeño al principio, luego crece.

Teníamos:

$$\alpha(n) = d(n) - \hat{\mathbf{w}}^H(n-1)\mathbf{u}(n)$$

$$d(n) = e_0(n) + \mathbf{w}_0^H \mathbf{u}(n).$$

De dónde

$$\alpha(n) = e_0(n) - (\hat{\mathbf{w}}(n-1) - \mathbf{w}_0)^H \mathbf{u}(n) = e_0(n) - \boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n).$$

Tomamos como índice de performance $J'(n) = \mathbb{E}[|\alpha(n)|^2]$.

Curva de aprendizaje (2)

$$J'(n) = \mathbb{E}[|\alpha(n)|^2] = \mathbb{E}[|e_0(n) - \boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)|^2]$$

$$= \underbrace{\mathbb{E}[|e_0(n)|^2]}_{\sigma^2} + \underbrace{\mathbb{E}[\mathbf{u}^H(n)\boldsymbol{\epsilon}^H(n-1)\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)]}_{(a)}$$

$$- \underbrace{\mathbb{E}[\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)e_0^*(n)]}_{(b)} - \underbrace{\mathbb{E}[e_0(n)\mathbf{u}^H(n)\boldsymbol{\epsilon}(n-1)]}_{(c)}.$$

Tenemos:

$$(a) = \mathbb{E}[\operatorname{Tr}[\mathbf{u}^{H}(n)\boldsymbol{\epsilon}^{H}(n-1)\boldsymbol{\epsilon}^{H}(n-1)\mathbf{u}(n)]]$$

$$= \mathbb{E}[\operatorname{Tr}[\mathbf{u}(n)\mathbf{u}^{H}(n)\boldsymbol{\epsilon}(n-1)\boldsymbol{\epsilon}^{H}(n-1)]]$$

$$= \operatorname{Tr}[\mathbb{E}[\mathbf{u}(n)\mathbf{u}^{H}(n)\boldsymbol{\epsilon}^{H}(n-1)\boldsymbol{\epsilon}^{H}(n-1)]]$$

$$\approx \operatorname{Tr}[\mathbb{E}[\mathbf{u}(n)\mathbf{u}^{H}(n)]\mathbb{E}[\boldsymbol{\epsilon}(n-1)\boldsymbol{\epsilon}^{H}(n-1)]]$$

$$= \operatorname{Tr}[\mathbf{R}\mathbf{K}(n-1)] = \frac{\sigma^{2}}{n-1}\operatorname{Tr}[\mathbf{R}\mathbf{R}^{-1}] = \frac{M\sigma^{2}}{n-1}, \quad , n > M.$$

Curva de aprendizaje (3)

Luego,

$$(b) = \mathbb{E}[\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)e_0^*(n)] = \mathbb{E}[\boldsymbol{\epsilon}^H(n-1)\mathbf{u}(n)]\underbrace{\mathbb{E}[e_0^*(n)]}_0 = 0,$$

y de la misma forma (c) = 0.

Finalmente,

$$J'(n) = \sigma^2 + \frac{M}{n-1}\sigma^2, \ n > M.$$

Obs.:

- $J'(n) \stackrel{n \to +\infty}{\longrightarrow} \sigma^2$. Esto es, en teoría, el algoritmo RLS no produce error en exceso o desajuste.
- La convergencia en media cuadrática es independiente de los valores propios de R (matriz de autocorrelación del vector de entrada u(n)).